ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



Lê Tràng Việt

PHÁT TRIỂN PHƯƠNG PHÁP HỌC ĐỘNG TRONG HỆ THỐNG KIỂM TRA LỖI CHO MÀN HÌNH ĐIỆN THOẠI

LUẬN VĂN THẠC SĨ KỸ THUẬT PHẦN MỀM

HÀ NỘI - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



Lê Tràng Việt

PHÁT TRIỂN PHƯƠNG PHÁP HỌC ĐỘNG TRONG HỆ THỐNG KIỂM TRA LỖI CHO MÀN HÌNH ĐIỆN THOẠI

LUẬN VĂN THẠC SĨ KỸ THUẬT PHẦN MỀM
Ngành: Kỹ Thuật Phần Mềm
Mã chuyên ngành: 8480103

Cán bộ hướng dẫn: TS. Vũ Thị Hồng Nhạn
TS. Đỗ Đức Đông

HÀ NỘI - 2026

VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY



Le Trang Viet

DEVELOPMENT OF AN ADAPTIVE LEARNING METHOD IN A DEFECT INSPECTION SYSTEM FOR SMARTPHONE DISPLAYS

SOFTWARE ENGINEERING MASTER'S THESIS

Major: Software Engineering
Program Code: 8480103

Supervisor: Dr. Vu Thi Hong Nhan
Co-Supervisor: Dr. Do Duc Dong

HANOI - 2026

Lời cảm ơn

Trước tiên, tôi xin gửi lời cảm ơn chân thành và sâu sắc nhất cô giáo TS. Vũ Thị Hồng Nhạn và thầy giáo TS. Đỗ Đức Đông, những người đã trực tiếp định hướng, chỉ bảo và tận tình đồng hành trong suốt quá trình thực hiện đề tài. Sự định hướng phương pháp luận, những góp ý chuyên môn quý báu cùng sự khuyến khích liên tục từ các thầy cô chính là nền tảng quan trọng giúp tôi hoàn thành luận văn này.

Tôi xin chân thành cảm ơn các thầy cô giáo tại Khoa Công nghệ Thông tin, Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội đã truyền đạt hệ thống kiến thức nền tảng và chuyên sâu trong suốt khóa học. Môi trường học thuật cùng sự hỗ trợ tận tình từ các thầy cô trong Khoa đã tạo tiền đề lý luận và điều kiện nghiên cứu thuận lợi cho tôi.

Tôi xin trân trọng cảm ơn Phòng Đào tạo và Ban Giám hiệu Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội đã tạo mọi điều kiện thuận lợi trong suốt quá trình đào tạo và hoàn thiện luận văn. Những hỗ trợ hành chính và môi trường học tập từ Nhà trường đã giúp tôi hoàn thành đúng tiến độ các nhiệm vụ nghiên cứu.

Cuối cùng, tôi xin bày tỏ lòng biết ơn vô hạn đối với cha, mẹ và vợ tôi đã luôn ủng hộ và yêu thương tôi một cách vô điều kiện. Nếu không có sự ủng hộ của gia đình tôi không thể hoàn thành được luận văn này.

Lời cam đoan

Tôi xin cam đoan rằng luận văn thạc sỹ công nghệ thông tin "Phát triển học động trong hệ thống kiểm tra lỗi cho màn hình điện thoại" là công trình nghiên cứu của riêng tôi dưới sự hướng dẫn của TS. Vũ Thị Hồng Nhạn và TS. Đỗ Đức Đông, không sao chép lại của người khác. Các tài liệu tham khảo được trích dẫn và chú thích đầy đủ.

Hà Nội, ngày 15 tháng 08 năm 2026

Học viên

Lê Tràng Việt

Tóm tắt

Luận văn nghiên cứu phương pháp tự động phân loại các dạng lỗi hiển thị trên màn hình điện thoại trong quy trình sản xuất công nghiệp bằng mạng khí nơ-ron tăng trưởng hai giai đoạn. Hệ thống kết hợp kỹ thuật xử lý ảnh, mạng nơ-ron sâu và thuật toán tăng trưởng mạng khí nơ-ron tăng trưởng tự tổ chức tích lũy bằng chứng (Evidence-Accumulating Growing Neural Gas - EAGNG). Mô hình giải quyết thách thức về sự thiếu hụt dữ liệu gán nhãn ban đầu và hiện tượng quên tri thức đã học (catastrophic forgetting) khi dữ liệu biến đổi theo thời gian.

Giai đoạn đầu tiên thực hiện tác vụ phát hiện bất thường ngoại tuyến trên các mẫu màn hình đạt chuẩn. Dữ liệu ảnh đầu vào được bổ sung kênh thông tin entropy cục bộ nhằm phản ánh độ biến thiên kết cấu bề mặt. Mạng mã hóa tự động (Autoencoder) tiến hành nén ảnh thành các vectơ biểu diễn không gian tiềm ẩn. Mạng Growing Neural Gas truyền thống huấn luyện trên các vector tiềm ẩn này nhằm thiết lập ranh giới phân bố của sản phẩm bình thường. Trong quá trình suy luận, các mẫu có khoảng cách tới mạng vượt quá ngưỡng ba lần độ lệch chuẩn (3σ) được xác định là bất thường và chuyển giao sang giai đoạn xử lý tiếp theo.

Giai đoạn thứ hai thực hiện phân cụm lỗi trực tuyến thông qua mạng học động EAGNG với bốn cơ chế cải tiến. Các vector đặc trưng hình thái trích xuất từ mô hình ResNet kết hợp kênh entropy đóng vai trò làm đầu vào huấn luyện. Bốn cơ chế bổ trợ bao gồm: (i) điều chỉnh tốc độ học và mức tích lũy lỗi dựa trên tuổi của nơ-ron nhằm đảm bảo sự hội tụ cấu trúc, (ii) chèn nút hoãn lại dựa trên bằng chứng tích lũy trong bộ đệm nhằm giảm thiểu nhiễu cục bộ, (iii) phát triển cấu trúc mạng nhận biết mật độ nhằm kiểm soát sự phân bố nơ-ron, và (iv) kiểm tra sự chồng lấp hộp giới hạn (bounding box overlap check) nhằm ngăn chặn liên kết không hợp lệ giữa các cụm độc lập. Thuật toán phân cụm thành phần liên thông trong lý thuyết đồ thị được áp dụng trên cấu trúc mạng tối ưu để hoàn tất phân loại dạng lỗi.

Hiệu năng của thuật toán EAGNG được đánh giá qua thực nghiệm trên chuỗi dữ liệu gồm ba nghìn bước thời gian (3000 steps). Trong giai đoạn phân cụm ổn định từ bước 650 đến bước 1800, thuật toán EAGNG đạt giá trị 100% trên cả ba chỉ số đánh giá gồm chỉ số Rand điều chỉnh (Adjusted Rand Index - ARI), thông tin tương hỗ chuẩn hóa (Normalized Mutual Information - NMI) và độ tinh khiết (Purity). Tại giai đoạn xuất hiện dịch chuyển khái niệm (concept drift) từ bước 1850 đến bước 3000, thuật toán EAGNG duy trì giá trị ARI trung bình là 89,98%, NMI trung bình là 92,30% và Purity trung bình là 95,49%. Tính trên toàn bộ chu kỳ phân cụm từ bước 650 đến bước 3000, mô hình đạt ARI trung bình là 94,99%, NMI trung bình là 96,15% và Purity trung bình là 97,74%. Tại bước thời

gian cuối cùng, số lượng nút của mạng EAGNG dừng lại ở mức 268 nút so với 361 nút của mạng Growing Neural Gas truyền thống, giảm 25,76% dung lượng bộ nhớ nút, đồng thời ghi nhận thời gian tính toán tích lũy 16,39 giây so với 23,69 giây của mô hình truyền thống.

Từ khóa: *phát hiện lỗi màn hình*, *học không giám sát*, *học cạnh tranh*, *học liên tục*, *mạng Growing Neural Gas (GNG)*, *Autoencoder*, *ResNet*, *entropy cục bộ*, *quên tri thức đã học*

Abstract

This thesis investigates an automated surface defect classification method for mobile phone display inspection using a two-stage dynamic neural network. The system integrates image processing techniques, deep neural architectures, and an evidence-accumulating growing neural gas (EAGNG) algorithm. The proposed approach addresses the scarcity of initially labeled samples and mitigates catastrophic forgetting during continuous stream processing.

The first stage executes offline anomaly detection on normal display samples. Input images are enhanced with local entropy map channels to represent surface texture variations. An autoencoder network compresses the four-channel images into latent space feature vectors. A standard growing neural gas network learns the topology of normal samples in the latent space. During inference, feature vectors with distances exceeding three standard deviations (3σ) from the network nodes are flagged as anomalies and transferred to the second stage.

The second stage performs online defect clustering through the proposed EAGNG dynamic learning algorithm. Morphological feature vectors extracted from a ResNet backbone operating on entropy-enhanced images serve as input to the network. The EAGNG algorithm incorporates four specific mechanisms: (i) node age-dependent learning rate and error accumulation decay to facilitate structural convergence, (ii) evidence-based deferred node insertion using buffer accumulation to filter local noise, (iii) density-aware topology growth to regulate node spatial distribution, and (iv) bounding box overlap checks to prevent invalid edges between distinct clusters. A connected-component graph clustering algorithm is applied to the resulting topology to output final defect categories.

Experimental evaluation across a sequence of three thousand time steps (3000 steps) confirms the quantitative performance of the EAGNG algorithm. In the stable clustering phase between step 650 and step 1800, the EAGNG model achieves a value of 100% across the adjusted Rand index (ARI), normalized mutual information (NMI), and purity metrics. During the concept drift phase from step 1850 to step 3000, the EAGNG model maintains an average ARI of 89.98%, NMI of 92.30%, and purity of 95.49%. Across the full evaluation window from step 650 to step 3000, the model achieves mean values of 94.99% for ARI, 96.15% for NMI, and 97.74% for purity. At the final time step, the EAGNG topology contains 268 nodes compared to 361 nodes in the standard growing neural gas network, representing a 25.76% reduction in node memory allocation, while requiring 16.39 seconds of cumulative execution time compared to 23.69 seconds for the baseline model.

Keywords: *display defect detection*, *unsupervised learning*, *competitive learning*, *growing neural gas (GNG)*, *autoencoder*, *ResNet*, *local entropy*, *catastrophic forgetting*

Mục lục

Lời cảm ơn

Lời cam đoan **i**

Tóm tắt **ii**

Abstract **iv**

Mục lục **v**

Danh sách hình vẽ **ix**

Danh sách bảng **xi**

Danh mục các từ viết tắt **xii**

Mở đầu **1**

Chương 1 Bài toán kiểm tra màn hình điện thoại **3**

1.1 Mô tả bài toán 3

1.2 Ý tưởng và hướng tiếp cận của bài toán 5

1.3 GNG trong kiểm tra màn hình điện thoại 7

1.3.1 Tổng quan về GNG 7

1.3.2 Ứng dụng và các nhược điểm của GNG 8

1.3.3 GNG đối với bài toán kiểm tra hình ảnh lỗi trên màn hình điện thoại 9

1.4 Động cơ nghiên cứu 10

Kết luận Chương 1 11

Chương 2 Cơ sở lý thuyết **13**

2.1 Tổng quan về Xử lý ảnh và Trích chọn đặc trưng 13

2.1.1 Biểu diễn ảnh số và Không gian mức xám 13

2.1.2 Lý thuyết thông tin và Shannon Entropy 15
2.1.3 Entropy cục bộ trong phân tích kết cấu 16
2.2 Mạng Nơ-ron Tích chập và Autoencoder 17
2.2.1 Mạng Nơ-ron Tích chập 17
2.2.2 Kiến trúc Autoencoder 18
2.2.3 Hàm Mất mát Tái tạo 20
2.3 Mạng nơ-ron tích chập ResNet cho trích xuất đặc trưng hình thái . . 21
2.3.1 Cơ chế Học dư và Kiến trúc Residual Block 21
2.3.2 Trích xuất đặc trưng hình thái cho luồng dữ liệu bốn kênh . . . 22
2.3.3 Vai trò của ResNet trong quy trình phân cụm trực tuyến EAGNG 24
2.4 Mạng nơ-ron không giám sát và Growing Neural Gas 24
2.4.1 Mạng tự tổ chức Kohonen 24
2.4.2 Mạng Khí nơ-ron 26
2.4.3 Mạng Khí nơ-ron tăng trưởng 26
2.5 Cơ sở toán học cho các cải tiến của thuật toán EAGNG 29
2.5.1 Lý thuyết suy giảm tốc độ học thích ứng theo vòng đời nút . . 29
2.5.2 Cơ chế đệm bộ nhớ và Ước lượng mật độ không gian cục bộ . . 30
2.5.3 Lý thuyết hình học bao không gian trong kiểm soát liên kết đồ thị 32
2.6 Phát hiện bất thường và phân cụm dựa trên lý thuyết đồ thị 33
2.6.1 Nguyên lý phát hiện bất thường dựa trên phân phối thống kê và khoảng cách 3-Sigma 34
2.6.2 Phân cụm đồ thị bằng thành phần liên thông 36
2.7 Bài toán Học liên tục 37
2.7.1 Mâu thuẫn giữa tính dẻo và tính ổn định 38
2.7.2 Các hướng tiếp cận lý thuyết chủ đạo trong Học liên tục 38
Kết luận Chương 2 39

Chương 3 Kiến trúc Hệ thống và Thuật toán EAGNG Phân cụm Khuyết tật Trực tuyến 41
3.1 Kiến trúc tổng thể hệ thống đề xuất 41
3.1.1 Pha 1: Phát hiện bất thường ngoại tuyến 42
3.1.2 Pha 2: Phân cụm lỗi thích nghi trực tuyến bằng thuật toán EAGNG 43
3.2 Biểu diễn dữ liệu và Xử lý đặc trưng không gian Entropy 44

3.2.1 Thuật toán trích xuất bản đồ Entropy cục bộ 44
3.2.2 Kỹ thuật ghép kênh RGB-E và Chuẩn hóa dữ liệu 45
3.3 Trích xuất đặc trưng chuyên biệt cho hai pha 46
3.3.1 Mạng mã hóa tự động: Nén không gian tiềm ẩn nhận dạng mẫu chuẩn 46
3.3.2 Mạng ResNet bốn kênh: Trích xuất đặc trưng hình thái lỗi . . . 47
3.3.3 Hàm mất mát và Tối ưu hóa mạng trích xuất đặc trưng 48
3.4 Mô hình phát hiện bất thường ngoại tuyến 48
3.4.1 Huấn luyện GNG ngoại tuyến trên không gian tiềm ẩn 49
3.4.2 Cơ chế phân loại bất thường dựa trên khoảng cách ngưỡng ba lần độ lệch chuẩn 50
3.5 Thuật toán phân cụm lỗi trực tuyến EAGNG 52
3.5.1 Cơ chế suy giảm tốc độ học và tích lũy lỗi theo tuổi nút 52
3.5.2 Kiểm tra chồng lấp Bounding Box kiểm soát liên kết cạnh . . . 53
3.5.3 Cơ chế trì hoãn chèn dựa trên bằng chứng và học cục bộ 54
3.5.4 Phát triển cấu trúc nhạy mật độ 54
3.5.5 Phân loại cụm lỗi bằng thuật toán Connected-Component trên đồ thị EAGNG 55
3.5.6 Thuật toán tổng thể và Mã giả EAGNG 56
3.6 Công cụ tự động sinh tập dữ liệu khuyết tật mô phỏng 57
Kết luận Chương 3 61

Chương 4 Kết quả thực nghiệm và Đánh giá 62
4.1 Thiết lập thực nghiệm và Kịch bản đánh giá trôi dạt khái niệm . . . 62
4.1.1 Môi trường thực nghiệm và Cơ sở hạ tầng tính toán 62
4.1.2 Cấu hình tham số thực nghiệm và thuật toán EAGNG 64
4.1.3 Kịch bản dòng dữ liệu khuyết tật liên tục 65
4.2 Phân tích và Đánh giá Kết quả Thực nghiệm 68
4.2.1 Đánh giá khả năng thích ứng với dịch chuyển khái niệm 69
4.2.2 Phân tích độ ổn định cấu trúc và hiện tượng quên thảm họa . . 70
4.2.3 Đánh giá thời gian thực thi và tốc độ xử lý 73
4.2.4 Phân tích trực quan hóa phân cụm lỗi màn hình 73
4.2.5 Tổng hợp kết quả so sánh định lượng 77
4.3 Thảo luận Kết quả và Đóng góp của Nghiên cứu 77

4.3.1 Thảo luận về hiệu năng hệ thống và tính hợp nhất cấu trúc . . 78
4.3.2 Đóng góp khoa học và ý nghĩa ứng dụng thực tiễn 78
Kết luận Chương 4 79

Kết luận **81**

Tài liệu tham khảo **83**

Danh sách hình vẽ

1.1 Sơ đồ tổng quan quy trình kiểm tra và phân loại lỗi màn hình điện thoại. 4
1.2 Sơ đồ kiến trúc hướng tiếp cận hai pha trong kiểm tra và phân loại lỗi màn hình điện thoại. 6
1.3 Tiến trình xử lý dữ liệu và phát triển cấu trúc mô hình EAGNG trực tuyến. 10
1.4 Mối quan hệ giữa mục tiêu, nội dung nghiên cứu và kết quả dự kiến của luận văn. 11

2.1 Cấu trúc tensor dữ liệu bốn kênh kết hợp kênh màu và kênh entropy cục bộ. 14
2.2 Quy trình tính toán bản đồ entropy cục bộ thông qua cửa sổ trượt lân cận. 16
2.3 Quy trình xử lý dữ liệu qua lớp tích chập và lớp lấy mẫu giảm. . . . 18
2.4 Kiến trúc tổng thể của mạng Autoencoder nén và tái tạo ảnh màn hình. 19
2.5 Cấu trúc khối học dư cơ bản với đường truyền tắt bảo toàn thông tin. 23
2.6 Cơ chế chèn nút mới và phân tách kết nối trong Mạng Khí nơ-ron tăng trưởng. 28
2.7 Sơ đồ cơ chế tích lũy bằng chứng trong vùng đệm $\mathcal{B}$ và kích hoạt huấn luyện cục bộ. 31
2.8 Phân bố khoảng cách Gauss và ngưỡng phân định bất thường dựa trên quy tắc ba Sigma. 35
2.9 Phân cụm các thành phần liên thông độc lập đại diện cho các dạng khuyết tật bề mặt. 37
2.10 Cấu trúc phân loại các hướng tiếp cận lý thuyết trong bài toán học liên tục. 39

3.1 Sơ đồ kiến trúc tổng thể hai pha của hệ thống tự động phân loại khuyết tật màn hình điện thoại. 42
3.2 Mô phỏng không gian tiềm ẩn chuẩn với cấu trúc đồ thị Mạng khí Nơ-ron tăng trưởng ngoại tuyến và cơ chế xác định mẫu bất thường dựa trên khoảng cách ngưỡng $\mu + 3\sigma$. 50
3.3 Mô hình quy trình tổng hợp hình ảnh khuyết tật màn hình mô phỏng. 58

4.1 Năm dạng khuyết tật hình học bề mặt màn hình điện thoại trong tập dữ liệu thực nghiệm. 67
4.2 Ba cấp độ cường độ khuyết tật từ mạnh đến yếu đại diện cho dạng khuyết tật đường tròn. 68
4.3 Sự biến thiên của chỉ số điều chỉnh Rand theo thời gian khi xuất hiện các dạng lỗi mới. 69
4.4 Sự biến thiên của chỉ số thông tin tương hỗ chuẩn hóa theo chuỗi thời gian xử lý mẫu. 70
4.5 Chỉ số độ thuần khiết phân cụm của các thuật toán theo từng giai đoạn xuất hiện lỗi. 71
4.6 So sánh độ dịch chuyển trọng số nút cũ giữa các thuật toán theo chuỗi thời gian. 72
4.7 Phân tích khả năng thích ứng linh hoạt và độ ổn định tô-pô của mạng EAGNG. 72
4.8 Phân tích thời gian nhịp và tốc độ xử lý của EAGNG, SOINN và GNG. 73
4.9 Trực quan hóa cấu trúc mạng và phân cụm của thuật toán EAGNG tại bước 3000. 74
4.10 Trực quan hóa cấu trúc mạng của thuật toán GNG truyền thống tại bước 3000. 75
4.11 Trực quan hóa cấu trúc mạng của thuật toán SOINN tại bước 3000. . 76

Danh sách bảng

4.1 Thống kê thông số môi trường phần cứng và phần mềm thực nghiệm. 63
4.2 Tổng hợp giá trị cài đặt các tham số mô hình và thuật toán EAGNG trong thực nghiệm. 66
4.3 Thống kê chi tiết kịch bản phân bố dòng dữ liệu khuyết tật theo giai đoạn và cường độ. 68
4.4 Bảng tổng hợp chỉ số hiệu năng định lượng tại thời điểm mẫu thứ 3000. 77

Danh mục các từ viết tắt và thuật ngữ

STT	Từ viết tắt	Cụm từ đầy đủ	Cụm từ tiếng Việt
1	AI	Artificial Intelligence	Trí tuệ nhân tạo
2	ML	Machine Learning	Học máy
3	DL	Deep Learning	Học sâu
4	CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
5	AE	Autoencoder	Mạng mã hóa tự động
6	CAE	Convolutional Autoencoder	Mạng mã hóa tự động tích chập
7	GNG	Growing Neural Gas	Mạng khí nơ-ron tăng trưởng
8	EAGNG	Evidence Accumulation Growing Neural Gas	Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng
9	SOM	Self-Organizing Map	Bản đồ tự tổ chức
10	BMU	Best Matching Unit	Đơn vị khớp tốt nhất
11	ResNet	Residual Network	Mạng nơ-ron dư
12	AOI	Automated Optical Inspection	Kiểm tra quang học tự động
13	QC	Quality Control	Kiểm soát chất lượng
14	CL	Continual Learning	Học liên tục
15	MSE	Mean Squared Error	Sai số bình phương trung bình
16	ReLU	Rectified Linear Unit	Đơn vị tuyến tính chỉnh lưu
17	RGB	Red Green Blue	Hệ màu đỏ - lục - lam
18	RGB-E	Red Green Blue - Entropy	Không gian màu RGB kết hợp kênh Entropy

STT	Từ viết tắt	Cụm từ đầy đủ	Cụm từ tiếng Việt
19	SSIM	Structural Similarity Index Measure	Chỉ số độ tương đồng cấu trúc
20	ARI	Adjusted Rand Index	Chỉ số Rand điều chỉnh
21	NMI	Normalized Mutual Information	Thông tin tương hỗ chuẩn hóa
22	CPU	Central Processing Unit	Bộ xử lý trung tâm
23	GPU	Graphics Processing Unit	Bộ xử lý đồ họa
24	RAM	Random Access Memory	Bộ nhớ truy cập ngẫu nhiên
25	t-SNE	t-Distributed Stochastic Neighbor Embedding	Phân bố láng giềng ngẫu nhiên t
26	CUDA	Compute Unified Device Architecture	Kiến trúc thiết bị tính toán hợp nhất

Mở đầu

Trong kỷ nguyên công nghiệp 4.0, sự bùng nổ của thị trường thiết bị di động đã đặt ra những yêu cầu ngày càng khắt khe đối với quy trình kiểm soát chất lượng (Quality Control - QC) trong các dây chuyền sản xuất. Màn hình điện thoại, với vai trò là giao diện tương tác chính giữa người và máy, là thành phần đòi hỏi độ hoàn thiện cao nhất. Bất kỳ một khiếm khuyết nhỏ nào về hiển thị, từ các điểm chết (dead pixels) đến các đường kẻ sọc hay vết loang màu, đều ảnh hưởng trực tiếp đến trải nghiệm người dùng và uy tín của nhà sản xuất. Do đó, việc phát triển các hệ thống kiểm tra quang học tự động (AOI) với độ chính xác cao và tốc độ xử lý thời gian thực đang trở thành một nhu cầu cấp thiết nhằm thay thế hoàn toàn sự phụ thuộc vào mắt thường của con người.

Tuy nhiên, các giải pháp thị giác máy tính truyền thống và các mô hình học sâu có giám sát (Supervised Deep Learning) hiện nay đang đối mặt với những rào cản lớn khi triển khai thực tế. Các phương pháp này đòi hỏi một lượng dữ liệu khổng lồ được gán nhãn thủ công tỉ mỉ cho từng loại lỗi, điều này tốn kém cả về thời gian và chi phí nhân lực. Hơn nữa, trong môi trường sản xuất năng động, các dạng lỗi mới thường xuyên xuất hiện một cách bất ngờ và không thể dự báo trước. Các mô hình mạng nơ-ron tĩnh (static models) thường thất bại trong việc nhận diện các mẫu lỗi lạ này, hoặc nếu được huấn luyện lại trên dữ liệu mới, chúng lại mắc phải hiện tượng "quên thảm họa"(Catastrophic Forgetting) – tức là mất đi khả năng nhận diện các lỗi cũ đã học trước đó.

Để giải quyết những hạn chế nêu trên, hướng tiếp cận sử dụng Học máy không giám sát (Unsupervised Learning) kết hợp với Học liên tục (Continual Learning) đang nổi lên như một giải pháp đầy tiềm năng. Thay vì dựa vào nhãn dữ liệu có sẵn, hệ thống có thể tự học cách biểu diễn các đặc trưng của dữ liệu bình thường và phát hiện các bất thường dựa trên sự sai lệch phân bố. Đặc biệt, việc ứng dụng các thuật toán có khả năng thích nghi cấu trúc mạng (topology adaptation) cho phép mô hình linh hoạt mở rộng "vùng tri thức"của mình theo thời gian, tiếp nhận các loại lỗi mới mà không làm xáo trộn những tri thức nền tảng đã được thiết lập.

Luận văn này đề xuất một kiến trúc hệ thống lai ghép (hybrid architecture) tiên tiến nhằm kiểm tra lỗi màn hình tự động. Giải pháp kết hợp sức mạnh trích xuất

đặc trưng của mạng Autoencoder nén dữ liệu với khả năng phân cụm động của mạng Growing Neural Gas (GNG). Điểm mới của nghiên cứu nằm ở việc tích hợp kênh thông tin Entropy cục bộ (Local Entropy) vào quá trình tiền xử lý, giúp tăng cường khả năng phát hiện các lỗi có độ tương phản thấp. Đồng thời, cơ chế sinh trưởng nơ-ron và cạnh tranh của GNG được khai thác triệt để nhằm giải quyết bài toán học liên tục, đảm bảo hệ thống có thể nhận diện chính xác các lỗi hình học phức tạp như hình tròn, hình tam giác, hay hình chữ nhật qua từng giai đoạn sản xuất mà không cần huấn luyện lại từ đầu.

Mục tiêu chính của luận văn là xây dựng và kiểm chứng một quy trình kiểm tra lỗi hoàn chỉnh, từ khâu sinh dữ liệu giả lập, trích chọn đặc trưng đến phân loại thích nghi. Các đóng góp của đề tài không chỉ dừng lại ở việc cải thiện độ chính xác phát hiện lỗi mà còn cung cấp một minh chứng thực nghiệm rõ ràng cho khả năng khắc phục hiện tượng quên thảm họa trong các hệ thống trí tuệ nhân tạo công nghiệp. Kết quả nghiên cứu hứa hẹn mở ra hướng đi mới cho việc phát triển các hệ thống giám sát chất lượng thông minh, linh hoạt và tiết kiệm chi phí cho các nhà máy thông minh trong tương lai.

Về bố cục, nội dung của luận văn bao gồm 4 Chương như sau: Chương 1 đưa ra bài toán phát hiện các lỗi hiển thị bất thường trên màn hình điện thoại. Chương 2 nền tảng kiến thức cơ bản, các nghiên cứu liên quan đến học không giám sát thích ứng và học động. Chương 3 đưa ra phương pháp phát hiện bất thường bằng học không giám sát thích ứng để giải quyết bài toán. Chương 4 kết quả thực nghiệm bằng ứng dụng thực tế sinh dữ liệu và học liên tục với mạng GNG.Cuối cùng là Kết luận tổng kết lại kết quả mà luận văn đạt được và đề xuất hướng phát triển.

Chương 1

Bài toán kiểm tra màn hình điện thoại

1.1 Mô tả bài toán

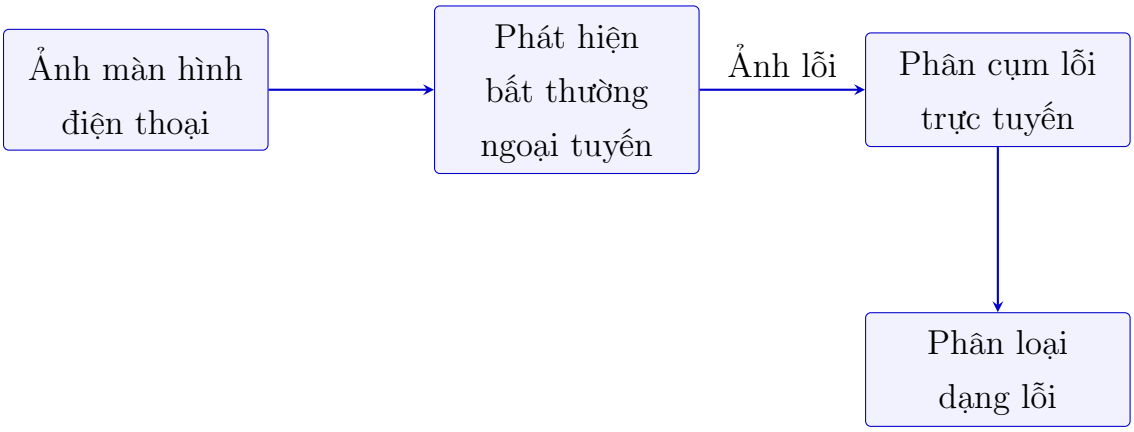
Kiểm tra và phân loại lỗi bề mặt màn hình điện thoại là công đoạn then chốt trong quy trình kiểm soát chất lượng sản phẩm tại các dây chuyền lắp ráp công nghiệp [1]. Cấu trúc phức hợp gồm nhiều lớp kính, tấm nền hiển thị và cảm ứng khiến các khuyết tật xuất hiện với đặc tính quang học đa dạng như vết trầy xước, hạt bụi, điểm chết pixel, vết nứt v.v... Hệ thống kiểm tra quang học tự động hỗ trợ phát hiện kịp thời các khuyết tật phát sinh, góp phần giảm chi phí nhân công và duy trì hiệu suất vận hành toàn hệ thống.

Các phương pháp kiểm tra lỗi truyền thống chủ yếu dựa trên kỹ thuật học máy có giám sát và các mạng nơ-ron tích chập [2–4]. Kỹ thuật học máy có giám sát đòi hỏi tập dữ liệu gán nhãn thủ công quy mô lớn đối với từng loại lỗi cố định. Trong thực tế sản xuất, các hình thái lỗi mới phát sinh liên tục do sự thay đổi của linh kiện đầu vào hoặc sự cố kỹ thuật của thiết bị. Do đó, các mô hình học giám sát có cấu trúc cố định thường gặp khó khăn trong việc nhận diện các dạng khuyết tật chưa từng xuất hiện trong tập dữ liệu huấn luyện.

Xu hướng ứng dụng các mô hình học không giám sát trong phát hiện bất thường giúp giảm sự phụ thuộc vào dữ liệu lỗi được gán nhãn thủ công [5, 6]. Các phương pháp này học tập các đặc trưng không gian từ tập sản phẩm đạt chuẩn để xác định ngưỡng sai biệt cho các mẫu khuyết tật. Tuy nhiên, phần lớn các tiếp cận không giám sát hiện hành chưa tích hợp cơ chế phân loại tự động và tổ chức dữ liệu cho các loại lỗi mới xuất hiện theo thời gian thực.

Nghiên cứu này tập trung giải quyết bài toán phát hiện bất thường và phân loại các dạng lỗi bề mặt màn hình điện thoại trong môi trường dòng dữ liệu động. Hệ thống đặt ra ba yêu cầu kỹ thuật bao gồm (i) phát hiện chính xác các vùng ảnh chứa lỗi dựa trên phân phối của mẫu sản phẩm chuẩn, (ii) tự động phân cụm các dạng lỗi mới phát sinh mà không làm gián đoạn tiến trình vận hành của hệ thống, và (iii) duy trì khả năng học liên tục để cập nhật tri thức mới. Dữ liệu hình ảnh

thu thập từ thực tế gặp hiện tượng mất cân bằng nghiêm trọng giữa số lượng mẫu đạt chuẩn và mẫu lỗi. Nghiên cứu đề xuất giải pháp tích hợp giữa kỹ thuật phát hiện bất thường ngoại tuyến và thuật toán học tăng cường trực tuyến nhằm phân loại các cụm lỗi theo thời gian thực.



Hình 1.1: Sơ đồ tổng quan quy trình kiểm tra và phân loại lỗi màn hình điện thoại.

Sơ đồ tổng quan quy trình kiểm tra và phân loại lỗi màn hình điện thoại được mô tả cụ thể trong Hình 1.1. Luồng xử lý bắt đầu từ việc tiếp nhận ảnh bề mặt màn hình điện thoại, sau đó dữ liệu được đưa qua khối phát hiện bất thường ngoại tuyến để lọc ra các mẫu sản phẩm đạt chuẩn và giữ lại các ảnh chứa vị trí lỗi. Các ảnh chứa lỗi tiếp tục được chuyển sang khối phân cụm lỗi trực tuyến nhằm tự động gom nhóm và xác định chủng loại khuyết tật mới.

Tiêu chuẩn đánh giá một mẫu ảnh thuộc nhóm bất thường được thiết lập dựa trên khoảng cách biểu diễn không gian ẩn so với ngưỡng phân phối mẫu chuẩn, được xác định thông qua Công thức 1.1:

$$d(z, \mathcal{W}) > 3\sigma \tag{1.1}$$

Trong Công thức 1.1, ký hiệu z biểu thị véc-tơ biểu diễn ẩn thu được từ không gian đặc trưng của mẫu ảnh đầu vào, ký hiệu $\mathcal{W}$ đại diện cho tập hợp các véc-tơ trọng số đại diện cho phân phối mẫu sản phẩm đạt chuẩn trong mô hình huấn luyện, ký hiệu $d(z, \mathcal{W})$ thể hiện khoảng cách Euclid nhỏ nhất từ véc-tơ ẩn z tới tập hợp trọng số $\mathcal{W}$, và ký hiệu σ đại diện cho độ lệch chuẩn của sai số tái tạo trên tập dữ liệu mẫu đạt chất lượng. Tất cả các mẫu ảnh có giá trị khoảng cách vượt quá ngưỡng phân phối này sẽ được xác định là bất thường và được chuyển sang khối phân cụm trực tuyến.

Giải pháp đề xuất sử dụng mạng Growing Neural Gas cải tiến kết hợp với cơ chế tích lũy bằng chứng nhằm tối ưu hóa tiến trình phân loại trực tuyến [7]. Phương pháp học động dựa trên mạng Growing Neural Gas có khả năng tự động thay đổi cấu trúc đồ thị và cập nhật tri thức mới mà không gặp phải hiện tượng quên tri thức cũ. Nghiên cứu kết hợp kỹ thuật tính toán bản đồ entropy và mô hình mã hóa Autoencoder trong pha phát hiện bất thường ngoại tuyến để trích xuất đặc trưng không gian và giảm chiều dữ liệu. Trong pha phân loại trực tuyến, thuật toán cải tiến Evidence-Accumulating Growing Neural Gas kiểm soát mật độ nút và tự động gộp các cụm lỗi gần nhau, giúp nâng cao độ chính xác phân loại trong hệ thống kiểm tra công nghiệp.

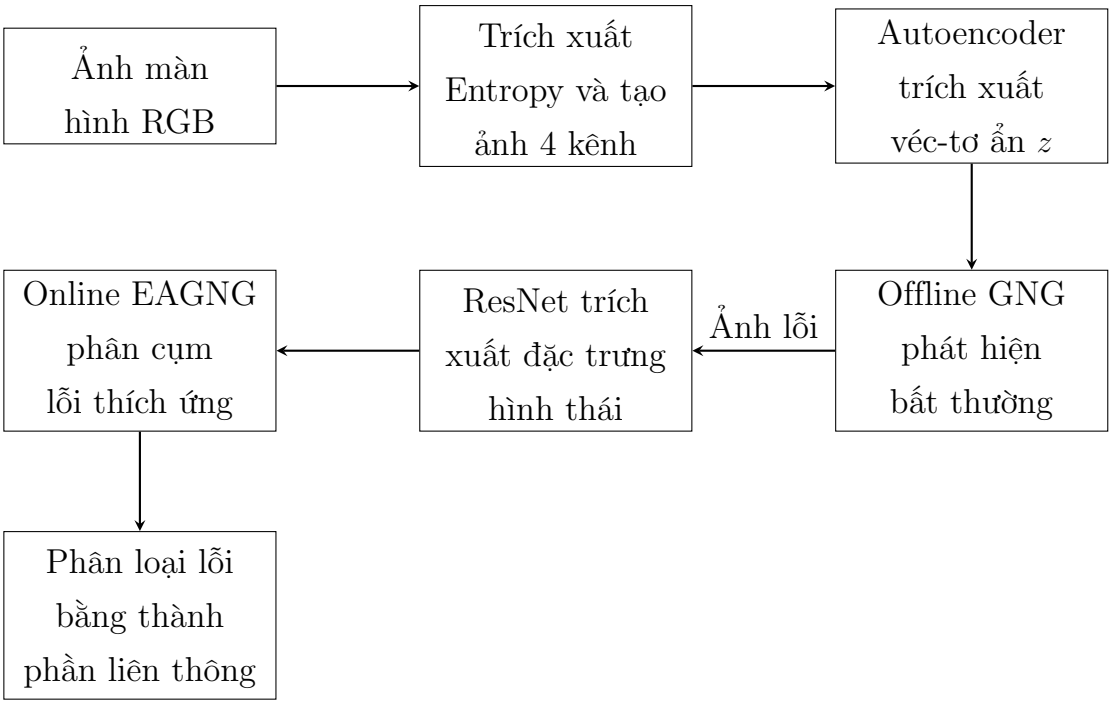
1.2 Ý tưởng và hướng tiếp cận của bài toán

Ý tưởng chủ đạo của luận văn dựa trên việc chia tách quá trình kiểm tra ngoại quan thành hai pha độc lập bao gồm pha phát hiện bất thường ngoại tuyến và pha phân cụm lỗi trực tuyến. Hướng tiếp cận này giải quyết hai thách thức lớn trong kiểm tra chất lượng màn hình điện thoại bao gồm sự mất cân bằng nghiêm trọng giữa số lượng mẫu đạt chuẩn và mẫu lỗi, cùng khả năng tự thích ứng với các dạng khuyết tật mới phát sinh trong dây chuyền sản xuất [8]. Trong pha thứ nhất, hệ thống tập trung xây dựng mô hình biểu diễn không gian cho các mẫu sản phẩm đạt chất lượng nhằm nhanh chóng sàng lọc và loại bỏ phần lớn dữ liệu bình thường. Trong pha thứ hai, hệ thống áp dụng cơ chế học động trực tuyến để tự động gom nhóm và phân loại các mẫu bị lỗi mà không cần gán nhãn trước [7].

Pha phát hiện bất thường ngoại tuyến kết hợp kỹ thuật trích xuất thông tin kết cấu không gian và mô hình học biểu diễn không giám sát. Dữ liệu ảnh đầu vào ban đầu gồm ba kênh màu chuẩn được bổ sung một kênh bản đồ entropy cục bộ [9]. Việc ghép nối kênh bản đồ này tạo thành cấu trúc ảnh bốn kênh nhằm tăng cường khả năng nhận diện các vùng có sự thay đổi đột ngột về độ sáng hoặc bề mặt. Tiếp theo, mô hình mạng mã hóa tự động thực hiện nén dữ liệu ảnh bốn kênh thành các véc-tơ biểu diễn ẩn mang thông tin cốt lõi của sản phẩm đạt chuẩn. Mô hình Mạng khí Nơ-ron tăng trưởng ngoại tuyến được huấn luyện trên tập các véc-tơ biểu diễn ẩn này để thiết lập bản đồ ma trận trọng số đại diện cho phân phối dữ liệu bình thường. Một mẫu ảnh được xác định là bất thường khi véc-tơ biểu diễn ẩn tương ứng có khoảng cách không gian vượt quá ngưỡng biến động quy định so

với các nút trọng số thuộc mô hình Mạng khí Nơ-ron Tăng trưởng.

Pha phân cụm lỗi trực tuyến xử lý các mẫu ảnh chứa khuyết tật đã được sàng lọc từ pha thứ nhất thông qua mạng khí nơ-ron tăng trưởng. Mô hình ResNet được sử dụng để trích xuất các véc-tơ đặc trưng tập trung vào hình thái khuyết tật từ cấu trúc ảnh bốn kênh [10]. Các véc-tơ đặc trưng này được truyền trực tiếp vào thuật toán Mạng khí Nơ-ron tăng trưởng Tích lũy Bằng chứng để cập nhật cấu trúc mạng theo thời gian thực. Thuật toán cải tiến tích hợp bốn cơ chế cốt lõi bao gồm (i) điều chỉnh tốc độ học và sai số tích lũy theo tuổi của nút, (ii) chèn nút muộn dựa trên vùng đệm bằng chứng và huấn luyện cục bộ, (iii) kiểm soát sự phát triển hình thái đồ thị dựa trên mật độ nút, và (iv) kiểm tra sự chồng lấp hộp giới hạn giữa các cụm để thực hiện gộp vết. Cuối cùng, thuật toán phân cụm thành phần liên thông trên đồ thị được áp dụng để xác định chính xác các nhóm lỗi riêng biệt mà không cần xác định trước số lượng cụm.



Hình 1.2: Sơ đồ kiến trúc hướng tiếp cận hai pha trong kiểm tra và phân loại lỗi màn hình điện thoại.

Sơ đồ kiến trúc xử lý chi tiết được mô tả cụ thể trong Hình 1.2. Luồng dữ liệu vận hành khép kín từ khâu tiếp nhận ảnh gốc ba kênh màu, tiến hành tính toán bản đồ độ hỗn loạn không gian để chuyển đổi thành cấu trúc bốn kênh, sau đó đưa qua mạng mã hóa tự động để trích xuất không gian ẩn. Khối Mạng khí Nơ-ron tăng

trưởng ngoại tuyến đóng vai trò bộ lọc phân phối để loại bỏ các mẫu sản phẩm đạt chất lượng. Các mẫu ảnh vượt ngưỡng phân phối được chuyển tiếp sang khối ResNet để trích xuất đặc trưng hình thái khuyết tật, làm đầu vào cho mô hình Mạng khí Nơ-ron tăng trưởng Tích lũy Bằng chứng trực tuyến thực hiện tích lũy và điều chỉnh cấu trúc đồ thị trước khi phân loại cụ thể.

Quá trình trích xuất kênh bản đồ độ hỗn loạn thông tin được thực hiện dựa trên việc đo lường mức độ biến động tần suất xuất hiện của các giá trị mức xám trong vùng lân cận cục bộ của từng điểm ảnh [9]. Chỉ số này phản ánh mức độ không đồng nhất về bề mặt, giúp làm nổi bật các đốm tròn mờ, điểm chết hoặc bọt khí trên tấm nền hiển thị mà các kênh màu thông thường khó phát hiện. Sau đó, mạng mã hóa tự động nén thông tin từ ảnh bốn kênh thành không gian ẩn dung lượng thấp thông qua quá trình tối thiểu hóa sai số tái tạo giữa ảnh đầu vào và ảnh đầu ra. Các véc-tơ ẩn thu được chứa đựng các đặc trưng hình học đại diện cho sản phẩm đạt chuẩn, phục vụ cho việc xây dựng ranh giới phân phối của dữ liệu bình thường.

Mô hình Mạng khí Nơ-ron tăng trưởng Tích lũy Bằng chứng quản lý quá trình cập nhật đồ thị thông qua cơ chế suy giảm tốc độ học theo độ tuổi của từng nút. Các nút mới được tạo ra có tốc độ học cao để nhanh chóng di chuyển về vị trí trung tâm của vùng dữ liệu mới phát sinh. Khi độ tuổi của nút tăng lên theo số bước thời gian, tốc độ học sẽ giảm dần theo hàm mũ nhằm giúp vị trí của nút đạt trạng thái cân bằng và duy trì độ ổn định cấu trúc. Kết hợp với việc tích lũy bằng chứng dữ liệu trong vùng đệm trước khi quyết định chèn nút, hướng tiếp cận này đảm bảo hệ thống phản ứng linh hoạt với các dạng lỗi mới mà không bị ảnh hưởng bởi nhiễu tín hiệu ngẫu nhiên v.v...

1.3 GNG trong kiểm tra màn hình điện thoại

1.3.1 Tổng quan về GNG

Thuật toán mạng khí nơ-ron tăng trưởng (Growing Neural Gas - GNG) đại diện cho mô hình học không giám sát có khả năng tự thích ứng cấu trúc đồ thị không gian dựa trên phân phối dữ liệu đầu vào [7]. Khác với các thuật toán phân cụm cố định số lượng trung tâm, mô hình khởi đầu với một số lượng nút tối thiểu và tự động bổ sung các nút mới trong tiến trình huấn luyện nhằm tối ưu hóa độ bao

phủ không gian đặc trưng. Cấu trúc mạng bao gồm tập hợp các nút mang vectơ trọng số và tập hợp các cạnh nối thiết lập mối quan hệ lân cận giữa các nút.

Nguyên lý vận hành của mạng dựa trên việc xác định hai nút có khoảng cách nhỏ nhất so với véc-tơ dữ liệu đầu vào trong không gian đặc trưng. Nút gần nhất được xác định là nút chiến thắng thứ nhất, trong khi nút gần thứ hai được xác định là nút chiến thắng thứ hai. Mô hình thực hiện điều chỉnh véc-tơ trọng số của nút chiến thắng thứ nhất cùng các nút lân cận kết nối trực tiếp về phía dữ liệu mới. Đồng thời, độ tuổi của cạnh nối giữa hai nút chiến thắng được khởi tạo lại về giá trị không, trong khi độ tuổi của các cạnh lân cận khác bị tăng lên một đơn vị. Các cạnh vượt quá ngưỡng tuổi quy định sẽ bị xóa khỏi hệ thống, dẫn đến việc loại bỏ các nút không còn kết nối.

Cơ chế tăng trưởng cấu trúc đồ thị được điều phối thông qua tiến trình tích lũy sai số tại các nút chiến thắng. Sau một số bước thời gian cố định, hệ thống xác định nút có tổng sai số tích lũy lớn nhất để tiến hành chèn nút mới vào khoảng giữa nút đó và nút lân cận có sai số cao nhất. Tiến trình này giúp mạng nâng cao độ phân giải biểu diễn tại các vùng không gian có mật độ dữ liệu phức tạp. Sai số của các nút liên quan sau đó được giảm theo một hệ số quy định để duy trì tính cân bằng cho toàn hệ thống.

1.3.2 Ứng dụng và các nhược điểm của GNG

Mô hình Mmạng khí nơ-ron tăng trưởng được áp dụng rộng rãi trong các bài toán phân nhóm không gian, nhận dạng mẫu và nén dữ liệu phi tuyến [7, 11]. Trong lĩnh vực xử lý ảnh và kiểm tra ngoại quan công nghiệp, thuật toán cung cấp giải pháp dựng bản đồ đặc trưng tự động mà không đòi hỏi giả định ban đầu về phân phối xác suất của dữ liệu. Khả năng tự do điều chỉnh số lượng nút giúp mô hình biểu diễn hiệu quả các không gian dữ liệu có hình thái phức tạp.

Mặc dù sở hữu khả năng thích ứng cấu trúc, mô hình truyền thống tồn tại bốn hạn chế kỹ thuật cốt lõi khi vận hành trong môi trường công nghiệp thực tế. Thứ nhất, thuật toán nhạy cảm với nhiễu dữ liệu dẫn đến việc chèn nút không cần thiết tại các vùng không gian có mật độ dữ liệu thưa thớt. Thứ hai, việc tích lũy sai số liên tục không tính đến thời gian tồn tại của nút gây ra sự bùng nổ số lượng nút tại vùng dữ liệu có mật độ cao, làm gia tăng chi phí tính toán của hệ thống.

Thứ ba, tốc độ học cố định làm giảm tính ổn định của mạng ở giai đoạn sau của quá trình huấn luyện trực tuyến, gây ra hiện tượng dao động trọng số xung quanh điểm cân bằng. Thứ tư, thuật toán thiếu cơ chế đánh giá sự chồng lấp hình học giữa các cụm độc lập, dẫn đến hiện tượng kết nối sai cạnh giữa các nhóm dữ liệu riêng biệt.

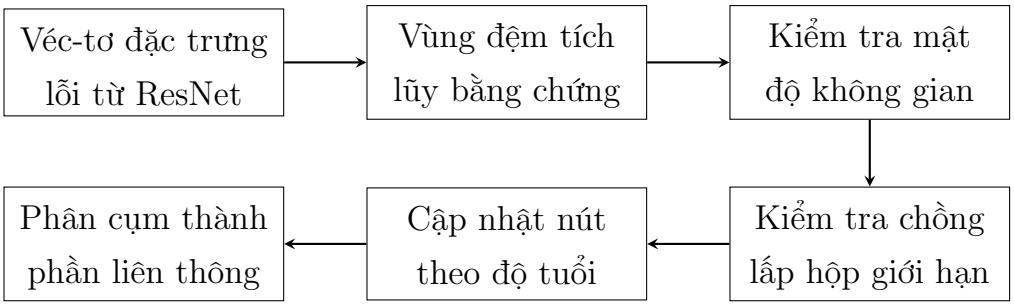
1.3.3 GNG đối với bài toán kiểm tra hình ảnh lỗi trên màn hình điện thoại

Đặc thụ của bài toán kiểm tra ngoại quan màn hình điện thoại đòi hỏi mô hình học không giám sát phải có khả năng xử lý dòng dữ liệu biến động liên tục và hạn chế ảnh hưởng của nhiễu tín hiệu quang học. Các dạng khuyết tật bề mặt như đốm tròn mờ, điểm chết hoặc bọt khí có kích thước và mật độ phân bố đa dạng trên tấm nền hiển thị. Khi áp dụng mô hình truyền thống vào bài toán này, sự xuất hiện của nhiễu ảnh công nghiệp khiến cấu trúc đồ thị bị biến dạng, gây ra tình trạng gom cụm sai lệch giữa các dạng lỗi khác nhau.

Để giải quyết các hạn chế nêu trên, luận văn định hướng ứng dụng thuật toán Mạng khí Nơ-ron Tăng trưởng Tích lũy Bằng chứng trong pha phân cụm lỗi trực tuyến. Phương pháp cải tiến tích hợp bốn cơ chế kỹ thuật bao gồm (i) điều chỉnh tốc độ học và hệ số giảm sai số theo độ tuổi của nút, (ii) chèn nút muộn dựa trên vùng đệm bằng chứng kết hợp huấn luyện cục bộ, (iii) kiểm soát sự phát triển hình thái dựa trên mật độ nút không gian, và (iv) kiểm tra sự chồng lấp hộp giới hạn giữa các cụm để gộp vết. Các cải tiến này giúp mô hình duy trì độ ổn định cấu trúc đồ thị và nâng cao độ chính xác phân loại khi xử lý dòng dữ liệu hình ảnh lỗi.

Tiến trình xử lý dữ liệu và phát triển cấu trúc mô hình cải tiến được mô tả cụ thể trong Hình 1.3. Khối tiếp nhận véc-tơ đặc trưng đưa dữ liệu đầu vào vào vùng đệm bằng chứng để tích lũy thông tin thống kê trước khi quyết định thay đổi cấu trúc đồ thị. Tiến trình kiểm tra mật độ không gian và kiểm tra chồng lấp hộp giới hạn đảm bảo các nút mới chỉ được tạo ra tại vùng dữ liệu có đủ mật độ, đồng thời ngăn chặn sự hợp nhất sai lệch giữa các cụm lỗi độc lập.

Sự kết hợp giữa cơ chế tích lũy bằng chứng và kiểm soát mật độ giúp giảm thiểu việc khởi tạo các nút dư thừa do nhiễu môi trường sản xuất. Đồng thời, việc gộp các vết lỗi dựa trên hộp giới hạn hình học cho phép hệ thống nhận diện chính xác



Hình 1.3: Tiến trình xử lý dữ liệu và phát triển cấu trúc mô hình EAGNG trực tuyến.

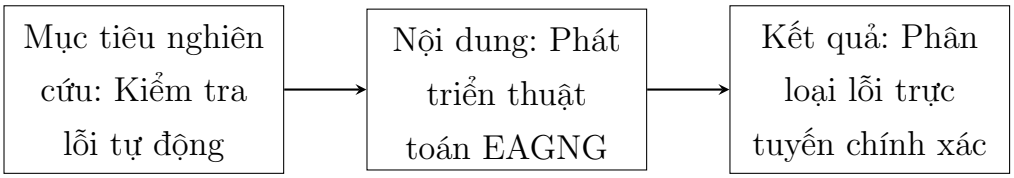
hình thái của từng chủng loại khuyết tật trên bề mặt màn hình điện thoại.

1.4 Động cơ nghiên cứu

Mục tiêu tổng quát của luận văn là nghiên cứu, thiết kế và phát triển phương pháp học động hai pha kết hợp giữa mô hình học biểu diễn không gian ngoại tuyến và thuật toán học trực tuyến thích ứng nhằm nâng cao độ chính xác và độ ổn định trong hệ thống kiểm tra chất lượng màn hình điện thoại. Luận văn hướng tới việc giải quyết triệt me hai thách thức lớn bao gồm sự mất cân bằng giữa số lượng mẫu đạt chuẩn và mẫu lỗi, cùng khả năng tự động phân loại các dạng khuyết tật mới phát sinh trên dây chuyền sản xuất. Để đạt được mục tiêu tổng quát, nghiên cứu xác định bốn mục tiêu cụ thể bao gồm (i) xây dựng cơ chế trích xuất đặc trưng đa kênh kết hợp bản đồ độ hỗn loạn không gian và mạng mã hóa tự động, (ii) thiết lập bộ lọc phát hiện bất thường ngoại tuyến dựa trên Mạng khí Nơ-ron Tăng trưởng, (iii) phát triển thuật toán Mạng khí Nơ-ron tăng trưởng Tích lũy Bằng chứng trực tuyến để phân cụm các dạng lỗi mới, và (iv) đánh giá hiệu năng hệ thống trên tập dữ liệu ảnh kiểm tra ngoại quan màn hình điện thoại thực tế v.v...

Nội dung nghiên cứu của luận văn tập trung giải quyết các bài toán kỹ thuật từ khâu xử lý dữ liệu đầu vào đến khâu tổ chức phân cụm trực tuyến. Nghiên cứu triển khai việc trích xuất thông tin độ hỗn loạn không gian để tạo lập cấu trúc ảnh bốn kênh, giúp làm nổi bật các đốm mờ và bọt khí bề mặt. Tiếp theo, luận văn nghiên cứu mô hình nén dữ liệu bằng mạng mã hóa tự động kết hợp thuật toán Mạng khí Nơ-ron tăng trưởng ngoại tuyến nhằm xác định ranh giới phân phối của sản phẩm đạt chất lượng. Đối với pha phân cụm lỗi trực tuyến, nội dung nghiên cứu tập trung đề xuất thuật toán Mạng khí Nơ-ron tăng trưởng Tích lũy Bằng

chứng với bốn cải tiến cốt lõi bao gồm cơ chế giảm tốc độ học theo độ tuổi của nút, chèn nút muộn dựa trên vùng đệm tích lũy bằng chứng, kiểm soát sự phát triển đồ thị dựa trên mật độ không gian và gộp vết dựa trên sự chồng lấp hộp giới hạn [7]. Cuối cùng, luận văn tiến hành thử nghiệm, so sánh đối chứng hiệu năng của phương pháp đề xuất với các thuật toán học không giám sát kinh điển [11].



Hình 1.4: Mối quan hệ giữa mục tiêu, nội dung nghiên cứu và kết quả dự kiến của luận văn.

Mối liên hệ logic giữa mục tiêu, nội dung nghiên cứu và kết quả dự kiến được thể hiện cụ thể trong Hình 1.4. Tiến trình nghiên cứu bắt đầu từ việc xác định mục tiêu kiểm tra lỗi tự động, từ đó triển khai nội dung phát triển thuật toán cải tiến nhằm đạt được kết quả phân loại lỗi trực tuyến chính xác trong môi trường sản xuất công nghiệp.

Kết quả dự kiến của luận văn đóng góp cả về mặt lý thuyết khoa học máy tính lẫn giá trị ứng dụng thực tiễn trong công nghiệp chế tạo. Về mặt lý thuyết, nghiên cứu hoàn thiện mô hình Mạng khí Nơ-ron tăng trưởng Tích lũy Bằng chứng với khả năng kiểm soát hiện tượng bùng nổ số lượng nút, ổn định vị trí trọng số và tự thích ứng với các dạng dữ liệu mới phát sinh theo thời gian [7]. Về mặt thực tiễn, luận văn cung cấp giải pháp phân loại lỗi ngoại quan tự động cho các dây chuyền lắp ráp màn hình điện thoại, giúp loại bỏ công đoạn gán nhãn thủ công tốn kém chi phí, giảm thiểu tỷ lệ bỏ sót khuyết tật và nâng cao năng suất vận hành toàn hệ thống v.v...

Kết luận Chương 1

Chương 1 đã trình bày tổng quan về bài toán kiểm tra chất lượng bề mặt màn hình điện thoại trong môi trường sản xuất công nghiệp. Bề mặt màn hình điện thoại có cấu trúc phức tạp với nhiều lớp vật liệu khác nhau, khiến các dạng khuyết tật ngoại quan xuất hiện với các hình thái đa dạng. Các phương pháp kiểm tra truyền thống phụ thuộc nhiều vào việc gán nhãn thủ công hoặc các mô hình học máy giám

sát cố định, gây ra khó khăn trong việc phát hiện và gom nhóm các dạng lỗi mới phát sinh. Nghiên cứu đã xác định việc kết hợp giữa phát hiện bất thường ngoại tuyến và phân cụm trực tuyến là hướng đi phù hợp để giải quyết vấn đề mất cân bằng dữ liệu và tự động phân loại khuyết tật.

Hệ thống đề xuất trong luận văn được xây dựng dựa trên kiến trúc hai pha nhằm tối ưu hóa tiến trình xử lý dòng dữ liệu ảnh. Pha phát hiện bất thường ngoại tuyến sử dụng bản đồ độ hỗn loạn thông tin không gian kết hợp với mô hình mã hóa tự động và thuật toán Mạng khí Nơ-ron tăng trưởng để nhanh chóng loại bỏ các sản phẩm đạt chất lượng. Pha phân cụm lỗi trực tuyến áp dụng thuật toán Mạng khí Nơ-ron tăng trưởng Tích lũy Bằng chứng cải tiến cùng mạng ResNet để tự động gom nhóm các dạng khuyết tật. Phương pháp đề xuất đã tích hợp bốn cơ chế kỹ thuật bao gồm (i) suy giảm tốc độ học theo độ tuổi của nút, (ii) chèn nút muộn dựa trên vùng đệm bằng chứng, (iii) kiểm soát sự phát triển hình thái dựa trên mật độ không gian, và (iv) gộp các vết lỗi dựa trên sự chồng lấp hộp giới hạn.

Các mục tiêu, nội dung nghiên cứu và kết quả dự kiến của luận văn đã được xác định rõ ràng nhằm đóng góp cả về mặt lý thuyết học máy lẫn tính ứng dụng thực tiễn trong công nghiệp. Luận văn hướng tới việc hoàn thiện mô hình học động trực tuyến có khả năng tự điều chỉnh cấu trúc đồ thị, nâng cao độ chính xác phân loại lỗi và giảm thiểu chi phí vận hành cho nhà máy sản xuất. Để làm cơ sở khoa học cho việc triển khai các phương pháp đề xuất trong các chương tiếp theo, Chương 2 sẽ trình bày chi tiết cơ sở lý thuyết nền tảng về mạng khí nơ-ron tăng trưởng, mô hình mã hóa tự động và lý thuyết Mạng khí Nơ-ron tăng trưởng truyền thống v.v...

Chương 2

Cơ sở lý thuyết

Chương này trình bày toàn bộ nền tảng lý thuyết cốt lõi làm cơ sở cho việc nghiên cứu và phát triển phương pháp học động trong hệ thống kiểm tra lỗi cho màn hình điện thoại. Các nội dung được hệ thống hóa từ lý thuyết xử lý ảnh số, biểu diễn entropy không gian, kiến trúc mạng nơ-ron tích chập tự mã hóa, mô hình học dư ResNet, các thuật toán phân cụm không giám sát họ Neural Gas, đến lý thuyết phát hiện bất thường dựa trên phân phối thống kê và bài toán học liên tục trong môi trường công nghiệp.

2.1 Tổng quan về Xử lý ảnh và Trích chọn đặc trưng

Xử lý ảnh và trích chọn đặc trưng đóng vai trò tiền đề trong hệ thống thị giác máy tính phục vụ kiểm tra chất lượng sản phẩm công nghiệp. Trong bài toán kiểm định màn hình điện thoại, dữ liệu hình ảnh thu nhận thường chứa đựng sự biến đổi phức tạp về độ sáng, kết cấu bề mặt và các dạng khuyết tật có kích thước siêu nhỏ. Việc xây dựng một không gian biểu diễn dữ liệu tối ưu giúp làm nổi bật các tín hiệu bất thường, tạo điều kiện thuận lợi cho các mô hình học máy ở giai đoạn sau thực hiện phân loại và phân cụm chính xác. Mục này tập trung hệ thống hóa các nguyên lý cơ bản về biểu diễn ảnh số, lý thuyết thông tin Shannon và phương pháp tính toán entropy cục bộ trong phân tích kết cấu bề mặt màn hình.

2.1.1 Biểu diễn ảnh số và Không gian mức xám

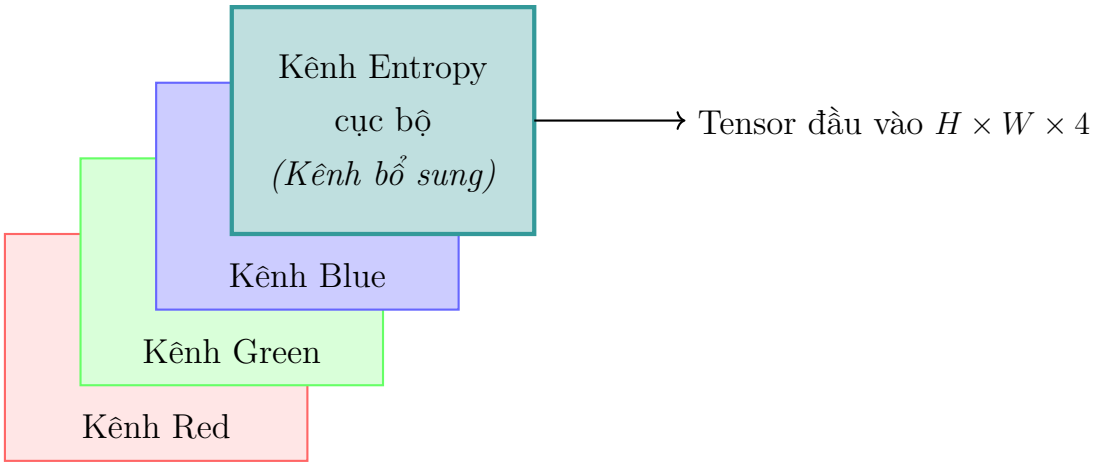
Biểu diễn ảnh số là quá trình rời rạc hóa tín hiệu quang học liên tục thành ma trận các giá trị số trong không gian hai chiều [12]. Trong không gian mức xám, mỗi điểm ảnh được đặc trưng bởi một giá trị cường độ sáng nằm trong khoảng xác định, thông thường là từ giá trị không đến hai trăm năm mươi lăm đối với định dạng tám bit. Cấu trúc ma trận ảnh I có kích thước chiều cao H và chiều rộng W được mô tả toán học thông qua Công thức 2.1:

$$I(x, y) \in [0, L-1], \quad \forall x \in \{1, 2, \ldots, H\}, \quad y \in \{1, 2, \ldots, W\} \tag{2.1}$$

Trong Công thức 2.1, ký hiệu $I(x, y)$ đại diện cho cường độ sáng của điểm ảnh tại tọa độ hàng x và cột y, H là số lượng hàng của ma trận ảnh, W là số lượng cột của ma trận ảnh, và L đại diện cho số lượng mức xám tối đa của hệ thống rời rạc hóa.

Đối với hệ thống kiểm tra màn hình điện thoại, việc chỉ sử dụng dữ liệu mức xám hoặc dữ liệu màu ba kênh truyền thống thường gặp hạn chế khi xuất hiện các lỗi có độ tương phản thấp. Các khuyết tật như đốm tròn mờ, hạt bụi nhỏ hoặc vùng phân bố độ sáng không đều thường hòa lẫn vào kết cấu nền của màn hình. Để giải quyết thách thức này, phương pháp đề xuất mở rộng cấu trúc biểu diễn dữ liệu bằng cách bổ sung một kênh thông tin thứ tư chứa đặc trưng entropy cục bộ, tạo thành một tensor dữ liệu bốn kênh với cấu trúc $I_{\text{ext}} \in \mathbb{R}^{H \times W \times 4}$. Việc kết hợp ba kênh màu cơ bản hoặc kênh mức xám cùng kênh entropy giúp hệ thống duy trì đầy đủ thông tin hình thái hình học đồng thời tăng cường độ nhạy đối với các biến đổi kết cấu bất thường.

Cấu trúc biểu diễn của tensor dữ liệu mở rộng được mô tả trực quan thông qua Hình 2.1.



Hình 2.1: Cấu trúc tensor dữ liệu bốn kênh kết hợp kênh màu và kênh entropy cục bộ.

Trong Hình 2.1, ba lớp đệm phía dưới thể hiện các kênh biểu diễn hình ảnh thông thường, trong khi lớp đệm phía trên được tô màu khác biệt đại diện cho kênh entropy cục bộ được trích xuất từ bề mặt màn hình. Sự tích hợp này đảm bảo toàn bộ thông tin không gian và thông tin thống kê biến động được truyền tải đồng thời vào các mạng nơ-ron phía sau.

2.1.2 Lý thuyết thông tin và Shannon Entropy

Lý thuyết thông tin do Claude Shannon đề xuất cung cấp khuôn khổ toán học định lượng độ hỗn loạn và lượng thông tin chứa đựng trong một nguồn phát ngẫu nhiên [9]. Trong lĩnh vực xử lý ảnh số, một bức ảnh hoặc một vùng ảnh có thể xem là một nguồn phát thông tin rời rạc, trong đó các giá trị mức xám của điểm ảnh đại diện cho các trạng thái có thể xảy ra của biến ngẫu nhiên. Công thức tính Shannon Entropy được xác định theo Công thức 2.2:

$$H(X) = -\sum_{i=1}^{N} P(x_i) \log_2 P(x_i) \tag{2.2}$$

Trong Công thức 2.2, ký hiệu $H(X)$ thể hiện giá trị entropy của biến ngẫu nhiên rời rạc X, x_i đại diện cho trạng thái thứ i trong tập hợp các trạng thái có thể xảy ra, $P(x_i)$ là xác suất xuất hiện của trạng thái x_i, và N thể hiện tổng số lượng trạng thái phân biệt của biến ngẫu nhiên X. Cơ số hai của phép toán lôgarit quy định đơn vị đo lượng thông tin tính bằng bit.

Khi áp dụng vào ảnh số, xác suất $P(r_k)$ của một mức xám r_k được ước lượng thông qua biểu đồ tần suất không gian của toàn bộ bức ảnh hoặc cửa sổ xét duyệt. Công thức xác định xác suất $P(r_k)$ được thể hiện trong Công thức 2.3:

$$P(r_k) = \frac{n_k}{M \cdot N_w} \tag{2.3}$$

Trong Công thức 2.3, ký hiệu n_k đại diện cho số lượng điểm ảnh có mức xám bằng r_k, M thể hiện chiều cao tính bằng điểm ảnh của vùng ảnh xét duyệt, và N_w đại diện cho chiều rộng tính bằng điểm ảnh của vùng ảnh xét duyệt. Tích số giữa M và N_w thể hiện tổng số điểm ảnh chứa trong vùng không gian đang phân tích.

Giá trị Shannon Entropy đạt giá trị cực đại khi tất cả các mức xám trong vùng xét duyệt có xác suất xuất hiện đồng đều, phản ánh một vùng bề mặt có mức độ hỗn loạn cao hoặc chứa cấu trúc dữ liệu phức tạp. Ngược lại, nếu vùng ảnh hoàn toàn đồng nhất về mức xám, xác suất của mức xám đó bằng một và xác suất các mức xám khác bằng không, dẫn đến giá trị entropy bằng không. Tính chất này tạo tiền đề quan trọng cho việc phân biệt giữa vùng màn hình hiển thị bình thường và các vùng bị lỗi bề mặt.

2.1.3 Entropy cục bộ trong phân tích kết cấu

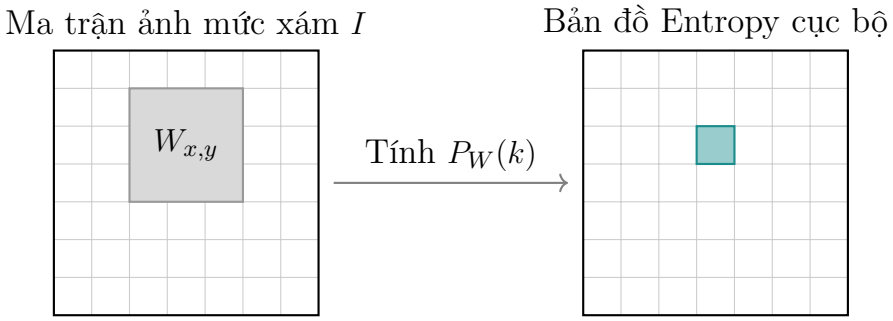
Mặc dù Shannon Entropy toàn cục cung cấp chỉ số đánh giá tổng quan về độ hỗn loạn của toàn bộ bức ảnh, chỉ số này không thể định vị được vị trí không gian của các biến đổi bất thường cục bộ [13]. Phân tích kết cấu dựa trên entropy cục bộ giải quyết hạn chế này bằng cách áp dụng kỹ thuật cửa sổ trượt quét qua từng điểm ảnh trên ma trận hình ảnh. Tại mỗi vị trí điểm ảnh (x, y), một vùng lân cận kích thước $w \times w$ được khởi tạo để tính toán giá trị phân bố xác suất xám nội vùng.

Công thức xác định entropy cục bộ tại tọa độ (x, y) được biểu diễn chi tiết qua Công thức 2.4:

$$H_{\text{local}}(x, y) = -\sum_{k=0}^{L-1} P_{W_{x,y}}(k) \log_2 \left(P_{W_{x,y}}(k) + \epsilon \right) \tag{2.4}$$

Trong Công thức 2.4, ký hiệu $H_{\text{local}}(x, y)$ đại diện cho giá trị entropy cục bộ được gán cho điểm ảnh trung tâm tại tọa độ (x, y), $W_{x,y}$ thể hiện ma trận cửa sổ trượt kích thước $w \times w$ nhận điểm ảnh (x, y) làm tâm, $P_{W_{x,y}}(k)$ là xác suất xuất hiện của mức xám k tính riêng trong phạm vi cửa sổ $W_{x,y}$, L đại diện cho tổng số mức xám của hình ảnh, và ϵ là một hằng số dương siêu nhỏ được thêm vào nhằm tránh lỗi toán học khi tính lôgarit của giá trị không.

Quy trình trượt cửa sổ và chuyển đổi giá trị mức xám thành bản đồ entropy cục bộ được minh họa rõ ràng trong Hình 2.2.



Hình 2.2: Quy trình tính toán bản đồ entropy cục bộ thông qua cửa sổ trượt lân cận.

Trong Hình 2.2, cửa sổ trượt $W_{x,y}$ di chuyển lần lượt qua từng vị trí trên ma trận ảnh gốc I. Giá trị entropy tính toán từ cửa sổ này được gán trực tiếp vào vị trí tương ứng trên bản đồ entropy cục bộ, tạo ra một ma trận hai chiều có cùng kích thước không gian với ảnh gốc.

Đối với bài toán kiểm tra lỗi màn hình điện thoại, sự hiện diện của các đốm tròn, vệt loang, nứt vỡ hoặc điểm chết màn hình sẽ làm đứt gãy tính đồng nhất của mô hình kết cấu xung quanh. Việc áp dụng tính toán entropy cục bộ mang lại ba ưu thế kĩ thuật quan trọng: (i) tăng cường độ nổi bật của các đường biên và các chi tiết bất thường bất kể mức xám tuyệt đối của vùng lỗi; (ii) giảm thiểu sự phụ thuộc vào điều kiện chiếu sáng không đều trên bề mặt hiển thị của sản phẩm; (iii) chuẩn hóa thông tin nhiễu nền, giúp các mạng nơ-ron tự động nén đặc trưng thu nhận được tín hiệu lỗi một cách tập trung.

Bản đồ entropy cục bộ thu được sau quá trình biến đổi này được kết hợp trực tiếp vào ma trận ảnh ban đầu để tạo thành kênh thông tin thứ tư. Kênh dữ liệu bổ sung này giữ vai trò là thành phần định hướng không gian, giúp mô hình Autoencoder trong Pha một nén dữ liệu chính xác và giúp mô hình ResNet trong Pha hai trích xuất các đặc trưng hình thái sắc nét hơn đối với các dạng lỗi bề mặt phức tạp.

2.2 Mạng Nơ-ron Tích chập và Autoencoder

Mạng nơ-ron tích chập và mô hình Autoencoder đóng vai trò nền tảng trong việc tự động hóa quá trình trích xuất đặc trưng và nén dữ liệu hình ảnh. Trong bài toán phát hiện bất thường trên bề mặt màn hình điện thoại ở Pha 1, việc xử lý trực tiếp tensor ảnh bốn kênh có chiều không gian lớn gây ra chi phí tính toán cao và nhiễu dữ liệu. Bằng cách kết hợp khả năng học đặc trưng không gian cục bộ của phép tích chập và khả năng biểu diễn nén của Autoencoder, hệ thống chuyển đổi dữ liệu ảnh đầu vào thành các vectơ biểu diễn ẩn có số chiều nhỏ hơn nhưng bảo toàn các thông tin cấu trúc cốt lõi.

2.2.1 Mạng Nơ-ron Tích chập

Mạng nơ-ron tích chập là một lớp mô hình học sâu được thiết kế chuyên biệt để xử lý dữ liệu cấu trúc lưới hai chiều như ảnh số [14]. Nguyên lý hoạt động cốt lõi của mạng dựa trên ba cơ chế toán học cơ bản bao gồm: (i) trường thụ cảm cục bộ giúp mạng tập trung vào các vùng điểm ảnh lân cận; (ii) chia sẻ trọng số giúp giảm số lượng tham số cần huấn luyện và tạo tính bất biến đối với phép dịch chuyển; (iii) lấy mẫu giảm nhằm thu gọn kích thước không gian của bản đồ đặc trưng.

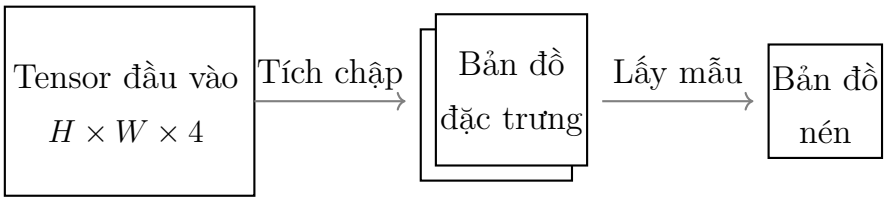
Phép toán tích chập hai chiều giữa ma trận ảnh đầu vào hoặc bản đồ đặc trưng

lớp trước với một hạt nhân tích chập được định nghĩa theo Công thức 2.5:

$$S(i,j) = (I * K)(i,j) = \sum_{m=-M}^{M} \sum_{n=-N}^{N} I(i-m, j-n)K(m,n) \tag{2.5}$$

Trong Công thức 2.5, ký hiệu $S(i,j)$ đại diện cho giá trị tại tọa độ (i,j) trên bản đồ đặc trưng đầu ra, I thể hiện ma trận dữ liệu đầu vào, K là ma trận hạt nhân tích chập kích thước $(2M+1) \times (2N+1)$, m và n lần lượt là chỉ số không gian của hạt nhân tích chập theo chiều cao và chiều rộng, toán tử $*$ thể hiện phép tích chập không gian hai chiều.

Sau phép tích chập, một hàm kích hoạt phi tuyến như hàm đơn vị tuyến tính sửa sai được áp dụng để tăng năng lực biểu diễn các mối quan hệ phức tạp. Tiếp theo, các lớp lấy mẫu giảm, phổ biến nhất là lấy mẫu cực đại, được sử dụng để trích xuất các đặc trưng nổi bật nhất trong từng vùng lân cận. Quy trình trích xuất đặc trưng cơ bản thông qua tích chập và lấy mẫu được mô tả trong Hình 2.3.



Hình 2.3: Quy trình xử lý dữ liệu qua lớp tích chập và lớp lấy mẫu giảm.

Trong Hình 2.3, dữ liệu đầu vào chứa bốn kênh thông tin được biến đổi qua các bộ lọc tích chập để tạo thành chuỗi bản đồ đặc trưng. Các bản đồ đặc trưng này tiếp tục trải qua quá trình lấy mẫu giảm nhằm thu nhỏ kích thước không gian nhưng vẫn giữ lại các tín hiệu hình thái quan trọng cho công đoạn mã hóa tiếp theo.

2.2.2 Kiến trúc Autoencoder

Mạng mã hóa tự động (Autoencoder) là một kiến trúc mạng nơ-ron học không giám sát được thiết kế nhằm học biểu diễn ẩn của dữ liệu bằng cách tái tạo lại chính dữ liệu đầu vào ở đầu ra [8]. Cấu trúc tổng thể của Autoencoder gồm hai phần chính: (i) bộ mã hóa thực hiện ánh xạ dữ liệu đầu vào không gian cao sang không gian ẩn có số chiều nhỏ hơn; (ii) bộ giải mã thực hiện ánh xạ từ không gian ẩn trở lại không gian ban đầu để khôi phục ảnh tái tạo.

Bộ mã hóa biến đổi tensor đầu vào $x \in \mathbb{R}^{H \times W \times 4}$ thành vectơ không gian ẩn $z \in \mathbb{R}^d$ thông qua chuỗi các lớp tích chập được mô tả toán học trong Công thức 2.6:

$$z = f_\theta(x) = \sigma(W_e x + b_e) \tag{2.6}$$

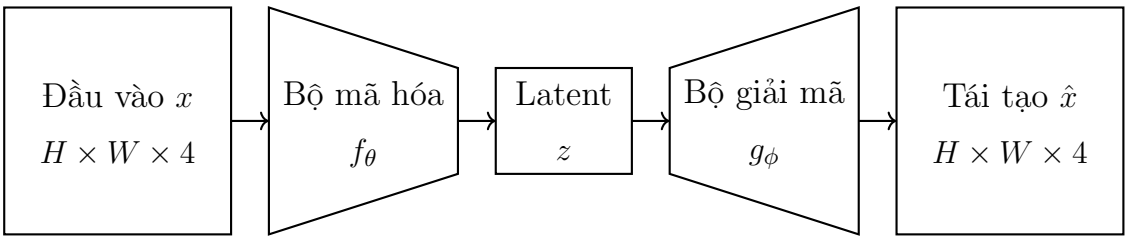
Trong Công thức 2.6, ký hiệu z đại diện cho vectơ không gian ẩn thu được, f_θ là hàm ánh xạ của bộ mã hóa phụ thuộc vào tập tham số θ, x là tensor ảnh đầu vào bốn kênh, W_e thể hiện ma trận trọng số của bộ mã hóa, b_e là vectơ độ lệch của bộ mã hóa, và σ đại diện cho hàm kích hoạt phi tuyến.

Bộ giải mã nhận vectơ không gian ẩn z và thực hiện quá trình tái tạo lại dữ liệu đầu vào thành $\hat{x} \in \mathbb{R}^{H \times W \times 4}$ thông qua các phép tích chập chuyển vị, được biểu diễn qua Công thức 2.7:

$$\hat{x} = g_\phi(z) = \sigma'(W_d z + b_d) \tag{2.7}$$

Trong Công thức 2.7, ký hiệu $\hat{x}$ đại diện cho tensor ảnh đầu ra tái tạo, g_ϕ là hàm ánh xạ của bộ giải mã phụ thuộc vào tập tham số ϕ, z là vectơ không gian ẩn, W_d thể hiện ma trận trọng số của bộ giải mã, b_d là vectơ độ lệch của bộ giải mã, và σ' đại diện cho hàm kích hoạt ở lớp xuất dữ liệu.

Sơ đồ tổng quan về kiến trúc mạng Autoencoder xử lý dòng dữ liệu ảnh bốn kênh được thể hiện trong Hình 2.4.



Hình 2.4: Kiến trúc tổng thể của mạng Autoencoder nén và tái tạo ảnh màn hình.

Trong Hình 2.4, hình thang thu nhỏ biểu thị quá trình nén dữ liệu của bộ mã hóa nhằm trích xuất vectơ đặc trưng z tại vùng nút thắt. Hình thang mở rộng tiếp theo đại diện cho quá trình khôi phục lại cấu trúc tensor ảnh ban đầu của bộ giải mã.

Trong quy trình thực nghiệm của Pha 1, mạng Autoencoder chỉ được huấn luyện ngoại tuyến trên tập dữ liệu ảnh màn hình bình thường. Nhờ đó, không gian ẩn

z học được cách biểu diễn hiệu quả các đặc trưng phân bố của sản phẩm đạt tiêu chuẩn chất lượng. Vectơ đặc trưng ẩn z thu được từ bộ mã hóa sau đó được trích xuất trực tiếp để làm dữ liệu đầu vào cho mô hình Growing Neural Gas ngoại tuyến, phục vụ bài toán phân định ngưỡng bất thường ở giai đoạn tiếp theo.

2.2.3 Hàm Mất mát Tái tạo

Hàm mất mát tái tạo đo lường mức độ sai lệch giữa dữ liệu ảnh gốc và dữ liệu ảnh thu được sau quá trình giải mã. Việc lựa chọn hàm mất mát phù hợp quyết định trực tiếp đến khả năng bảo toàn chi tiết cấu trúc nền và độ nhạy của mô hình đối với các đặc trưng cục bộ. Trong luận văn này, sai số bình phương trung bình được sử dụng làm hàm mục tiêu chính để tối ưu hóa tập tham số của mạng Autoencoder [15].

Công thức toán học của hàm mất mát sai số bình phương trung bình áp dụng cho dữ liệu tensor bốn kênh được biểu diễn qua Công thức 2.8:

$$\mathcal{L}_{\text{MSE}}(x, \hat{x}) = \frac{1}{C \cdot H \cdot W} \sum_{c=1}^{C} \sum_{i=1}^{H} \sum_{j=1}^{W} \left(x(c,i,j) - \hat{x}(c,i,j)\right)^2 \tag{2.8}$$

Trong Công thức 2.8, ký hiệu $\mathcal{L}_{\text{MSE}}(x, \hat{x})$ thể hiện tổn thất tái tạo tính theo trung bình bình phương sai số, C đại diện cho số lượng kênh dữ liệu đầu vào với giá trị cố định bằng bốn, H là chiều cao ảnh tính bằng điểm ảnh, W là chiều rộng ảnh tính bằng điểm ảnh, $x(c,i,j)$ là giá trị độ sáng hoặc giá trị entropy gốc tại kênh c, hàng i, cột j, và $\hat{x}(c,i,j)$ là giá trị tương ứng được tái tạo bởi bộ giải mã.

Quá trình huấn luyện mô hình Autoencoder thực hiện tối ưu hóa tập tham số θ và ϕ thông qua giải thuật lan truyền ngược nhằm giảm thiểu giá trị tổn thất theo Công thức 2.9:

$$(\theta^*, \phi^*) = \arg\min_{\theta,\phi} \mathcal{L}_{\text{MSE}}\left(x, g_\phi(f_\theta(x))\right) \tag{2.9}$$

Trong Công thức 2.9, ký hiệu θ^* và ϕ^* lần lượt là tập hợp các trọng số tối ưu của bộ mã hóa và bộ giải mã thu được sau quá trình huấn luyện, $\arg\min$ đại diện cho phép toán tìm tập tham số làm tối thiểu hóa giá trị của hàm mất mát tái tạo $\mathcal{L}_{\text{MSE}}$.

Đối với các mẫu ảnh không chứa khuyết tật, giá trị mất mát tái tạo $\mathcal{L}_{\text{MSE}}$ duy trì ở mức rất thấp do mô hình đã được tối ưu hóa trên phân bố dữ liệu này. Khi đưa một ảnh có chứa lỗi bề mặt vào mô hình, do mạng chưa từng được học các dạng cấu trúc lỗi bất thường, bộ giải mã sẽ không thể khôi phục chính xác các vùng khuyết tật đó. Sự gia tăng đột biến của sai số tái tạo tại các vùng bị lỗi chính là cơ sở quan trọng giúp gia tăng tính phân biệt của vectơ không gian ẩn z, hỗ trợ mô hình Growing Neural Gas thực hiện phát hiện bất thường chính xác hơn.

2.3 Mạng nơ-ron tích chập ResNet cho trích xuất đặc trưng hình thái

Trích xuất đặc trưng hình thái đóng vai trò quyết định đối với hiệu quả phân cụm các dạng khuyết tật bề mặt màn hình điện thoại trong Pha hai. Trong khi mô hình Autoencoder ở Pha một tập trung vào việc học phân phối ảnh bình thường để tái tạo dữ liệu, mô hình ở Pha hai cần trích xuất được các thông tin có tính phân biệt cao về hình học, hình thái và đường biên của vết lỗi. Kiến trúc mạng học dư ResNet được lựa chọn nhờ khả năng trích xuất đặc trưng sâu mà không gặp phải hiện tượng suy giảm tín hiệu gradient. Mục này phân tích cơ sở lý thuyết của học dư, phương pháp cải tiến lớp đầu vào cho luồng dữ liệu bốn kênh và vai trò của đặc trưng hình thái trong quy trình phân cụm trực tuyến của thuật toán EAGNG.

2.3.1 Cơ chế Học dư và Kiến trúc Residual Block

Khi tăng chiều sâu của các mạng nơ-ron tích chập truyền thống, mô hình thường gặp phải hiện tượng tiêu biến gradient hoặc bùng nổ gradient, dẫn đến độ chính xác huấn luyện bị suy giảm [10]. Kiến trúc ResNet giải quyết triệt để thách thức này bằng cách giới thiệu cơ chế kết nối tắt hay còn gọi là đường truyền đồng nhất. Thay vì buộc các lớp tích chập phải học trực tiếp một ánh xạ mục tiêu đầy đủ, cơ chế này cấu trúc lại mạng để các lớp nơ-ron chỉ cần học phần dư chênh lệch giữa đầu vào và đầu ra.

Giả sử ánh xạ gốc cần tối ưu hóa là $\mathcal{H}(x)$, kiến trúc học dư chuyển đổi bài toán thành việc tối ưu hóa hàm phần dư $\mathcal{F}(x) = \mathcal{H}(x) - x$. Khi đó, ánh xạ mục tiêu ban đầu được khôi phục theo Công thức 2.10:

$$y = \mathcal{F}(x, \{W_i\}) + x \tag{2.10}$$

Trong Công thức 2.10, ký hiệu y đại diện cho vectơ đầu ra của khối học dư, x thể hiện vectơ đầu vào của khối, W_i đại diện cho tập ma trận trọng số của các lớp tích chập trong khối, và $\mathcal{F}(x, \{W_i\})$ thể hiện ánh xạ phần dư cần học qua các lớp xử lý phi tuyến.

Khi kích thước của đầu vào x và đầu ra $\mathcal{F}$ trùng khớp nhau, phép cộng trực tiếp theo từng phần tử được thực hiện. Trong trường hợp kích thước không gian hoặc số lượng kênh thay đổi, một ma trận biến đổi tuyến tính W_s được bổ sung vào đường truyền tắt để chuẩn hóa kích thước, như được mô tả trong Công thức 2.11:

$$y = \mathcal{F}(x, \{W_i\}) + W_s x \tag{2.11}$$

In Công thức 2.11, ký hiệu W_s đại diện cho ma trận ma trận chiếu tuyến tính được áp dụng để điều chỉnh số lượng kênh hoặc kích thước không gian của vectơ đầu vào x sao cho đồng nhất với đầu ra của hàm phần dư.

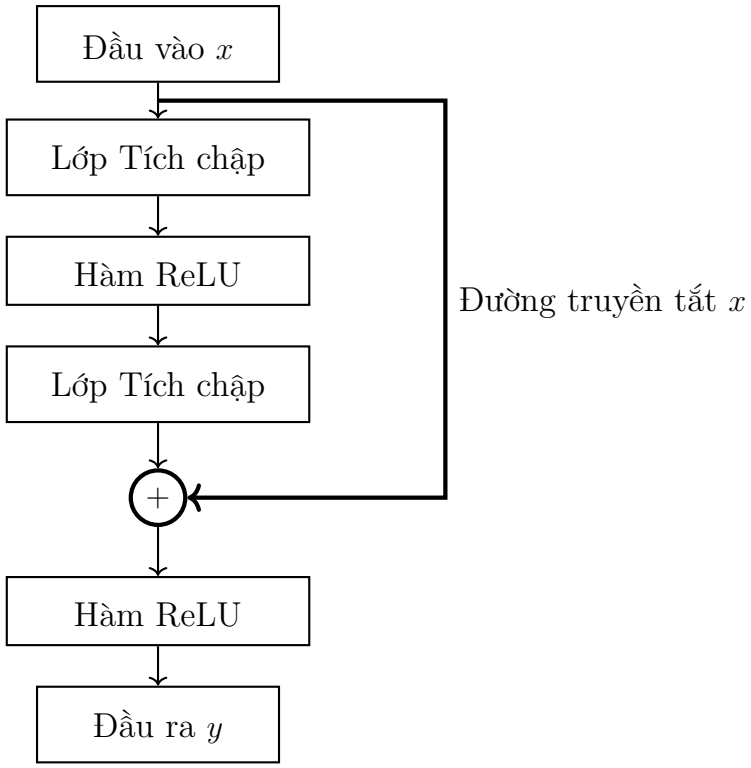
Cấu trúc hình học và luồng dữ liệu bên trong một khối học dư cơ bản được mô tả chi tiết trong Hình 2.5.

Trong Hình 2.5, dòng dữ liệu gốc x được chia làm hai nhánh. Nhánh chính trải qua các phép biến đổi tích chập phi tuyến để trích xuất tín hiệu biến đổi, trong khi nhánh đường truyền tắt bỏ qua các lớp biến đổi và cộng trực tiếp tín hiệu ban đầu vào đầu ra trước khi qua hàm kích hoạt cuối cùng.

2.3.2 Trích xuất đặc trưng hình thái cho luồng dữ liệu bốn kênh

Các mô hình ResNet tiền huấn luyện trên tập dữ liệu chuẩn thường được thiết kế để tiếp nhận đầu vào ảnh màu ba kênh. Trong hệ thống kiểm tra màn hình điện thoại, để khai thác tối đa thông tin từ kênh entropy cục bộ đã được ghép nối ở giai đoạn tiền xử lý, kiến trúc của lớp tích chập đầu tiên trong mạng ResNet cần được điều chỉnh cấu trúc trọng số [16].

Ma trận hạt nhân tích chập của lớp đầu tiên được mở rộng chiều không gian kênh từ ba lên bốn. Phép toán tích chập đối với tensor đầu vào bốn kênh $I_{\text{ext}} \in \mathbb{R}^{H \times W \times 4}$ tại bản đồ đặc trưng thứ m được xác định theo Công thức 2.12:



Hình 2.5: Cấu trúc khối học dư cơ bản với đường truyền tắt bảo toàn thông tin.

$$F_m(i,j) = \sum_{c=1}^{4} \left(I_{\text{ext},c} * K_{m,c}\right)(i,j) + b_m \tag{2.12}$$

Trong Công thức 2.12, ký hiệu $F_m(i,j)$ đại diện cho giá trị đặc trưng tại vị trí không gian (i,j) trên bản đồ đặc trưng thứ m, $I_{\text{ext},c}$ thể hiện kênh thứ c của tensor ảnh đầu vào bốn kênh, $K_{m,c}$ là hạt nhân tích chập tương ứng với kênh c của bộ lọc thứ m, toán tử $*$ thể hiện phép tích chập không gian hai chiều, và b_m đại diện cho giá trị độ lệch của bộ lọc thứ m.

Việc tích hợp đồng thời bốn kênh dữ liệu mang lại các lợi thế kỹ thuật trong quá trình học đặc trưng hình thái bao gồm: (i) ba kênh màu ban đầu cung cấp các thông tin về độ tương phản, mức xám và màu sắc tổng thể của vùng lỗi; (ii) kênh entropy cục bộ bổ sung các tín hiệu về sự đứt gãy kết cấu và biên giới không gian của vết khuyết tật; (iii) sự kết hợp qua các khối học dư cho phép mạng tự động tổng hợp các đặc trưng cấp cao biểu diễn chính xác hình thái hình học của các dạng lỗi phức tạp.

2.3.3 Vai trò của ResNet trong quy trình phân cụm trực tuyến EAGNG

Trong Pha hai của hệ thống, các hình ảnh chứa lỗi sau khi được phát hiện ở Pha một sẽ được chuyển sang công đoạn phân cụm trực tuyến. Mạng ResNet đóng vai trò là bộ trích xuất đặc trưng hình thái cố định, biến đổi mỗi ảnh khuyết tật thành một vectơ đặc trưng không gian $z_{\text{shape}} \in \mathbb{R}^d$. Nhờ khả năng biểu diễn hình học vượt trội của mạng tích chập sâu, các vết lỗi có cùng bản chất hình thái sẽ được ánh xạ thành các điểm dữ liệu nằm gần nhau trong không gian đặc trưng d chiều.

Vectơ đặc trưng z_{shape} sau đó được đưa trực tiếp vào mạng EAGNG để thực hiện học và phân cụm trực tuyến theo thời gian thực. Sự kết hợp này mang lại hai ý nghĩa quan trọng cho bài toán kiểm tra chất lượng sản phẩm: (i) làm giảm số chiều của dữ liệu đầu vào cho mạng EAGNG so với việc sử dụng trực tiếp điểm ảnh thô, giúp tối ưu hóa tốc độ tính toán khoảng cách không gian; (ii) loại bỏ các yếu tố nhiễu nền không quan trọng, tập trung vào các đặc trưng cấu trúc như tỷ lệ khung hình, độ dốc biên và diện tích phân bố của vết lỗi, tạo điều kiện thuận lợi cho thuật toán EAGNG xây dựng cấu trúc đồ thị phân cụm chính xác.

2.4 Mạng nơ-ron không giám sát và Growing Neural Gas

Học không giám sát đóng vai trò then chốt trong việc khám phá cấu trúc ẩn và phân cụm dữ liệu mà không cần nhãn tiên lượng. Trong bài toán phân tích khuyết tật màn hình điện thoại, các thuật toán học không giám sát dạng phân vùng dựa trên đồ thị cho phép biểu diễn phân phối dữ liệu phức tạp trong không gian đặc trưng nhiều chiều. Các mô hình dựa trên nguyên lý học cạnh tranh như Mạng tự tổ chức, Khí nơ-ron và Khí nơ-ron tăng trưởng phản ánh quá trình tự thích ứng của tập hợp nút đối với mật độ dữ liệu đầu vào. Mục này trình bày tiến trình phát triển lý thuyết từ các mô hình mạng không gian cố định đến mạng tăng trưởng linh hoạt, làm cơ sở khoa học cho việc đề xuất mô hình cải tiến ở các chương sau.

2.4.1 Mạng tự tổ chức Kohonen

Mạng tự tổ chức được Kohonen đề xuất nhằm ánh xạ không gian dữ liệu nhiều chiều về không gian lưới thấp chiều mà vẫn bảo toàn quan hệ lân cận giữa các mẫu dữ liệu [17]. Cấu trúc mạng bao gồm một lưới các nút nơ-ron được sắp xếp

cố định trên mặt phẳng hai chiều, trong đó mỗi nút i gắn liền với một vectơ trọng số $w_i \in \mathbb{R}^d$. Khi tiếp nhận một vectơ dữ liệu đầu vào $x \in \mathbb{R}^d$, mạng xác định nút chiến thắng $c(x)$ có khoảng cách Euclid nhỏ nhất tới x theo Công thức 2.13:

$$c(x) = \arg\min_i \|x - w_i\| \tag{2.13}$$

Trong Công thức 2.13, ký hiệu $c(x)$ đại diện cho chỉ số của nút chiến thắng, x thể hiện vectơ dữ liệu đầu vào trong không gian d chiều, w_i đại diện cho vectơ trọng số của nút nơ-ron thứ i, và $\|\cdot\|$ biểu diễn phép đo khoảng cách Euclid trong không gian thực.

Sau khi xác định nút chiến thắng, trọng số của nút chiến thắng và các nút trong vùng lân cận không gian lưới được cập nhật theo Công thức 2.14:

$$w_i(t+1) = w_i(t) + h_{ci}(t)\,[x(t) - w_i(t)] \tag{2.14}$$

Trong Công thức 2.14, ký hiệu $w_i(t)$ đại diện cho vectơ trọng số của nút thứ i tại bước thời gian t, $x(t)$ thể hiện mẫu dữ liệu đầu vào tại bước t, và $h_{ci}(t)$ đại diện cho hàm lân cận không gian giữa nút chiến thắng c và nút i. Hàm lân cận $h_{ci}(t)$ thường được xác định bởi hàm Gauss suy giảm theo thời gian và khoảng cách lưới giữa hai nút, được tính theo Công thức 2.15:

$$h_{ci}(t) = \alpha(t) \cdot \exp\left(-\frac{\|r_c - r_i\|^2}{2\sigma^2(t)}\right) \tag{2.15}$$

Trong Công thức 2.15, ký hiệu $\alpha(t)$ đại diện cho tốc độ học tại bước t, r_c và r_i lần lượt thể hiện tọa độ vị trí cố định của nút c và nút i trên lưới hai chiều, và $\sigma(t)$ đại diện cho bán kính vùng lân cận suy giảm theo thời gian.

Mô hình Mạng tự tổ chức sở hữu ưu thế về khả năng trực quan hóa dữ liệu cấu trúc cao về dạng lưới hai chiều dễ quan sát. Tuy nhiên, kiến trúc này bộc lộ những hạn chế kỹ thuật đáng kể khi áp dụng vào dữ liệu khuyết tật thực tế: (i) số lượng nút nơ-ron và cấu trúc lưới cố định buộc người dùng phải xác định trước, làm giảm tính dẻo khi phân phối dữ liệu thay đổi; (ii) sự ràng buộc không gian lưới cứng nhắc dễ dẫn đến tình trạng các nút bị kéo dãn vào các vùng không có dữ liệu; (iii) tốc độ học và bán kính lân cận suy giảm dần về không khiến mạng mất khả năng học các mẫu dữ liệu mới xuất hiện ở giai đoạn sau.

2.4.2 Mạng Khí nơ-ron

Mạng Khí nơ-ron do Martinetz và Schulten đề xuất nhằm loại bỏ sự ràng buộc của cấu trúc lưới không gian cố định trong Mạng tự tổ chức [18]. Thay vì dựa vào vị trí hình học trên lưới, Mạng Khí nơ-ron sắp xếp thứ tự các nút nơ-ron dựa trên khoảng cách không gian đặc trưng thực tế tới mẫu dữ liệu đầu vào. Đối với mỗi mẫu x, mạng tính toán khoảng cách tới toàn bộ các nút và gán chỉ số xếp hạng $k_i(x, W) \in \{0, 1, \ldots, N-1\}$, trong đó nút gần nhất có chỉ số bằng không.

Quy tắc cập nhật trọng số cho tất cả các nút nơ-ron trong Mạng Khí nơ-ron được thực hiện theo Công thức 2.16:

$$w_i(t+1) = w_i(t) + \epsilon(t) \cdot \exp\left(-\frac{k_i(x, W)}{\lambda(t)}\right)[x(t) - w_i(t)] \tag{2.16}$$

Trong Công thức 2.16, ký hiệu $w_i(t)$ đại diện cho vectơ trọng số của nút thứ i tại bước t, $x(t)$ là mẫu dữ liệu đầu vào, $k_i(x, W)$ thể hiện thứ tự xếp hạng khoảng cách của nút i so với mẫu x, $\epsilon(t)$ đại diện cho tốc độ học tại bước t, và $\lambda(t)$ thể hiện hằng số suy giảm phạm vi ảnh hưởng của thứ tự xếp hạng.

Mô hình Khí nơ-ron đạt được tốc độ hội tụ nhanh hơn và giảm thiểu sai số biểu diễn đáng kể so với Mạng tự tổ chức nhờ không bị giới hạn bởi lưới hai chiều cố định. Mặc dù vậy, thuật toán vẫn duy trì các điểm hạn chế cốt lõi bao gồm: (i) tổng số lượng nút nơ-ron N vẫn phải được thiết lập cố định từ trước; (ii) chi phí tính toán tăng nhanh do phải sắp xếp thứ tự khoảng cách cho toàn bộ các nút tại mỗi bước học; (iii) sự suy giảm theo thời gian của các tham số $\epsilon(t)$ và $\lambda(t)$ cản trở mạng thích ứng với luồng dữ liệu học liên tục.

2.4.3 Mạng Khí nơ-ron tăng trưởng

Mạng khí nơ-ron tăng trưởng do Fritzke đề xuất là bước phát triển quan trọng giúp giải quyết triệt để hạn chế về số lượng nút cố định của các mô hình tiền nhiệm [7]. Thuật toán bắt đầu với một tập hợp gồm hai nút ban đầu và tự động bổ sung nút mới hoặc xóa bỏ các kết nối không hiệu quả dựa trên việc tích lũy sai số cục bộ. Mạng duy trì một tập hợp các nút A và một tập hợp các cạnh nối C giữa các cặp nút để phản ánh cấu trúc đồng dạng hình học của dữ liệu.

Quy trình cập nhật của thuật toán Mạng Khí nơ-ron tăng trưởng khi tiếp nhận

một mẫu dữ liệu x được thực hiện theo chuỗi các bước toán học:

Đầu tiên, mạng xác định hai nút gần x nhất, ký hiệu là nút chiến thắng thứ nhất s_1 và nút chiến thắng thứ hai s_2, thỏa mãn điều kiện khoảng cách theo Công thức 2.17:

$$s_1 = \arg\min_{i \in A} \|x - w_i\|, \quad s_2 = \arg\min_{i \in A \setminus \{s_1\}} \|x - w_i\| \tag{2.17}$$

Trong Công thức 2.17, ký hiệu s_1 và s_2 lần lượt đại diện cho chỉ số của nút chiến thắng thứ nhất và thứ hai trong tập hợp nút A, x thể hiện mẫu dữ liệu đầu vào, và w_i đại diện cho vectơ trọng số của nút i.

Thứ hai, mạng tăng tuổi của tất cả các cạnh nối xuất phát từ s_1. Nếu giữa s_1 và s_2 chưa có cạnh nối, mạng tạo một cạnh mới nối hai nút này và đặt tuổi bằng không. Sai số tích lũy của nút chiến thắng s_1 được cập nhật theo Công thức 2.18:

$$E_{s_1} \leftarrow E_{s_1} + \|x - w_{s_1}\|^2 \tag{2.18}$$

Trong Công thức 2.18, ký hiệu E_{s_1} đại diện cho giá trị sai số tích lũy của nút s_1, x thể hiện mẫu dữ liệu đầu vào, và w_{s_1} đại diện cho vectơ trọng số của nút s_1.

Thứ ba, vị trí trọng số của nút chiến thắng s_1 và các nút lân cận n có kết nối trực tiếp với s_1 được điều chỉnh dịch chuyển về phía mẫu x theo Công thức 2.19 và Công thức 2.20:

$$w_{s_1} \leftarrow w_{s_1} + \epsilon_b(x - w_{s_1}) \tag{2.19}$$

$$w_n \leftarrow w_n + \epsilon_n(x - w_n), \quad \forall n \in N_{s_1} \tag{2.20}$$

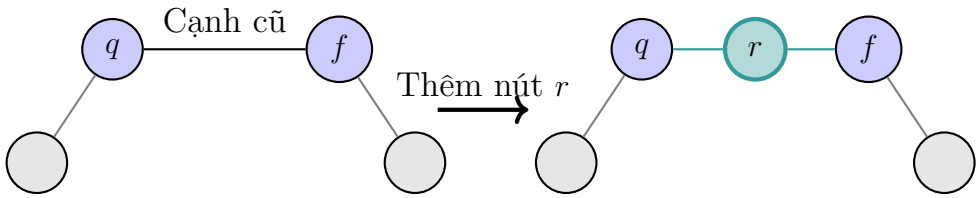
Trong Công thức 2.19 và Công thức 2.20, ký hiệu ϵ_b đại diện cho tốc độ học của nút chiến thắng, ϵ_n thể hiện tốc độ học của các nút lân cận, và N_{s_1} đại diện cho tập hợp các nút có cạnh nối trực tiếp với nút s_1.

Thứ tư, sau một chu kỳ cố định λ bước học, mạng phát hiện nút q có sai số tích lũy lớn nhất và nút f có sai số lớn nhất trong số các nút lân cận của q. Một nút mới r được chèn vào giữa q và f với trọng số được khởi tạo theo Công thức 2.21:

$$w_r = \frac{1}{2}(w_q + w_f) \tag{2.21}$$

Trong Công thức 2.21, ký hiệu w_r đại diện cho vectơ trọng số của nút mới bổ sung, w_q và w_f lần lượt thể hiện vectơ trọng số của hai nút có sai số lớn nhất. Sau khi chèn nút r, cạnh nối giữa q và f bị xóa bỏ, đồng thời hai cạnh mới nối r với q và r với f được tạo lập.

Quá trình thêm nút mới và tái cấu trúc liên kết đồ thị trong Mạng Khí nơ-ron tăng trưởng được mô tả trực quan trong Hình 2.6.



Cấu trúc mạng trước khi thêm nút Cấu trúc mạng sau khi chèn nút r

Hình 2.6: Cơ chế chèn nút mới và phân tách kết nối trong Mạng Khí nơ-ron tăng trưởng.

Trong Hình 2.6, nút q và nút f đại diện cho hai nút có sai số tích lũy lớn nhất. Khi thỏa mãn điều kiện chu kỳ λ, nút mới r được chèn vào trung điểm không gian giữa q và f, đồng thời kết nối cũ giữa q và f được thay thế bằng hai kết nối mới tới r.

Mặc dù Mạng Khí nơ-ron tăng trưởng sở hữu năng lực tự thích ứng cấu trúc đồ thị mạnh mẽ, mô hình này vẫn bộc lộ các điểm hạn chế nghiêm trọng khi triển khai trong hệ thống học trực tuyến kiểm tra vết lỗi màn hình: (i) tần suất thêm nút mới phụ thuộc hoàn toàn vào ngưỡng chu kỳ cố định λ mà không xét đến mật độ dữ liệu thực tế tại vùng không gian xét duyệt, dẫn đến nguy cơ bùng nổ số lượng nút tại các vùng dữ liệu dày đặc; (ii) mạng thiếu cơ chế phân biệt giữa dữ liệu nhiễu ngẫu nhiên và vết lỗi thực sự, khiến các mẫu nhiễu đứng đơn lẻ cũng tích lũy sai số và kích hoạt quá trình sinh nút không cần thiết; (iii) hiện tượng quên thảm họa xảy ra khi luồng dữ liệu lỗi xuất hiện theo chuỗi thời gian, do các nút cũ liên tục bị điều chỉnh trọng số về phía dữ liệu mới mà không có cơ chế đóng băng hoặc bảo tồn bằng vùng đệm bằng chứng; (iv) việc kết nối các nút chỉ dựa trên khoảng cách giữa hai nút chiến thắng s_1 và s_2 dễ gây ra hiện tượng nối nhầm cạnh giữa hai cụm khuyết tật nằm gần nhau về mặt không gian nhưng khác biệt về thuộc tính hình thái.

Những hạn chế nêu trên tạo nền tảng lý thuyết trực tiếp cho việc phát triển mô hình EAGNG trong luận văn này, nơi các cơ chế tích lũy bằng chứng, kiểm soát mật độ và kiểm tra chồng lấp hình học bao được tích hợp nhằm nâng cao tính ổn định và độ chính xác phân cụm.

2.5 Cơ sở toán học cho các cải tiến của thuật toán EAGNG

Mạng Khí nơ-ron tăng trưởng truyền thống bộc lộ những hạn chế kỹ thuật khi vận hành trong môi trường học trực tuyến, bao gồm hiện tượng bùng nổ số lượng nút tại các vùng dữ liệu có mật độ cao và nguy cơ hợp nhất sai các cụm khuyết tật do nhiễu không gian. Thuật toán EAGNG được phát triển nhằm khắc phục các tồn tại này thông qua bốn cải tiến cốt lõi dựa trên nền tảng toán học vững chắc. Mục này phân tích các nguyên lý toán học làm cơ sở cho việc điều khiển tốc độ học theo tuổi nút, cơ chế hoãn chèn nút dựa trên bằng chứng tích lũy, đánh giá mật độ không gian cục bộ và kiểm soát liên kết đồ thị bằng không gian bao hình học.

2.5.1 Lý thuyết suy giảm tốc độ học thích ứng theo vòng đời nút

Sự cân bằng giữa tính dẻo và tính ổn định là bài toán trung tâm trong các mô hình học liên tục và học trực tuyến [19]. Trong mạng Khí nơ-ron tăng trưởng gốc, tốc độ học và mức độ tích lũy sai số của các nút nơ-ron được duy trì cố định đối với nút chiến thắng bất chấp thời gian tồn tại của nút đó trong mạng. Điều này khiến cho các nút nơ-ron đã hội tụ vững chắc vẫn bị nhiễu loạn khi xuất hiện các mẫu dữ liệu ngoại lai đơn lẻ.

Thuật toán EAGNG bổ sung biến số tuổi nút $a_i \in \mathbb{N}$ cho mỗi nút i trong tập hợp nút A. Hàm suy giảm tốc độ học thích ứng theo thời gian sống của nút được định nghĩa theo Công thức 2.22:

$$\eta_i(a_i) = \frac{\eta_0}{1 + \alpha_a \cdot a_i} \tag{2.22}$$

Trong Công thức 2.22, ký hiệu $\eta_i(a_i)$ đại diện cho tốc độ học thích ứng của nút i tại độ tuổi a_i, η_0 thể hiện tốc độ học khởi tạo ban đầu, và α_a là hệ số suy giảm theo tuổi nút nhận giá trị dương.

Tương tự, mức độ tích lũy sai số E_i khi tiếp nhận mẫu dữ liệu mới x được điều chỉnh suy giảm theo độ trưởng thành của nút, được thể hiện trong Công thức 2.23:

$$\Delta E_i = \frac{\|x - w_i\|^2}{1 + \beta_a \cdot a_i} \tag{2.23}$$

Trong Công thức 2.23, ký hiệu ΔE_i đại diện cho giá trị gia tăng sai số tích lũy của nút i, x thể hiện vectơ đặc trưng đầu vào, w_i đại diện cho vectơ trọng số của nút i, $\|\cdot\|$ là phép đo khoảng cách Euclid, và β_a là hệ số kiểm soát mức độ suy giảm tích lũy sai số.

Quy luật suy giảm thích ứng này mang lại hai hiệu ứng toán học quan trọng: (i) các nút nơ-ron mới khởi tạo có độ tuổi nhỏ sẽ sở hữu tốc độ học cao, cho phép nhanh chóng di chuyển về trung tâm của vùng dữ liệu khuyết tật mới xuất hiện; (ii) các nút nơ-ron đã tồn tại qua nhiều bước học sẽ có độ tuổi lớn, dẫn đến tốc độ học và mức gia tăng sai số giảm dần, giúp bảo vệ cấu trúc tri thức đã học khỏi hiện tượng nhiễu loạn ngẫu nhiên.

2.5.2 Cơ chế đệm bộ nhớ và Ước lượng mật độ không gian cục bộ

Việc chèn nút mới ngay lập tức khi xuất hiện một mẫu dữ liệu nằm xa các nút hiện có khiến mạng Khí nơ-ron tăng trưởng rất nhạy cảm với nhiễu ngẫu nhiên [20]. Thuật toán EAGNG giải quyết thách thức này bằng cách kết hợp vùng đệm bộ nhớ tích lũy bằng chứng cùng phương pháp ước lượng mật độ nhân không gian.

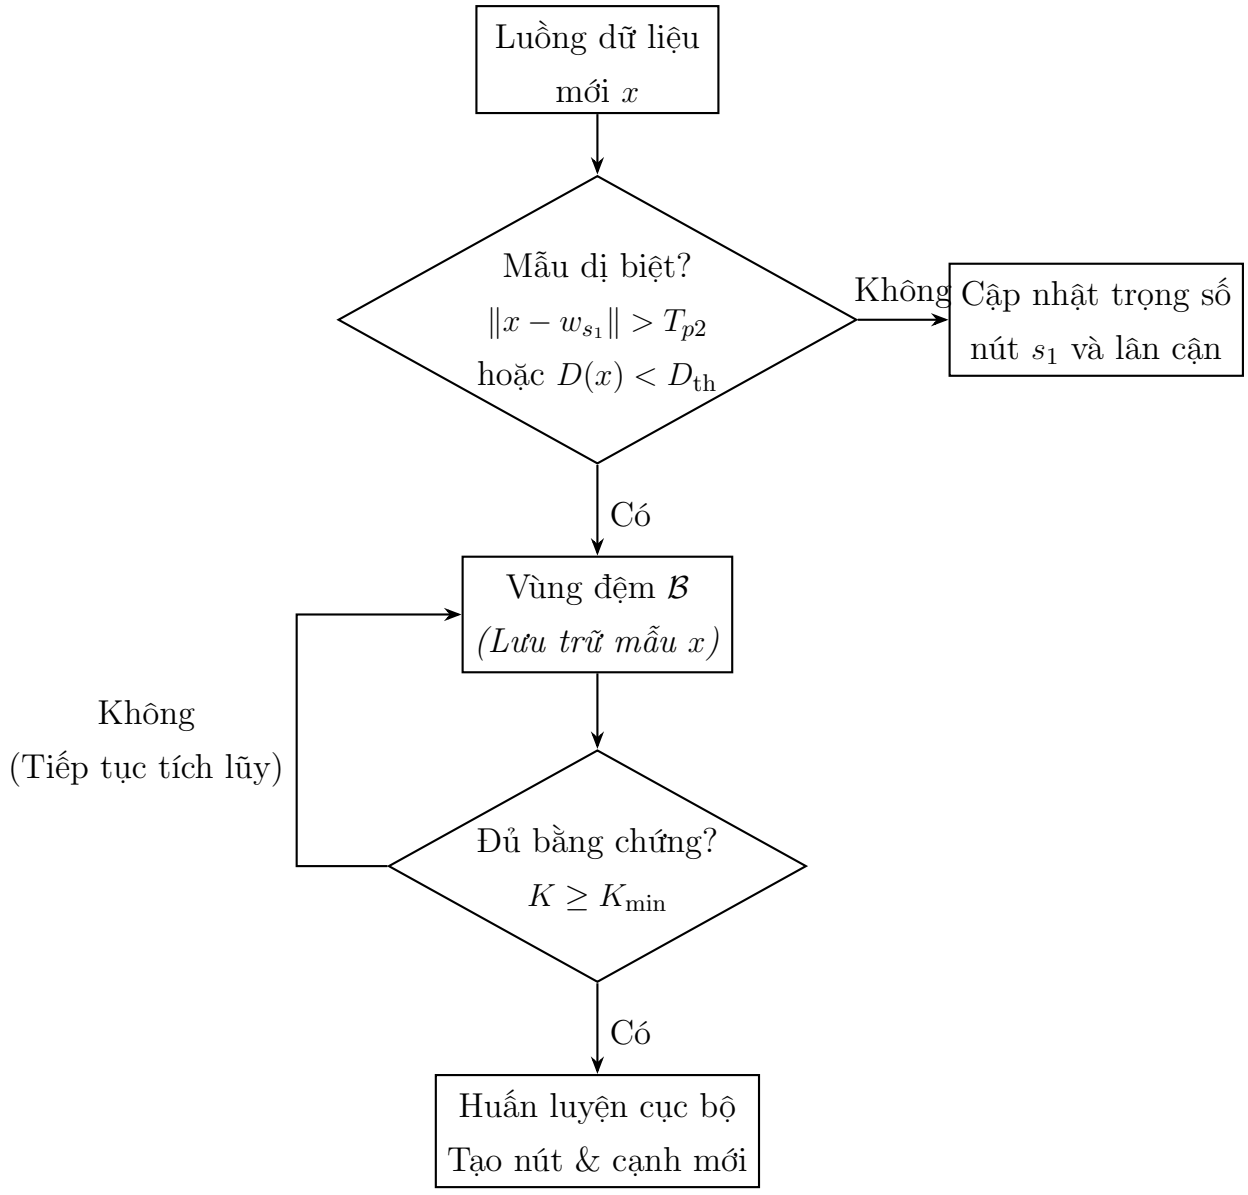
Khi một mẫu dữ liệu đầu vào x có khoảng cách tới nút chiến thắng vượt quá ngưỡng bất thường nhưng chưa đủ điều kiện tạo cấu trúc liên kết ngay, mẫu dữ liệu này được đưa vào vùng đệm bộ nhớ tạm thời $\mathcal{B} = \{x_1, x_2, \ldots, x_K\}$. Mật độ dữ liệu cục bộ $D(x)$ tại điểm x trong vùng đệm được ước lượng thông qua hàm nhân Gauss theo Công thức 2.24:

$$D(x) = \frac{1}{K \cdot h^d} \sum_{j=1}^{K} \exp\left(-\frac{\|x - x_j\|^2}{2h^2}\right) \tag{2.24}$$

Trong Công thức 2.24, ký hiệu $D(x)$ đại diện cho giá trị ước lượng mật độ không gian cục bộ tại vị trí x, K thể hiện số lượng mẫu dữ liệu hiện có trong vùng đệm bộ nhớ, h là bán kính cửa sổ nhân Gauss, d đại diện cho số chiều của không gian

đặc trưng, và x_j thể hiện mẫu dữ liệu thứ j trong vùng đệm.

Sơ đồ cơ chế hoãn chèn nút dựa trên vùng đệm bằng chứng và huấn luyện cục bộ được minh họa chi tiết trong Hình 2.7.



Hình 2.7: Sơ đồ cơ chế tích lũy bằng chứng trong vùng đệm $\mathcal{B}$ và kích hoạt huấn luyện cục bộ.

Trong Hình 2.7, các mẫu dữ liệu mới chưa đạt ngưỡng mật độ D_{th} sẽ không tạo nút ngay mà được chuyển vào vùng đệm bộ nhớ $\mathcal{B}$. Quá trình huấn luyện cục bộ để sinh cấu trúc nút và cạnh nối mới chỉ được kích hoạt khi số lượng bằng chứng tích lũy K đạt vượt ngưỡng tối thiểu $K_{\min}$.

Bên cạnh đó, để tránh hiện tượng bùng nổ số lượng nút tại các vùng đã có mật độ

biểu diễn cao, thuật toán EAGNG bổ sung chỉ số kiểm tra mật độ mạng cục bộ ρ_i tại nút i theo Công thức 2.25:

$$\rho_i = \frac{1}{|N_i|} \sum_{j \in N_i} \frac{1}{\|w_i - w_j\| + \epsilon} \tag{2.25}$$

Trong Công thức 2.25, ký hiệu ρ_i đại diện cho mật độ không gian cục bộ xung quanh nút i, N_i thể hiện tập hợp các nút lân cận có kết nối trực tiếp với nút i, $|N_i|$ là số lượng nút lân cận, w_i và w_j lần lượt là vectơ trọng số của nút i và nút j, và ϵ là hằng số dương siêu nhỏ để tránh lỗi chia cho giá trị không.

Khi nút q có sai số tích lũy lớn nhất đạt điều kiện phân tách, hệ thống kiểm tra chỉ số ρ_q. Việc chèn nút mới chỉ diễn ra khi giá trị ρ_q nhỏ hơn ngưỡng mật độ tối đa $\rho_{\max}$, đảm bảo mạng duy trì mật độ nút phân bố đồng đều và tối ưu tài nguyên tính toán.

2.5.3 Lý thuyết hình học bao không gian trong kiểm soát liên kết đồ thị

Trong quá trình học trực tuyến, các vết khuyết tật khác nhau có thể xuất hiện gần nhau trong không gian đặc trưng. Mô hình Khí nơ-ron tăng trưởng truyền thống chỉ dựa vào khoảng cách giữa hai nút chiến thắng s_1 và s_2 để tạo cạnh nối, dẫn đến rủi ro nối nhầm các cụm khuyết tật riêng biệt thành một phân lớp duy nhất [21].

Thuật toán EAGNG tích hợp cơ chế kiểm soát liên kết dựa trên lý thuyết không gian bao hình học chữ nhật song song với các trục tọa độ. Đối với mỗi cụm nơ-ron C_m trong đồ thị, hình học bao không gian $B(C_m)$ được xác định bởi tập hợp các khoảng giá trị cực trị trên từng chiều không gian theo Công thức 2.26:

$$B(C_m) = \prod_{d=1}^{D} \left[\min_{i \in C_m} w_{i,d}, \max_{i \in C_m} w_{i,d} \right] \tag{2.26}$$

Trong Công thức 2.26, ký hiệu $B(C_m)$ đại diện cho hình học bao không gian của cụm thứ m, D là tổng số chiều của không gian đặc trưng, $w_{i,d}$ thể hiện giá trị tọa độ chiều thứ d của nút i thuộc cụm C_m, và toán tử $\prod$ biểu thị tích Cartesian của các khoảng giá trị không gian.

Khi xuất hiện yêu cầu tạo cạnh nối giữa nút $u \in C_m$ và nút $v \in C_n$ thuộc hai cụm phân biệt, thuật toán tiến hành tính toán thể tích vùng giao cắt V_{overlap} giữa hai hình học bao $B(C_m)$ và $B(C_n)$ theo Công thức 2.27:

$$V_{\text{overlap}}(C_m, C_n) = \prod_{d=1}^{D} \max\left(0,\, \min\left(w_{m,d}^{\max}, w_{n,d}^{\max}\right) - \max\left(w_{m,d}^{\min}, w_{n,d}^{\min}\right)\right) \tag{2.27}$$

Trong Công thức 2.27, ký hiệu $V_{\text{overlap}}(C_m, C_n)$ đại diện cho thể tích phần không gian chồng lấp giữa hai hình học bao, $w_{m,d}^{\max}$ và $w_{m,d}^{\min}$ lần lượt là giá trị tọa độ lớn nhất và nhỏ nhất theo chiều d của cụm C_m.

Tỷ lệ giao cắt không gian R_{overlap} so với thể tích nhỏ hơn giữa hai không gian bao được xác định theo Công thức 2.28:

$$R_{\text{overlap}} = \frac{V_{\text{overlap}}(C_m, C_n)}{\min\left(V(B(C_m)),\, V(B(C_n))\right)} \tag{2.28}$$

Trong Công thức 2.28, ký hiệu R_{overlap} đại diện cho tỷ lệ chồng lấp không gian giữa hai cụm, và $V(B(C_m))$ thể hiện tổng thể tích không gian bao của cụm C_m.

Quy tắc quyết định liên kết đồ thị được quy định cụ thể: nếu tỷ lệ giao cắt R_{overlap} vượt quá ngưỡng cho phép τ_{overlap}, hai cụm được xác nhận là thuộc cùng một vùng khuyết tật mở rộng và việc tạo cạnh nối được phê duyệt; ngược lại, nếu tỷ lệ R_{overlap} nhỏ hơn ngưỡng, phép tạo cạnh nối bị từ chối nhằm duy trì sự ranh giới độc lập giữa hai dạng lỗi bề mặt. Cơ chế này đảm bảo mạng EAGNG phân cụm chính xác hình thái các vết khuyết tật phức tạp mà không bị sáp nhập sai lệch.

2.6 Phát hiện bất thường và phân cụm dựa trên lý thuyết đồ thị

Hệ thống kiểm tra chất lượng màn hình điện thoại đòi hỏi sự phối hợp chặt chẽ giữa khả năng sàng lọc mẫu bất thường ở Pha một và phân loại khuyết tật ở Pha hai. Việc kết hợp nguyên lý phân phối thống kê cùng lý thuyết đồ thị tạo nên khuôn khổ toán học hoàn chỉnh cho phép phát hiện các khuyết tật vượt khỏi phân phối của ảnh bình thường, đồng thời gom nhóm tự động các dạng lỗi bề mặt có đặc trưng tương đồng. Mục này trình bày nguyên lý phát hiện bất thường dựa trên quy tắc ba Sigma và phương pháp phân cụm đồ thị bằng thành phần liên thông.

2.6.1 Nguyên lý phát hiện bất thường dựa trên phân phối thống kê và khoảng cách 3-Sigma

Phát hiện bất thường dựa trên phân phối thống kê dựa trên giả định rằng các mẫu dữ liệu bình thường tập trung trong một miền không gian ẩn xác định và tuân theo phân phối chuẩn. Trong Pha một của quy trình đề xuất, mạng Autoencoder thực hiện nén các tensor ảnh bốn kênh bình thường thành các vectơ không gian ẩn $z \in \mathbb{R}^d$, sau đó mạng Khí nơ-ron tăng trưởng ngoại tuyến học cấu trúc phân phối của tập hợp các vectơ này. Mỗi mẫu ảnh thử nghiệm x_{test} khi đi qua bộ mã hóa sẽ thu được vectơ ẩn z_{test}, và khoảng cách đại diện cho sai số tái tổ chức tới nút nơ-ron chiến thắng w_c trong mạng Khí nơ-ron tăng trưởng được xác định theo Công thức 2.29:

$$d(z_{\text{test}}, w_c) = \|z_{\text{test}} - w_c\| = \sqrt{\sum_{k=1}^{d} \left(z_{\text{test},k} - w_{c,k}\right)^2} \tag{2.29}$$

Trong Công thức 2.29, ký hiệu $d(z_{\text{test}}, w_c)$ đại diện cho khoảng cách Euclid từ vectơ không gian ẩn thử nghiệm z_{test} tới vectơ trọng số của nút chiến thắng w_c, d là số chiều của không gian ẩn, $z_{\text{test},k}$ là thành phần thứ k của vectơ ẩn thử nghiệm, và $w_{c,k}$ đại diện cho thành phần thứ k của nút chiến thắng w_c.

Giá trị trung bình và độ lệch chuẩn của khoảng cách được tính toán trên toàn bộ tập dữ liệu huấn luyện ảnh bình thường để thiết lập ngưỡng phân định bất thường khoa học [22]. Kỳ vọng toán học và độ lệch chuẩn của khoảng cách không gian ẩn được định nghĩa lần lượt trong Công thức 2.30 và Công thức 2.31:

$$\mu = \frac{1}{N_{\text{good}}} \sum_{i=1}^{N_{\text{good}}} d(z_i, w_{c(i)}) \tag{2.30}$$

$$\sigma = \sqrt{\frac{1}{N_{\text{good}}} \sum_{i=1}^{N_{\text{good}}} \left(d(z_i, w_{c(i)}) - \mu\right)^2} \tag{2.31}$$

Trong Công thức 2.30 và Công thức 2.31, ký hiệu μ đại diện cho giá trị khoảng cách trung bình của tập mẫu ảnh bình thường, σ thể hiện độ lệch chuẩn của phân phối khoảng cách, N_{good} đại diện cho tổng số lượng mẫu ảnh bình thường trong tập

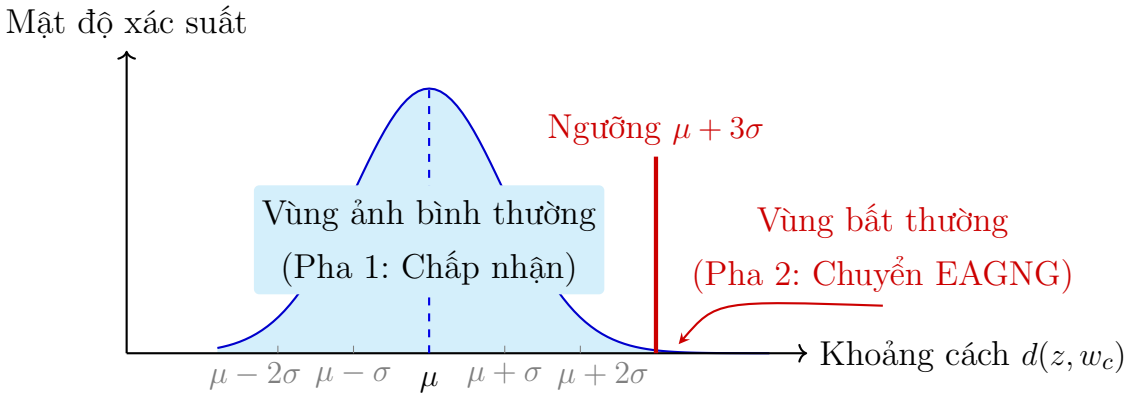
huấn luyện ngoại tuyến, z_i là vectơ ẩn của mẫu thứ i, và $w_{c(i)}$ là nút chiến thắng tương ứng với mẫu z_i.

Quy tắc ba Sigma được áp dụng để xác định ranh giới phân định bất thường với xác suất tin cậy đạt mức chín mươi chín phẩy bảy mươi ba phần trăm đối với phân phối chuẩn [23]. Điều kiện quyết định một mẫu dữ liệu ẩn có thuộc nhóm bất thường và cần chuyển sang Pha hai hay không được thể hiện trong Công thức 2.32:

$$\text{Anomaly}(z_{\text{test}}) = \begin{cases} 1, & \text{nếu } d(z_{\text{test}}, w_c) > \mu + 3\sigma \\ 0, & \text{ngược lại} \end{cases} \tag{2.32}$$

Trong Công thức 2.32, ký hiệu $\text{Anomaly}(z_{\text{test}})$ nhận giá trị bằng một khi mẫu thử nghiệm bị kết luận là chứa khuyết tật bất thường, và nhận giá trị bằng không khi mẫu thử nghiệm nằm trong giới hạn biến động cho phép của sản phẩm đạt tiêu chuẩn.

Phân bố xác suất và ngưỡng phân định bất thường dựa trên khoảng cách ba Sigma được minh họa trực quan trong Hình 2.8.



Hình 2.8: Phân bố khoảng cách Gauss và ngưỡng phân định bất thường dựa trên quy tắc ba Sigma.

Trong Hình 2.8, đường cong biểu diễn mật độ xác suất khoảng cách của các mẫu ảnh đạt tiêu chuẩn. Vùng tô màu nhạt bên trái đại diện cho miền dữ liệu bình thường, trong khi ranh giới đánh dấu tại điểm ba Sigma tách biệt các mẫu bất thường cần được chuyển tiếp sang Pha hai để thực hiện phân cụm.

2.6.2 Phân cụm đồ thị bằng thành phần liên thông

Phân cụm dựa trên thành phần liên thông chuyển đổi cấu trúc đồ thị mạng nơ-ron thành các tập hợp con rời rạc đại diện cho từng loại khuyết tật độc lập. Sau khi mạng EAGNG hoàn tất quá trình huấn luyện trực tuyến ở Pha hai, cấu trúc mạng được biểu diễn dưới dạng một đồ thị vô hướng $G = (V, E)$, trong đó V là tập hợp tất cả các nút nơ-ron đại diện cho các trung tâm dữ liệu khuyết tật, và E là tập hợp các cạnh nối phản ánh mối quan hệ lân cận giữa các nút.

Hai nút nơ-ron $u \in V$ và $v \in V$ được coi là thuộc cùng một thành phần liên thông nếu tồn tại ít nhất một đường đi nối trực tiếp hoặc gián tiếp giữa hai nút đó trên đồ thị G [24]. Định nghĩa toán học của tập hợp thành phần liên thông thứ k, ký hiệu là C_k, được thể hiện qua Công thức 2.33:

$$C_k = \{v \in V \mid \exists p = (u = v_0, v_1, \ldots, v_m = v), \forall j \in \{0, \ldots, m-1\}, (v_j, v_{j+1}) \in E\} \tag{2.33}$$

Trong Công thức 2.33, ký hiệu C_k đại diện cho tập hợp các nút thuộc thành phần liên thông thứ k, p thể hiện dãy các nút tạo thành đường đi từ nút u đến nút v, m là độ dài tính bằng số cạnh của đường đi, và (v_j, v_{j+1}) đại diện cho cạnh nối trực tiếp giữa nút v_j và nút v_{j+1} nằm trong tập cạnh E.

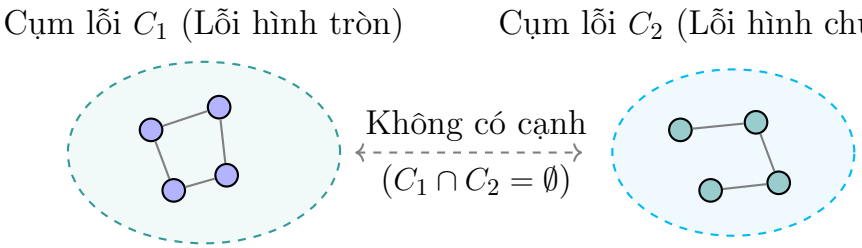
Tập hợp tất cả các thành phần liên thông tạo thành một phép phân hoạch hoàn chỉnh trên tập nút V, thỏa mãn các điều kiện phủ kín và rời rạc theo Công thức 2.34:

$$V = \bigcup_{k=1}^{M} C_k, \quad C_i \cap C_j = \emptyset, \quad \forall i \neq j \tag{2.34}$$

Trong Công thức 2.34, ký hiệu M đại diện cho tổng số lượng cụm khuyết tật độc lập được trích xuất từ đồ thị, C_i và C_j lần lượt thể hiện thành phần liên thông thứ i và thứ j, và $\emptyset$ đại diện cho tập hợp rỗng.

Cấu trúc phân tách các cụm khuyết tật riêng biệt thông qua thuật toán tìm thành phần liên thông trên đồ thị EAGNG được minh họa trong Hình 2.9.

Trong Hình 2.9, các nút nơ-ron thuộc cùng một phân lớp khuyết tật duy trì các liên kết cạnh nội vùng, tạo thành các đường đi liên thông khép kín. Việc thiếu hụt



Hình 2.9: Phân cụm các thành phần liên thông độc lập đại diện cho các dạng khuyết tật bề mặt.

cạnh nối giữa hai nhóm nút giúp phân tách hoàn toàn các dạng khuyết tật khác nhau thành các cụm độc lập.

Phương pháp phân cụm đồ thị bằng thành phần liên thông sở hữu ba ưu thế kỹ thuật vượt trội trong môi trường sản xuất thực tế: (i) thuật toán tự động xác định số lượng cụm khuyết tật M dựa trên cấu trúc đồ thị thực tế mà không đòi hỏi thiết lập trước số cụm như các thuật toán phân hoạch truyền thống; (ii) khả năng biểu diễn các cụm có hình dạng phi tuyến và cấu trúc hình học phức tạp nhờ tính linh hoạt của các kết nối cạnh; (iii) sự kết hợp giữa các thuật toán kiểm soát liên kết của EAGNG và thành phần liên thông giúp loại bỏ các cạnh nối không hợp lệ, ngăn ngừa hiện tượng gộp sai các dạng khuyết tật bề mặt có vị trí gần nhau.

2.7 Bài toán Học liên tục

Bài toán học liên tục đóng vai trò trung tâm trong các hệ thống học máy vận hành trên luồng dữ liệu biến đổi theo thời gian. Môi trường vận hành thực tế luôn tồn tại sự dịch chuyển phân bố dữ liệu đầu vào do các yếu tố vật lý và điều kiện môi trường. Các mô hình học máy truyền thống thường được thiết kế dựa trên giả định dữ liệu độc lập và phân bố đồng nhất, dẫn đến sự suy giảm hiệu năng khi áp dụng vào luồng dữ liệu mở. Lĩnh vực học liên tục tập trung nghiên cứu các nguyên lý toán học và cơ chế thuật toán cho phép hệ thống tích lũy tri thức mới một cách bền vững mà không làm suy giảm khả năng xử lý trên các phân bố dữ liệu đã ghi nhận trong quá khứ.

2.7.1 Mâu thuẫn giữa tính dẻo và tính ổn định

Mâu thuẫn giữa tính dẻo và tính ổn định phản ánh thách thức nền tảng trong việc thiết kế các hệ thống học thích ứng động. Tính dẻo đại diện cho khả năng của hệ thống trong việc điều chỉnh trạng thái không gian tham số để tiếp thu thông tin mới từ luồng dữ liệu hiện tại [19]. Ngược lại, tính ổn định đảm bảo rằng các cấu trúc biểu diễn đã được tối ưu hóa trong quá khứ không bị suy biến. Khi một hệ thống quá nghiêng về tính dẻo, hiện tượng quên lãng thảm khốc sẽ xảy ra, làm mất hoàn toàn khả năng nhận dạng các phân lớp dữ liệu cũ [25].

Khung toán học tổng quát của bài toán học liên tục được mô hình hóa thông qua một chuỗi các nhiệm vụ nối tiếp $t \in \{1, 2, \ldots, T\}$. Tại mỗi bước thời gian t, mô hình tiếp nhận phân bố dữ liệu $\mathcal{D}_t$ và hướng tới việc tối ưu hóa hàm mất mát toàn cục được biểu diễn trong Công thức 2.35:

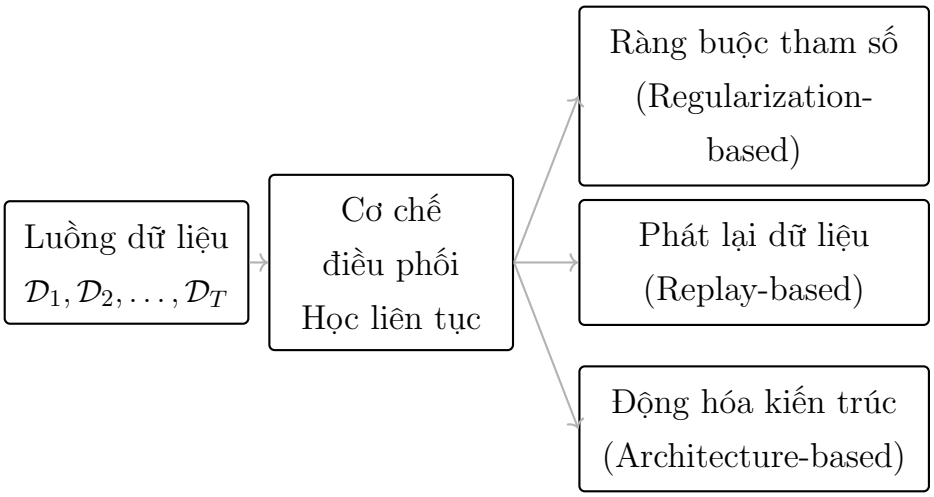
$$\mathcal{L}_{\text{total}}(\theta_t) = \mathbb{E}_{(x,y)\sim\mathcal{D}_t}\left[\ell(f(x;\theta_t), y)\right] + \Omega(\theta_t, \theta_{1:t-1}) \tag{2.35}$$

Trong Công thức 2.35, ký hiệu $\mathcal{L}_{\text{total}}(\theta_t)$ đại diện cho tổng giá trị mất mát của mô hình tại thời điểm t, θ_t thể hiện tập hợp tham số trạng thái của mạng tại bước t, $\mathbb{E}_{(x,y)\sim\mathcal{D}_t}$ là giá trị kỳ vọng toán học trên phân bố dữ liệu của nhiệm vụ t, $\ell(f(x;\theta_t), y)$ thể hiện hàm mất mát đo lường độ sai lệch giữa đầu ra dự báo $f(x;\theta_t)$ và nhãn mục tiêu y, và $\Omega(\theta_t, \theta_{1:t-1})$ đại diện cho thành phần phạt số học nhằm bảo toàn tri thức từ các tập tham số lịch sử $\theta_{1:t-1}$.

2.7.2 Các hướng tiếp cận lý thuyết chủ đạo trong Học liên tục

Các phương pháp nghiên cứu học liên tục trong lý thuyết học máy được phân chia thành ba nhóm tiếp cận chính dựa trên cơ chế kiểm soát không gian tham số và bộ nhớ. Nhóm tiếp cận thứ nhất dựa trên ràng buộc tham số nhằm hạn chế sự biến động của các trọng số quan trọng đối với các nhiệm vụ trước đó thông qua thành phần phạt trong hàm mất mát [26]. Nhóm tiếp cận thứ hai dựa trên việc phát lại dữ liệu hoặc tạo mẫu tái tạo nhằm duy trì sự hiện diện của phân bố dữ liệu cũ trong quá trình tối ưu hóa các mẫu dữ liệu mới [27]. Nhóm tiếp cận thứ ba dựa trên việc mở rộng linh hoạt kiến trúc mạng, trong đó không gian biểu diễn được bổ sung các thành phần mới khi tiếp nhận luồng dữ liệu chứa thông tin chưa từng xuất hiện.

Cấu trúc phân loại các hướng tiếp cận lý thuyết chủ đạo trong bài toán học liên tục được tổng hợp trong Hình 2.10.



Hình 2.10: Cấu trúc phân loại các hướng tiếp cận lý thuyết trong bài toán học liên tục.

Trong Hình 2.10, luồng dữ liệu biến đổi theo thời gian được tiếp nhận và xử lý qua khối điều phối trung tâm nhằm cân bằng tính dẻo và tính ổn định. Ba nhánh tiếp cận lý thuyết tương ứng với ba chiến lược tối ưu hóa không gian tham số, bộ nhớ đệm và kiến trúc mô hình.

Mỗi hướng tiếp cận lý thuyết mang lại các đặc tính tính toán riêng biệt trong môi trường xử lý trực tuyến. Phương pháp ràng buộc tham số có ưu điểm là giữ nguyên kích thước mô hình cố định, nhưng chịu giới hạn về dung lượng biểu diễn khi số lượng nhiệm vụ gia tăng. Phương pháp phát lại dữ liệu giúp duy trì chính xác ranh giới phân định của các phân lớp cũ, nhưng đòi hỏi dung lượng bộ nhớ lưu trữ bổ sung cho các tập dữ liệu quá khứ. Phương pháp thích ứng kiến trúc động cho phép mô hình mở rộng dung lượng biểu diễn một cách tự nhiên theo độ phức tạp của dữ liệu, tuy nhiên đòi hỏi cơ chế kiểm soát sự tăng trưởng để tránh bùng nổ tài nguyên tính toán v.v...

Kết luận Chương 2

Chương 2 đã trình bày tổng quan hệ thống cơ sở lý thuyết về mạng Khí nơ-ron tăng trưởng và các mở rộng toán học nhằm giải quyết bài toán tự động phân loại khuyết tật trong kiểm tra chất lượng màn hình thiết bị di động. Nội dung chương đã phân tích chi tiết nguyên lý vận hành của thuật toán Khí nơ-ron tăng trưởng

truyền thống, đồng thời chỉ ra các hạn chế kỹ thuật liên quan đến hiện tượng bùng nổ số lượng nút nơ-ron và nguy cơ sáp nhập sai các cụm khuyết tật riêng biệt do nhiễu không gian. Bên cạnh đó, khung toán học của bài toán học liên tục cũng được hệ thống hóa nhằm làm rõ thách thức về mâu thuẫn giữa tính dẻo và tính ổn định trong môi trường xử lý luồng dữ liệu biến đổi.

Các cải tiến toán học cốt lõi của mô hình EAGNG được tổng hợp nhằm tạo tiền đề khắc phục các tồn tại kỹ thuật trên thông qua bốn cơ chế chính: (i) mô hình hóa quy luật suy giảm tốc độ học và mức tích lũy sai số theo độ tuổi nút nhằm duy trì tính ổn định của cấu trúc tri thức; (ii) thiết lập vùng đệm bộ nhớ tích lũy bằng chứng kết hợp phương pháp ước lượng mật độ nhân Gauss để hoãn chèn nút đối với các mẫu dữ liệu ngoại lai; (iii) đánh giá mật độ không gian cục bộ nhằm kiểm soát sự tăng trưởng số lượng nút tại các vùng dữ liệu có mật độ cao; (iv) áp dụng lý thuyết hình học bao không gian để kiểm soát điều kiện tạo cạnh nối giữa các cụm nơ-ron. Bên cạnh đó, việc tích hợp quy tắc phân phối thống kê ba Sigma cho Pha một và thuật toán thành phần liên thông trên đồ thị cho Pha hai tạo nên cơ chế hoàn chỉnh cho phép lọc bỏ ảnh bình thường và phân nhóm chính xác các dạng lỗi bề mặt.

Toàn bộ các nguyên lý toán học và mô hình lý thuyết được tổng hợp trong Chương 2 đóng vai trò là nền tảng khoa học trực tiếp cho việc thiết kế kiến trúc chi tiết của hệ thống EAGNG. Trên cơ sở lý thuyết đã được thiết lập, Chương 3 sẽ trình bày chi tiết phương pháp đề xuất, cấu trúc thuật toán tổng quát, quy trình xử lý dữ liệu luồng thực tế và cách thức hiện thực hóa hệ thống phân loại khuyết tật màn hình điện thoại.

Chương 3

Kiến trúc Hệ thống và Thuật toán EAGNG Phân cụm Khuyết tật Trực tuyến

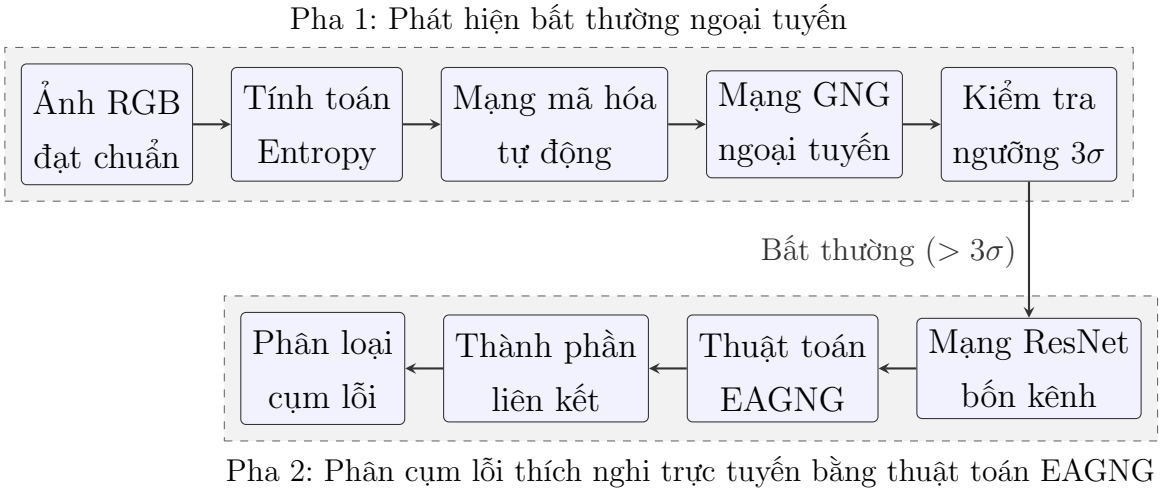
Chương 3 trình bày chi tiết về kiến trúc hệ thống tổng thể và thiết kế thuật toán Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng đề xuất cho bài toán tự động phân loại khuyết tật màn hình điện thoại. Giải pháp được xây dựng dựa trên mô hình hai pha nối tiếp nhằm giải quyết đồng thời yêu cầu lọc bỏ sản phẩm đạt chuẩn ở tốc độ cao và phân cụm linh hoạt các dạng lỗi bề mặt phức tạp trong điều kiện vận hành thời gian thực. Hệ thống tích hợp thông tin entropy cục bộ làm kênh dữ liệu thứ tư kết hợp với các mạng nơ-ron sâu chuyên biệt để trích xuất đặc trưng phù hợp cho từng giai đoạn xử lý.

Nội dung chính của chương tập trung làm rõ cấu trúc toán học và các cơ chế cải tiến cốt lõi của thuật toán đề xuất. Pha 1 sử dụng mạng mã hóa tự động để nén không gian biểu diễn và thiết lập ranh giới phân loại bất thường bằng quy tắc ba lần độ lệch chuẩn trên Mạng khí Nơ-ron tăng trưởng ngoại tuyến. Pha 2 phát triển thuật toán Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng với bốn cơ chế cải tiến chính bao gồm: (i) suy giảm tốc độ học và tích lũy lỗi theo tuổi nút, (ii) trì hoãn chèn nút dựa trên tích lũy bằng chứng kết hợp huấn luyện cục bộ, (iii) phát triển cấu trúc nhạy mật độ, và (iv) kiểm tra sự chồng lấp hộp giới hạn để kiểm soát liên kết cạnh. Toàn bộ quy trình tạo thành một khung xử lý toán học hoàn chỉnh, làm cơ sở lý thuyết cho việc triển khai thực nghiệm ở chương tiếp theo.

3.1 Kiến trúc tổng thể hệ thống đề xuất

Hệ thống đề xuất được cấu trúc thành hai pha xử lý nối tiếp nhằm giải quyết triệt để bài toán phát hiện bất thường và phân cụm khuyết tật thời gian thực trên màn hình điện thoại. Pha 1 đảm nhận vai trò lọc bỏ các mẫu sản phẩm đạt chuẩn thông qua mô hình phát hiện bất thường ngoại tuyến, giúp giảm tải khối lượng tính toán

cho hệ thống. Pha 2 tập trung phân tích hình thái khuyết tật và thực hiện phân cụm tự động bằng thuật toán Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng. Sự kết hợp giữa xử lý dữ liệu đa kênh và trích xuất đặc trưng chuyên biệt giữa hai pha tạo nên một quy trình khép kín, đảm bảo độ chính xác và tính thích nghi cao trong môi trường sản xuất công nghiệp. Sơ đồ khối tổng thể của hệ thống được trình bày chi tiết trong Hình 3.1.



Hình 3.1: Sơ đồ kiến trúc tổng thể hai pha của hệ thống tự động phân loại khuyết tật màn hình điện thoại.

3.1.1 Pha 1: Phát hiện bất thường ngoại tuyến

Pha phát hiện bất thường ngoại tuyến có mục tiêu thiết lập mô hình biểu diễn phân bố của sản phẩm đạt tiêu chuẩn chất lượng. Quy trình khởi đầu bằng việc thu thập tập hợp các hình ảnh màn hình điện thoại không chứa khuyết tật từ dây chuyền sản xuất. Mỗi hình ảnh đầu vào ban đầu được tính toán bản đồ entropy cục bộ để ghi nhận thông tin về độ phức tạp bề mặt và được ghép nối trực tiếp thành kênh dữ liệu thứ tư. Mạng mã hóa tự động tiếp nhận dữ liệu bốn kênh này nhằm thực hiện nén dữ liệu và thu gọn không gian biểu diễn về một không gian tiềm ẩn có kích thước nhỏ hơn [15].

Mô hình Mạng khí Nơ-ron tăng trưởng ngoại tuyến được huấn luyện trực tiếp trên tập hợp các vectơ tiềm ẩn thu được từ mạng mã hóa tự động. Quá trình huấn luyện này giúp Mạng khí Nơ-ron tăng trưởng học được cấu trúc không gian của dữ liệu chuẩn và hình thành bộ nút đại diện cho phân bố dữ liệu không lỗi. Khi một

hình ảnh mới được đưa vào kiểm tra, vectơ tiềm ẩn của hình ảnh đó sẽ được tính toán khoảng cách Euclid tới nút gần nhất trong Mạng khí Nơ-ron tăng trưởng.

Việc quyết định một mẫu dữ liệu có chứa khuyết tật hay không dựa trên quy tắc thống kê ba lần độ lệch chuẩn. Khoảng cách Euclid cực tiểu $d_{min}(z)$ từ vectơ tiềm ẩn z tới tập hợp các nút trong Mạng khí Nơ-ron tăng trưởng được xác định theo Công thức 3.1:

$$d_{min}(z) = \min_{i \in V} \|z - w_i\|_2 \tag{3.1}$$

trong đó z đại diện cho vectơ tiềm ẩn thu được từ không gian ẩn của mạng mã hóa tự động, V biểu diễn tập hợp các nút trong đồ thị nơ-ron khí tăng trưởng ngoại tuyến, w_i là vectơ trọng số của nút thứ i trong tập hợp V, và $\|\cdot\|_2$ thể hiện chuẩn Euclid hai. Ngưỡng quyết định bất thường T_{pha1} được thiết lập theo Công thức 3.2:

$$T_{pha1} = \mu_d + 3\sigma_d \tag{3.2}$$

trong đó μ_d biểu diễn giá trị trung bình của khoảng cách cực tiểu trên tập dữ liệu huấn luyện chuẩn, và σ_d đại diện cho độ lệch chuẩn tương ứng của chuỗi khoảng cách này. Nếu khoảng cách $d_{min}(z)$ vượt quá ngưỡng T_{pha1}, mẫu dữ liệu được xác định là bất thường và được chuyển sang pha 2 để thực hiện phân cụm khuyết tật.

3.1.2 Pha 2: Phân cụm lỗi thích nghi trực tuyến bằng thuật toán EAGNG

Pha phân cụm lỗi thích nghi trực tuyến tiếp nhận toàn bộ các mẫu hình ảnh được xác định là bất thường từ pha 1 để tiến hành phân tích sâu và phân loại cấu trúc lỗi. Không giống như pha 1 tập trung vào việc tái tạo toàn cục thông qua mạng mã hóa tự động, pha 2 sử dụng kiến trúc mạng nơ-ron tích chập ResNet điều chỉnh bốn kênh đầu vào để trích xuất các đặc trưng chú trọng đến hình thái và ranh giới khuyết tật.

Vectơ đặc trưng thu được từ mạng ResNet bốn kênh được đưa trực tiếp vào mô hình Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng để tiến hành huấn luyện trực tuyến. Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng thực hiện cập nhật cấu trúc mạng một cách liên tục dựa trên bốn cơ chế cải tiến chính bao gồm: (i) suy giảm tốc độ học và tích lũy lỗi theo tuổi nút, (ii) trì hoãn chèn nút dựa trên tích lũy bằng chứng kết hợp huấn luyện cục bộ, (iii) phát triển cấu trúc nhạy mật

độ nhằm kiểm soát sự bùng nổ số lượng nút, và (iv) kiểm tra sự chồng lấp hộp giới hạn để kiểm soát việc nối cạnh giữa các cụm. Các cơ chế này giúp mô hình duy trì tính ổn định cấu trúc tô-pô và tránh hiện tượng nhiễu cấu trúc khi dữ liệu xuất hiện theo dòng liên tục [7].

Sau khi Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng hoàn thành cập nhật trạng thái trực tuyến cho mẫu dữ liệu, thuật toán thành phần liên kết trên đồ thị được áp dụng để nhóm các nút kết nối thành các cụm khuyết tật riêng biệt. Các tập hợp nút thuộc cùng một thành phần liên kết trên đồ thị được xác định là một lớp khuyết tật cụ thể trên bề mặt màn hình điện thoại. Phương pháp phân cụm dựa trên đồ thị này giúp hệ thống tự động phát hiện các dạng lỗi mới phát sinh mà không cần biết trước số lượng cụm khuyết tật trong quá trình vận hành v.v...

3.2 Biểu diễn dữ liệu và Xử lý đặc trưng không gian Entropy

Biểu diễn dữ liệu đa kênh đóng vai trò quyết định trong việc nâng cao độ nhạy của hệ thống đối với các khuyết tật có độ tương phản thấp trên bề mặt màn hình điện thoại. Các phương pháp xử lý ảnh truyền thống dựa trên không gian màu RGB thường gặp khó khăn trong việc phát hiện các vết ố mờ do sự biến đổi độ sáng không đáng kể so với nền xung quanh. Để khắc phục hạn chế này, hệ thống đề xuất tích hợp không gian entropy cục bộ như một kênh thông tin bổ sung nhằm gia tăng khả năng phân tách đặc trưng giữa vùng bề mặt chuẩn và vùng chứa khuyết tật.

3.2.1 Thuật toán trích xuất bản đồ Entropy cục bộ

Entropy cục bộ đo lường mức độ không chắc chắn hoặc độ phức tạp của sự phân bố mức xám trong một cửa sổ trượt xung quanh mỗi điểm ảnh. Bản đồ entropy thu được phản ánh sự thay đổi cấu trúc bề mặt, trong đó các vùng chứa đốm tròn hoặc hạt bụi thường thể hiện độ mất trật tự thông tin cao hơn đáng kể so với các vùng bề mặt đồng nhất [9].

Quy trình trích xuất bản đồ entropy cục bộ được thực hiện thông qua các bước tính toán trên từng vùng ảnh lân cận. Đầu tiên, hình ảnh đầu vào được chuyển đổi về dạng ảnh mức xám hai chiều. Tiếp theo, một cửa sổ trượt vuông kích thước $N \times N$ điểm ảnh được quét qua toàn bộ bề mặt hình ảnh với bước nhảy bằng một.

Tại mỗi vị trí tâm (x, y) của cửa sổ trượt $W(x, y)$, xác suất xuất hiện p_k của mức xám k được xác định theo Công thức 3.3:

$$p_k = \frac{n_k}{\sum_{j=0}^{L-1} n_j} \tag{3.3}$$

trong đó n_k đại diện cho số lượng điểm ảnh có mức xám k nằm bên trong cửa sổ trượt $W(x, y)$, L biểu diễn tổng số mức xám của hình ảnh với giá trị mặc định bằng 256, và mẫu số thể hiện tổng số điểm ảnh trong cửa sổ trượt $N \times N$.

Giá trị entropy cục bộ $E(x, y)$ tại điểm ảnh tâm (x, y) được tính toán dựa trên định lý entropy thông tin Shannon theo Công thức 3.4:

$$E(x, y) = -\sum_{k=0}^{L-1} p_k \log_2(p_k + \epsilon) \tag{3.4}$$

trong đó p_k là xác suất xuất hiện của mức xám k, ϵ là một hằng số dương cực tiểu được thêm vào nhằm tránh lỗi vô cấm toán học khi $p_k = 0$, và $\log_2$ là hàm logarit cơ số hai. Việc lặp lại phép tính trên toàn bộ các điểm ảnh giúp tạo ra một bản đồ entropy hai chiều có cùng kích thước không gian với hình ảnh ban đầu v.v...

Việc lựa chọn kích thước cửa sổ trượt $N \times N$ ảnh hưởng trực tiếp đến chất lượng trích xuất đặc trưng hình thái. Nếu kích thước N quá nhỏ, bản đồ entropy sẽ bị ảnh hưởng mạnh bởi nhiễu ngẫu nhiên của cảm biến thu nhận ảnh. Ngược lại, nếu kích thước N quá lớn, ranh giới của các vết khuyết tật siêu nhỏ sẽ bị làm mịn quá mức, dẫn đến mất mát thông tin không gian quan trọng. Qua các thực nghiệm khảo sát, kích thước cửa sổ $N = 9$ điểm ảnh được lựa chọn nhằm tối ưu hóa sự cân bằng giữa khả năng triệt tiêu nhiễu và độ sắc nét của biên giới khuyết tật.

3.2.2 Kỹ thuật ghép kênh RGB-E và Chuẩn hóa dữ liệu

Kỹ thuật ghép kênh kết hợp bản đồ entropy vào không gian màu nguyên bản nhằm tạo ra cấu trúc dữ liệu bốn kênh RGB-E đồng bộ về kích thước không gian. Cấu trúc dữ liệu mở rộng này cung cấp đầy đủ thông tin màu sắc, độ sáng và cấu trúc bề mặt cho các mô hình trích xuất đặc trưng phía sau.

Vectơ biểu diễn dữ liệu bốn kênh $I_{RGB-E}(x, y)$ tại tọa độ (x, y) được hình thành bằng cách ghép nối trực tiếp bản đồ entropy vào tập hợp các kênh màu tiêu chuẩn theo Công thức 3.5:

$$I_{RGB-E}(x, y) = [R(x, y), G(x, y), B(x, y), E_{norm}(x, y)]^T \tag{3.5}$$

trong đó $R(x, y)$, $G(x, y)$, và $B(x, y)$ lần lượt đại diện cho cường độ giá trị của các kênh màu đỏ, xanh lá cây và xanh dương tại điểm ảnh (x, y), trong khi $E_{norm}(x, y)$ biểu diễn giá trị entropy cục bộ đã qua chuẩn hóa.

Do phạm vi giá trị của bản đồ entropy ban đầu khác biệt so với khoảng giá trị màu sắc, việc chuẩn hóa dữ liệu là bắt buộc nhằm đảm bảo tính đồng đều về mặt miền giá trị giữa các kênh đầu vào. Giá trị entropy cục bộ $E(x, y)$ được biến đổi về khoảng $[0, 1]$ thông qua kỹ thuật chuẩn hóa Cực tiểu - Cực đại theo Công thức 3.6:

$$E_{norm}(x, y) = \frac{E(x, y) - E_{min}}{E_{max} - E_{min} + \delta} \tag{3.6}$$

trong đó E_{min} và E_{max} lần lượt đại diện cho giá trị entropy nhỏ nhất và lớn nhất ghi nhận được trên toàn bộ bản đồ ảnh, còn δ là hằng số dương cực tiểu ngăn ngừa hiện tượng chia cho số không.

Quy trình chuẩn hóa bốn kênh giúp ổn định quá trình lan truyền ngược và tăng tốc độ hội tụ khi huấn luyện các mạng nơ-ron sâu trong hệ thống. Dữ liệu bốn kênh sau khi xử lý đáp ứng đầy đủ điều kiện về mặt phân bố để làm đầu vào cho mô hình Autoencoder ở Pha 1 và mạng ResNet cải tiến ở Pha 2 [10].

3.3 Trích xuất đặc trưng chuyên biệt cho hai pha

Quá trình trích xuất đặc trưng được thiết kế tách biệt cho hai pha xử lý nhằm đáp ứng các mục tiêu bài toán khác nhau. Pha phát hiện bất thường ngoại tuyến yêu cầu một không gian biểu diễn thu nhỏ để nén các đặc tính của bề mặt màn hình đạt chuẩn, trong khi pha phân cụm lỗi trực tuyến cần các đặc trưng phản ánh chi tiết hình thái và biên giới của khuyết tật. Sự phân tách này giúp tối ưu hóa dung lượng tính toán và nâng cao khả năng phân tách giữa các lớp lỗi phát sinh.

3.3.1 Mạng mã hóa tự động: Nén không gian tiềm ẩn nhận dạng mẫu chuẩn

Mạng mã hóa tự động đảm nhận nhiệm vụ học cách biểu diễn thu gọn của các hình ảnh màn hình không chứa khuyết tật. Bằng cách huấn luyện mạng tái tạo lại chính dữ liệu đầu vào bốn kênh, mô hình buộc phải nén thông tin qua một bộ thắt nút để tạo ra vectơ tiềm ẩn chứa các đặc trưng tổng quát nhất của bề mặt chuẩn [28].

Quá trình mã hóa và giải mã được thực hiện qua hai phép biến đổi phi tuyến nối tiếp. Hàm mã hóa chuyển đổi dữ liệu đầu vào bốn kênh thành vectơ tiềm ẩn theo Công thức 3.7:

$$z = g_\theta(I_{RGB-E}) \tag{3.7}$$

trong đó I_{RGB-E} đại diện cho dữ liệu ảnh đầu vào bốn kênh bao gồm ba kênh màu và một kênh entropy, g_θ biểu diễn hàm mã hóa được tham số hóa bởi tập trọng số θ, và z là vectơ tiềm ẩn nằm trong không gian nén. Sau đó, quá trình tái tạo hình ảnh từ không gian tiềm ẩn được thực hiện qua hàm giải mã theo Công thức 3.8:

$$\hat{I}_{RGB-E} = f_\phi(z) \tag{3.8}$$

trong đó f_ϕ là hàm giải mã được tham số hóa bởi tập trọng số ϕ, và $\hat{I}_{RGB-E}$ biểu diễn dữ liệu ảnh tái tạo bốn kênh thu được ở đầu ra.

Vectơ tiềm ẩn z thu được sau quá trình huấn luyện giữ vai trò là đầu vào cho mô hình Mạng khí Nơ-ron tăng trưởng ngoại tuyến ở Pha 1. Do mạng mã hóa tự động chỉ được huấn luyện trên tập dữ liệu đạt chuẩn, khả năng tái tạo của mạng đối với các vùng chứa khuyết tật sẽ kém hiệu quả, tạo ra sự sai lệch khoảng cách đáng kể và hỗ trợ cho việc phân loại bất thường ở các giai đoạn sau.

3.3.2 Mạng ResNet bốn kênh: Trích xuất đặc trưng hình thái lỗi

Mạng ResNet bốn kênh được cải tiến để trích xuất các đặc trưng ngữ nghĩa và hình thái khuyết tật phục vụ cho giai đoạn phân cụm trực tuyến ở Pha 2. Khác với mạng mã hóa tự động tập trung vào việc tái tạo toàn cục, kiến trúc ResNet tận dụng các liên kết tắt nhằm bảo toàn thông tin độ dốc và trích xuất các đặc trưng ranh giới sắc nét của đốm tròn hoặc hạt bụi [10].

Lớp tích phân đầu tiên của kiến trúc mạng được điều chỉnh để tiếp nhận trực tiếp dữ liệu đầu vào bốn kênh. Biến đổi đặc trưng từ ảnh bất thường sang vectơ đặc trưng hình thái được mô tả theo Công thức 3.9:

$$f_{defect} = R_\psi(I_{RGB-E}^{anomaly}) \tag{3.9}$$

trong đó $I_{RGB-E}^{anomaly}$ đại diện cho dữ liệu ảnh bất thường bốn kênh được chuyển tiếp từ Pha 1, R_ψ biểu diễn hàm trích xuất đặc trưng của mạng ResNet cải tiến với tập tham số ψ, và f_{defect} là vectơ đặc trưng hình thái đầu ra được sử dụng cho thuật toán phân cụm trực tuyến.

Vectơ đặc trưng f_{defect} tập trung phản ánh các yếu tố cấu trúc bao gồm: (i) kích thước và diện tích của vùng khuyết tật, (ii) độ bất đồng nhất về mặt entropy tại khu vực biến dạng, và (iii) tỷ lệ hình dạng biên giới khuyết tật. Các yếu tố này tạo tiền đề cho việc phân tách chính xác các dạng lỗi có hình thái khác nhau trong không gian đặc trưng.

3.3.3 Hàm mất mát và Tối ưu hóa mạng trích xuất đặc trưng

Quá trình huấn luyện mạng trích xuất đặc trưng sử dụng các hàm mất mát chuyên biệt nhằm tối ưu hóa khả năng biểu diễn dữ liệu cho từng pha. Việc lựa chọn đúng hàm mục tiêu đảm bảo mô hình không bị quá khớp với dữ liệu huấn luyện và duy trì tính ổn định khi triển khai thực tế.

Mạng mã hóa tự động ở Pha 1 được tối ưu hóa thông qua hàm mất mát sai số bình phương trung bình kết hợp với chỉ số độ tương đồng cấu trúc. Hàm mất mát tổng hợp của mạng mã hóa tự động được xác định theo Công thức 3.10:

$$L_{AE}(\theta, \phi) = \frac{1}{M} \sum_{i=1}^{M} \| I_{RGB-E}^{(i)} - \hat{I}_{RGB-E}^{(i)} \|_2^2 + \lambda \left(1 - \text{SSIM}(I_{RGB-E}^{(i)}, \hat{I}_{RGB-E}^{(i)}) \right) \quad (3.10)$$

trong đó M đại diện cho tổng số mẫu ảnh trong một lô huấn luyện, $I_{RGB-E}^{(i)}$ và $\hat{I}_{RGB-E}^{(i)}$ lần lượt biểu diễn ảnh gốc thứ i và ảnh tái tạo tương ứng, SSIM là chỉ số đo lường độ tương đồng cấu trúc giữa hai hình ảnh, λ là hệ số cân bằng giữa hai thành phần mất mát, và $\| \cdot \|_2$ thể hiện chuẩn Euclid hai.

Thuật toán tối ưu hóa Adam được áp dụng để cập nhật trọng số cho cả hai mạng với tốc độ học được điều chỉnh giảm dần theo thời gian huấn luyện. Quá trình tối ưu hóa kết thúc khi giá trị của hàm mất mát đạt trạng thái hội tụ và không giảm quá một ngưỡng xác định trước trong nhiều chu kỳ huấn luyện liên tiếp v.v...

3.4 Mô hình phát hiện bất thường ngoại tuyến

Pha phát hiện bất thường ngoại tuyến đóng vai trò sàng lọc toàn bộ các sản phẩm màn hình điện thoại đạt tiêu chuẩn chất lượng trước khi đưa dữ liệu nghi ngờ vào chuỗi xử lý phức tạp ở pha tiếp theo. Việc xây dựng một mô hình đại diện chính xác cho phân bố của sản phẩm không khuyết tật giúp hệ thống tối ưu hóa tài nguyên tính toán và giảm thiểu tỷ lệ báo động giả. Cơ chế này dựa trên sự kết

hợp giữa khả năng nén đặc trưng của mạng mã hóa tự động và năng lực học tô-pô không gian của Mạng khí Nơ-ron tăng trưởng.

3.4.1 Huấn luyện GNG ngoại tuyến trên không gian tiềm ẩn

Mạng khí nơ-ron tăng trưởng ngoại tuyến được xây dựng nhằm mô phỏng chính xác cấu trúc hình học của không gian đặc trưng biểu diễn bề mặt sản phẩm đạt chuẩn. Tập hợp các vectơ tiềm ẩn thu được từ đầu ra của mạng mã hóa tự động ở Mục 3.3.1 đóng vai trò là dữ liệu đầu vào cho quá trình huấn luyện. Thông qua thuật toán cạnh tranh không giám sát, mạng tự động điều chỉnh vị trí các nút và thiết lập các liên kết cạnh nhằm bao phủ toàn bộ vùng dữ liệu chuẩn trong không gian tiềm ẩn [7].

Quá trình cập nhật vị trí nút chiến thắng và các nút lân cận trực tiếp trong mạng khí nơ-ron tăng trưởng được thực hiện theo nguyên lý học cạnh tranh [11]. Đối với mỗi vectơ tiềm ẩn đầu vào z, nút chiến thắng thứ nhất s_1 có khoảng cách Euclid nhỏ nhất đến z và nút chiến thắng thứ hai s_2 được xác định. Vectơ trọng số của nút s_1 được cập nhật theo Công thức 3.11:

$$\Delta w_{s_1} = \epsilon_b(z - w_{s_1}) \tag{3.11}$$

trong đó z đại diện cho vectơ tiềm ẩn đầu vào, w_{s_1} biểu diễn vectơ trọng số của nút chiến thắng thứ nhất s_1, và ϵ_b là tốc độ học của nút chiến thắng. Đồng thời, vectơ trọng số của các nút n thuộc tập hợp lân cận trực tiếp N_{s_1} của nút s_1 được điều chỉnh theo Công thức 3.12:

$$\Delta w_n = \epsilon_n(z - w_n) \quad \forall n \in N_{s_1} \tag{3.12}$$

trong đó w_n biểu diễn vectơ trọng số của nút lân cận n, N_{s_1} là tập hợp các nút có liên kết cạnh trực tiếp với nút s_1, và ϵ_n đại diện cho tốc độ học của các nút lân cận.

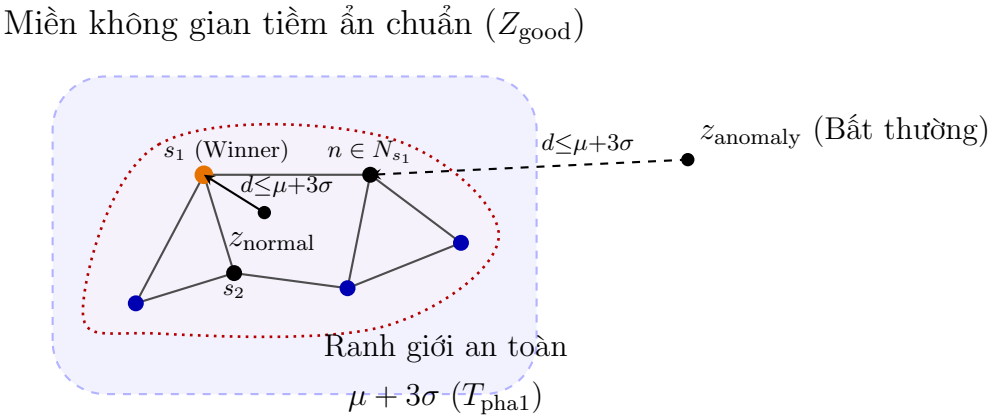
Sự tích lũy lỗi cục bộ tại từng nút quyết định việc bổ sung nút mới vào cấu trúc mạng sau một số chu kỳ huấn luyện định kỳ. Lỗi tích lũy A_{s_1} của nút chiến thắng s_1 được cập nhật theo Công thức 3.13:

$$A_{s_1} \leftarrow A_{s_1} + \|z - w_{s_1}\|_2^2 \tag{3.13}$$

trong đó A_{s_1} đại diện cho giá trị lỗi tích lũy của nút s_1, z là vectơ tiềm ẩn hiện tại, w_{s_1} là vectơ trọng số của nút s_1, và $\|\cdot\|_2$ thể hiện chuẩn Euclid hai. Quá trình gia

tăng số lượng nút dừng lại khi mạng đạt đến số lượng nút tối đa quy định trước hoặc khi sai số tái tạo toàn cục đạt trạng thái ổn định.

Mô hình phân bố dữ liệu chuẩn thu được sau quá trình huấn luyện ngoại tuyến hình thành nên một đồ thị phác họa vùng không gian an toàn của sản phẩm không lỗi. Sơ đồ minh họa quá trình phân tách vùng dữ liệu chuẩn và xác định điểm bất thường trên không gian tiềm ẩn được thể hiện trong Hình 3.2.



Hình 3.2: Mô phỏng không gian tiềm ẩn chuẩn với cấu trúc đồ thị Mạng khí Nơ-ron tăng trưởng ngoại tuyến và cơ chế xác định mẫu bất thường dựa trên khoảng cách ngưỡng $\mu + 3\sigma$.

3.4.2 Cơ chế phân loại bất thường dựa trên khoảng cách ngưỡng ba lần độ lệch chuẩn

Cơ chế phân loại bất thường dựa trên nguyên lý đo lường sự độ lệch của biểu diễn không gian ẩn từ mẫu đầu vào so với cấu trúc đồ thị của mô hình Mạng khí Nơ-ron tăng trưởng ngoại tuyến. Khi hình ảnh bề mặt màn hình điện thoại được đưa vào hệ thống, véc-tơ biểu diễn ẩn z_x của mẫu ảnh đó sẽ được trích xuất thông qua mạng mã hóa tự động. Khoảng cách Euclid nhỏ nhất từ véc-tơ ẩn z_x tới tập hợp các véc-tơ trọng số trong đồ thị Mạng khí Nơ-ron tăng trưởng ngoại tuyến được tính toán theo Công thức 3.14:

$$d(z_x) = \min_{i \in V} \|z_x - w_i\|_2 \tag{3.14}$$

Trong Công thức 3.14, ký hiệu $d(z_x)$ đại diện cho khoảng cách nhỏ nhất từ mẫu kiểm thử z_x đến đồ thị mạng, ký hiệu V biểu diễn tập hợp chỉ số các nút thuộc

mạng, ký hiệu w_i thể hiện véc-tơ trọng số của nút thứ i, và ký hiệu $\|\cdot\|_2$ đại diện cho chuẩn Euclid cấp hai.

Cơ sở lý thuyết của việc định giá trị ngưỡng phân định bất thường xuất phát từ mối liên hệ giữa khoảng cách biểu diễn không gian và xác suất thuộc về phân phối của tập sản phẩm đạt chuẩn [23, 29]. Giá trị khoảng cách $d(z_x)$ từ véc-tơ đầu vào z_x đến nút gần nhất càng lớn phản ảnh mẫu dữ liệu càng nằm xa vùng phân phối của dữ liệu đạt chất lượng đã được mô hình học trước đó. Giả định chuỗi khoảng cách cực tiểu của các mẫu đạt tiêu chuẩn tuân theo phân phối chuẩn, khoảng khoảng cách $\mu_d \pm 3\sigma_d$ bao phủ 99,73% số lượng mẫu dữ liệu bình thường theo tiêu chuẩn thống kê [29]. Do đó, bất kỳ mẫu sản phẩm nào có khoảng cách vượt quá ngưỡng trên sẽ được hệ thống gán nhãn là mẫu bất thường với độ tin cậy cao.

Để thiết lập ngưỡng phân định T_{pha1} một cách tự động, hệ thống sử dụng tập kiểm định độc lập gồm các mẫu sản phẩm không chứa khuyết tật. Các thông số thống kê bao gồm giá trị trung bình và độ lệch chuẩn của chuỗi khoảng cách cực tiểu trên tập kiểm định được xác định lần lượt thông qua Công thức 3.15 và Công thức 3.16:

$$\mu_d = \frac{1}{K}\sum_{j=1}^{K} d(z_j^{val}) \tag{3.15}$$

$$\sigma_d = \sqrt{\frac{1}{K-1}\sum_{j=1}^{K}\left(d(z_j^{val}) - \mu_d\right)^2} \tag{3.16}$$

Trong Công thức 3.15 và Công thức 3.16, ký hiệu K đại diện cho tổng số lượng mẫu kiểm định đạt chuẩn, ký hiệu z_j^{val} biểu diễn véc-tơ ẩn của mẫu kiểm định thứ j, ký hiệu μ_d thể hiện giá trị trung bình mẫu của khoảng cách, và ký hiệu σ_d đại diện cho độ lệch chuẩn mẫu.

Quy tắc xác định ngưỡng phân loại bất thường T_{pha1} được thiết lập theo nguyên lý ba lần độ lệch chuẩn thể hiện trong Công thức 3.17:

$$T_{pha1} = \mu_d + 3\sigma_d \tag{3.17}$$

Trong Công thức 3.17, ký hiệu T_{pha1} đóng vai trò là ngưỡng khoảng cách tối đa chấp nhận được đối với một sản phẩm đạt chuẩn.

Tiến trình ra quyết định kiểm tra chất lượng đối với một mẫu ảnh đầu vào được thực hiện phân định qua hai trường hợp cụ thể: (i) nếu khoảng cách $d(z_x) \leq T_{pha1}$,

mẫu dữ liệu được kết luận là sản phẩm đạt chuẩn và hệ thống kết thúc tiến trình xử lý đối với mẫu này, và (ii) nếu khoảng cách $d(z_x) > T_{pha1}$, mẫu dữ liệu bị xác định là bất thường và được chuyển tiếp sang Pha 2 để thực hiện phân tích đặc trưng và phân cụm trực tuyến. Cơ chế này đảm bảo chỉ những hình ảnh thực sự chứa khuyết tật mới đi vào tiến trình phân cụm trực tuyến, giúp tối ưu hóa chi phí tính toán và duy trì tốc độ vận hành cho toàn hệ thống.

3.5 Thuật toán phân cụm lõi trực tuyến EAGNG

Thuật toán Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng được đề xuất nhằm giải quyết bài toán phân cụm khuyết tật thích nghi trực tuyến từ dòng đặc trưng trích xuất từ mạng ResNet bốn kênh ở Pha 2. Mạng khí Nơ-ron tăng trưởng truyền thống của Fritzke [7] gặp nhiều hạn chế khi vận hành trong môi trường công nghiệp liên tục do hiện tượng nhiễu dữ liệu, sự xuất hiện của các dạng lỗi mới và nguy cơ bùng nổ số lượng nút không kiểm soát. Thuật toán cải tiến tích hợp bốn cơ chế cốt lõi để duy trì tính ổn định tô-pô, kiểm soát mật độ nút và phân tách chính xác các hình thái khuyết tật phức tạp.

3.5.1 Cơ chế suy giảm tốc độ học và tích lũy lỗi theo tuổi nút

Cơ chế suy giảm tốc độ học và tích lũy lỗi theo tuổi nút điều chỉnh động năng lực học của từng nút dựa trên thời gian tồn tại của nút đó trong đồ thị. Các nút mới được tạo ra có mức độ linh hoạt cao để nhanh chóng thích nghi với vùng không gian đặc trưng mới, trong khi các nút có tuổi đời cao đạt trạng thái ổn định nhằm bảo tồn tri thức cấu trúc đã học [11].

Tốc độ học của nút chiến thắng thứ nhất s_1 và các nút lân cận n thuộc tập hợp N_{s_1} giảm dần theo độ tuổi của nút a_{s_1} được tính toán theo Công thức 3.18 và Công thức 3.19:

$$\epsilon_b(a_{s_1}) = \frac{\epsilon_{b0}}{1 + \alpha_a \cdot a_{s_1}} \tag{3.18}$$

$$\epsilon_n(a_n) = \frac{\epsilon_{n0}}{1 + \alpha_a \cdot a_n} \tag{3.19}$$

trong đó ϵ_{b0} và ϵ_{n0} lần lượt đại diện cho tốc độ học khởi tạo của nút chiến thắng và nút lân cận, a_{s_1} và a_n tương ứng là tuổi hiện tại của nút s_1 và nút n, còn α_a là hệ số suy giảm tuổi nút.

Đồng thời, tốc độ tích lũy lỗi tại nút chiến thắng s_1 cũng được điều chỉnh giảm theo tuổi nhằm tránh hiện tượng phát triển nút mới bất hợp lý tại các vùng dữ liệu đã ổn định. Mức tăng lỗi tích lũy ΔA_{s_1} được xác định theo Công thức 3.20:

$$\Delta A_{s_1} = \left(1 - \frac{a_{s_1}}{a_{s_1} + a_{max}}\right) \cdot \|f_{defect} - w_{s_1}\|_2^2 \tag{3.20}$$

trong đó f_{defect} là vectơ đặc trưng lỗi đầu vào từ mạng ResNet, w_{s_1} biểu diễn vectơ trọng số của nút s_1, a_{max} là hằng số tuổi chuẩn hóa tối đa, và $\|\cdot\|_2$ thể hiện chuẩn Euclid hai. Cơ chế này đảm bảo những nút lâu năm không liên tục tích lũy lỗi do nhiễu ngẫu nhiên, giúp cấu trúc đồ thị duy trì sự ổn định qua thời gian.

3.5.2 Kiểm tra chồng lấp Bounding Box kiểm soát liên kết cạnh

Cơ chế kiểm tra chồng lấp hộp giới hạn ngăn chặn việc kết nối nhầm lẫn giữa hai cụm khuyết tật riêng biệt nằm gần nhau trong không gian đặc trưng. Phép tạo cạnh nối truyền thống chỉ dựa trên khoảng cách giữa hai nút chiến thắng có thể vô tình gộp hai loại lỗi có bản chất hình thái khác nhau thành một cụm duy nhất.

Đối với mỗi cụm nút C_k trên đồ thị, một hộp giới hạn đa chiều $BB(C_k)$ được xác định bởi giá trị cực tiểu và cực đại của tọa độ các nút thuộc cụm đó. Tỷ lệ chồng lấp $O(C_a, C_b)$ giữa hai hộp giới hạn của cụm C_a và cụm C_b được tính toán theo Công thức 3.21:

$$O(C_a, C_b) = \frac{\text{Thể tích}(BB(C_a) \cap BB(C_b))}{\min\big(\text{Thể tích}(BB(C_a)), \text{Thể tích}(BB(C_b))\big)} \tag{3.21}$$

trong đó Thể tích$(\cdot)$ đại diện cho thể tích của hộp giới hạn trong không gian đặc trưng, và phần tử số biểu diễn thể tích phần giao nhau giữa hai hộp giới hạn.

Điều kiện thiết lập cạnh nối giữa nút $u \in C_a$ và nút $v \in C_b$ được quy định theo Công thức 3.22:

$$\text{Cho phép tạo cạnh } (u, v) \iff O(C_a, C_b) \geq \theta_{overlap} \tag{3.22}$$

trong đó $\theta_{overlap}$ là ngưỡng chồng lấp tối thiểu bắt buộc. Nếu tỷ lệ chồng lấp $O(C_a, C_b)$ nhỏ hơn ngưỡng $\theta_{overlap}$, phép kết nối cạnh giữa hai nút bị loại bỏ, bảo toàn sự phân tách độc lập giữa hai lớp khuyết tật riêng biệt.

3.5.3 Cơ chế trì hoãn chèn dựa trên bằng chứng và học cục bộ

Cơ chế trì hoãn chèn dựa trên bằng chứng và học cục bộ giải quyết vấn đề chèn nút nhiễu khi dòng dữ liệu xuất hiện các điểm ngoại lệ đơn lẻ. Thay vì lập tức tạo nút mới khi gặp một mẫu dữ liệu nằm xa các nút hiện có, thuật toán lưu giữ mẫu dữ liệu đó vào một bộ đệm tạm thời để thu thập đủ bằng chứng mật độ trước khi tái cấu trúc tô-pô cục bộ [30].

Khi khoảng cách cực tiểu từ một vectơ đặc trưng mới f_{defect} đến nút gần nhất vượt quá ngưỡng phân tách T_{p2}, điểm dữ liệu này được đưa vào vùng đệm lưu trữ tạm thời B_r tương ứng với vùng không gian r. Ngưỡng quyết định việc khởi tạo quá trình huấn luyện cục bộ dựa trên số lượng bằng chứng tích lũy được xác định theo Công thức 3.23:

$$|B_r| \geq N_{evidence} \tag{3.23}$$

trong đó $|B_r|$ đại diện cho số lượng mẫu đặc trưng hiện có trong bộ đệm B_r, và $N_{evidence}$ là hằng số ngưỡng bằng chứng tối thiểu bắt buộc để xác nhận một cụm lỗi mới.

Khi điều kiện trong Công thức 3.23 được thỏa mãn, thuật toán tiến hành quá trình huấn luyện cục bộ trên tập hợp các mẫu dữ liệu thuộc B_r. Trọng số của nút mới w_{new} được khởi tạo tại tâm của tập bằng chứng B_r theo Công thức 3.24:

$$w_{new} = \frac{1}{|B_r|} \sum_{x_j \in B_r} x_j \tag{3.24}$$

trong đó x_j đại diện cho vectơ đặc trưng thứ j nằm trong bộ đệm B_r. Sau khi nút mới được khởi tạo và kết nối với các nút lân cận thích hợp, bộ đệm B_r được xóa rỗng để sẵn sàng thu thập bằng chứng cho các chu kỳ tiếp theo v.v...

3.5.4 Phát triển cấu trúc nhạy mật độ

Cơ chế phát triển cấu trúc nhạy mật độ ngăn ngừa sự gia tăng số lượng nút quá mức tại các vùng đặc trưng có mật độ cao nhưng độ biến động nhỏ. Các thuật toán khí tăng trưởng truyền thống thường chèn nút mới tại vị trí có lỗi tích lũy lớn nhất mà không kiểm tra mật độ phân bố xung quanh, dẫn đến hiện tượng dư thừa nút và lãng phí bộ nhớ tính toán.

Mật độ nút cục bộ ρ_q tại nút có lỗi tích lũy cao nhất q được tính toán dựa trên khoảng cách trung bình đến các nút lân cận trực tiếp theo Công thức 3.25:

$$\rho_q = \frac{|N_q|}{\sum_{n \in N_q} \|w_q - w_n\|_2 + \epsilon_0} \tag{3.25}$$

trong đó N_q là tập hợp các nút lân cận trực tiếp có liên kết cạnh với nút q, $|N_q|$ đại diện cho số lượng nút lân cận, w_q và w_n lần lượt là vectơ trọng số của nút q và nút n, còn ϵ_0 là hằng số dương cực tiểu ngăn ngừa lỗi chia cho số không.

Quyết định chèn nút mới giữa nút q và nút lân cận f có lỗi lớn nhất được kiểm soát bởi điều kiện mật độ theo Công thức 3.26:

$$\text{Phép chèn được thực hiện khi } \rho_q < \rho_{thresh} \tag{3.26}$$

trong đó ρ_{thresh} là ngưỡng mật độ tối đa cho phép chèn nút. Nếu $\rho_q \geq \rho_{thresh}$, thuật toán bỏ qua việc chèn nút mới và thay vào đó thực hiện phân bổ lại lỗi tích lũy của nút q cho các nút lân cận nhằm ổn định mạng mà không gia tăng quy mô đồ thị.

3.5.5 Phân loại cụm lỗi bằng thuật toán Connected-Component trên đồ thị EAGNG

Sau khi cấu trúc đồ thị EAGNG được cập nhật trực tuyến, việc xác định các lớp khuyết tật dựa trên thuật toán tìm thành phần liên kết trên đồ thị vô hướng $G = (V, E)$. Mỗi thành phần liên kết cô lập đại diện cho một cụm khuyết tật có hình thái đặc trưng riêng biệt trên bề mặt màn hình điện thoại [31].

Tập hợp các cụm khuyết tật $\mathcal{C} = \{C_1, C_2, \ldots, C_K\}$ được trích xuất sao cho thỏa mãn hai điều kiện tô-pô cơ bản theo Công thức 3.27:

$$\bigcup_{i=1}^{K} C_i = V \quad \text{và} \quad C_i \cap C_j = \emptyset \quad \forall i \neq j \tag{3.27}$$

trong đó V đại diện cho tập hợp tất cả các nút trong đồ thị EAGNG, E biểu diễn tập hợp các cạnh nối giữa các nút, và K là tổng số cụm khuyết tật tự động phát hiện được tại thời điểm hiện tại.

Phương pháp phân cụm dựa trên đồ thị này loại bỏ yêu cầu phải khai báo trước số lượng cụm mục tiêu. Khi xuất hiện dạng khuyết tật hoàn toàn mới trên dây chuyền sản xuất, thuật toán EAGNG tự động hình thành các nút và thành phần liên kết mới, giúp hệ thống thích ứng linh hoạt với những biến đổi thực tế.

3.5.6 Thuật toán tổng thể và Mã giả EAGNG

Thuật toán EAGNG tổng thể hợp nhất bốn cơ chế cải tiến vào một quy trình xử lý luồng dữ liệu liên tục. Quá trình vận hành của thuật toán được trình bày chi tiết trong Thuật toán 1.

Thuật toán 1: Thuật toán phân cụm lỗi trực tuyến EAGNG

Require: Dòng đặc trưng f_{defect}, tập nút V, tập cạnh E, các tham số $\epsilon_{b0}, \epsilon_{n0}, N_{evidence}, \rho_{thresh}, \theta_{overlap}$.

Ensure: Tập các cụm khuyết tật $\mathcal{C} = \{C_1, C_2, \ldots, C_K\}$.

while có mẫu dữ liệu đầu vào f_{defect} **do**
  Tìm hai nút $s_1, s_2 \in V$ gần f_{defect} nhất theo chuẩn Euclid;
  if $\|f_{defect} - w_{s_1}\|_2 > T_{p2}$ **then**
    Thêm f_{defect} vào bộ đệm B_r;
    if $|B_r| \geq N_{evidence}$ **then**
      Khởi tạo nút mới w_{new} theo Công thức 3.24;
      $V \leftarrow V \cup \{new\}$; Xóa bộ đệm B_r;
    end if
  else
    Cập nhật tuổi tất cả các cạnh nối với s_1: $a_{(s_1,n)} \leftarrow a_{(s_1,n)} + 1$;
    Tính tốc độ học $\epsilon_b(a_{s_1})$ và $\epsilon_n(a_n)$ theo Công thức 3.18 và 3.19;
    $w_{s_1} \leftarrow w_{s_1} + \epsilon_b(a_{s_1})(f_{defect} - w_{s_1})$;
    $w_n \leftarrow w_n + \epsilon_n(a_n)(f_{defect} - w_n), \quad \forall n \in N_{s_1}$;
    Tính tích lũy lỗi ΔA_{s_1} theo Công thức 3.20;
    if chưa có cạnh (s_1, s_2) **then**
      Kiểm tra điều kiện chồng lấp $O(C_{s_1}, C_{s_2}) \geq \theta_{overlap}$ theo Công thức 3.22;
      if Thỏa mãn điều kiện **then**
        $E \leftarrow E \cup \{(s_1, s_2)\}$;
        Tái lập tuổi cạnh $a_{(s_1,s_2)} \leftarrow 0$;
      end if
    else
      Tái lập tuổi cạnh $a_{(s_1,s_2)} \leftarrow 0$;
    end if

if đến chu kỳ kiểm tra chèn nút và $\rho_{s_1} < \rho_{thresh}$ **then**

Tìm nút lân cận $u \in N_{s_1}$ có lỗi lớn nhất và chèn nút mới giữa s_1 và u;

end if

Loại bỏ các cạnh có tuổi vượt quá a_{max} và các nút cô lập không có liên kết;

end if

end while

Áp dụng thuật toán Connected-Component trích xuất tập cụm lỗi $\mathcal{C}$ theo Công thức 3.27;

return Tập cụm khuyết tật $\mathcal{C}$.

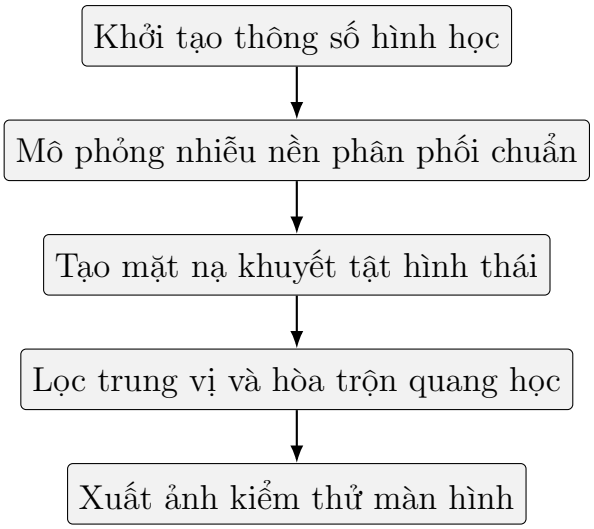
3.6 Công cụ tự động sinh tập dữ liệu khuyết tật mô phỏng

Thuật toán phân cụm trực tuyến EAGNG yêu cầu một cơ chế kiểm thử tính thích ứng trước các biến đổi đột ngột và liên tục của dòng dữ liệu đầu vào. Do việc thu thập các hình ảnh lỗi thực tế trên dây chuyền sản xuất màn hình điện thoại thường gặp hạn chế về số lượng và sự đa dạng của các dạng khuyết tật, công cụ sinh dữ liệu tự động thích nghi đã được phát triển nhằm mục đích chủ động tạo ra các tập dữ liệu mô phỏng theo mô hình thống kê học [12]. Mô hình này thực hiện việc tổng hợp ngẫu nhiên các cấu trúc nhiễu nền của màn hình chuẩn kết hợp với sự chèn lặp các dạng lỗi hình thái có kiểm soát về vị trí, kích thước và độ tương phản quang học.

Luận văn đề xuất quy trình tự động sinh dữ liệu hình ảnh được chia thành hai giai đoạn tính toán chính bao gồm giai đoạn mô phỏng nền màn hình và giai đoạn tổng hợp khuyết tật. Quy trình xử lý tổng thể của công cụ sinh dữ liệu được thể hiện trong Hình 3.3.

Sơ đồ trong Hình 3.3 minh họa các bước tính toán nối tiếp nhau nhằm tạo ra một hình ảnh màn hình hoàn chỉnh. Quá trình bắt đầu từ việc xác định các tham số không gian, tiếp tục qua việc tạo cấu trúc bề mặt bằng phân phối thống kê, sau đó vẽ mặt nạ khuyết tật và cuối cùng áp dụng bộ lọc mờ trung vị để đảm bảo tính liên tục của ranh giới điểm ảnh.

Trong giai đoạn mô phỏng nền màn hình, độ sáng của mỗi điểm ảnh tại tọa độ (r, c) trên khung hình kích thước $H \times W$ điểm ảnh được tính toán kết hợp giữa thành



Hình 3.3: Mô hình quy trình tổng hợp hình ảnh khuyết tật màn hình mô phỏng.

phần biến ngẫu nhiên theo phân phối chuẩn và thành phần ngẫu nhiên động. Công thức (3.28) biểu diễn mô hình toán học tạo mức xám nền cho ảnh:

$$I_{bg}(r,c) = \text{clip}\left(0.8 \cdot \eta(r,c) + 0.2 \cdot [B_{min} + U \cdot (B_{max} - B_{min})], 0, 255\right) \tag{3.28}$$

Trong Công thức (3.28), ký hiệu $\eta(r,c) \sim \mathcal{N}(\mu, \sigma^2)$ đại diện cho mẫu ngẫu nhiên thu được từ phân phối chuẩn với giá trị trung bình $\mu = 215$ và độ lệch chuẩn $\sigma \in \{5, 7\}$, biến số $U \sim \mathcal{U}(0,1)$ đại diện cho biến ngẫu nhiên phân phối đều trong khoảng từ zero đến một, và toán hàm $\text{clip}(x, 0, 255)$ thực hiện việc ép giá trị điểm ảnh nằm trong miền giới hạn mức xám từ 0 đến 255 theo chuẩn biểu diễn số nguyên tám bit. Các ngưỡng biên động B_{min} và B_{max} trong Công thức (3.28) được xác định dựa trên Công thức (3.29):

$$B_{min} = \max(0, \mu - 4\sigma), \quad B_{max} = \min(255, \mu + 3\sigma) \tag{3.29}$$

Công thức (3.29) đảm bảo rằng thành phần độ sáng nền duy trì tính ổn định thống kê nhưng vẫn tạo ra sự biến thiên nhẹ giữa các khung hình nhằm mô phỏng nhiễu cảm biến quang học thực tế. Khi khởi tạo hình ảnh đạt tiêu chuẩn, giá trị độ lệch chuẩn $\sigma = 7$ được áp dụng để mô phỏng nhiễu phân tán rộng, trong khi hình ảnh chứa lỗi sử dụng giá trị $\sigma = 5$.

Đối với giai đoạn tạo khuyết tật, vị trí trung tâm (x_d, y_d) của vùng lỗi được khống chế trong vùng không gian hiển thị an toàn nhằm tránh hiện tượng khuyết tật bị cắt đứt tại biên khung ảnh. Giới hạn tọa độ được mô tả qua Công thức (3.30):

$$x_d \in [\alpha_x W, (1-\alpha_x)W], \quad y_d \in [\alpha_y H, (1-\alpha_y)H] \tag{3.30}$$

Trong Công thức (3.30), thông số $\alpha_x = 0.15$ và $\alpha_y = 0.15$ đại diện cho tỷ lệ khoảng lùi tương đối so với chiều rộng $W = 540$ điểm ảnh và chiều cao $H = 1170$ điểm ảnh của màn hình. Kích thước bán kính đặc trưng của vết lỗi được tính toán dựa trên đường kính tối thiểu $D_{min} = \min(H, W)$ nhân với các tỷ lệ bán kính giới hạn trong khoảng từ 0.03 đến 0.08.

Công cụ hỗ trợ tổng hợp năm hình thái khuyết tật chính bao gồm: (i) hình tròn, (ii) hình tam giác, (iii) hình chữ nhật, (iv) đường thẳng ngang và (v) đường thẳng dọc. Mức độ nghiêm trọng của khuyết tật được phân thành bốn cấp độ thông qua hệ số tỷ lệ cường độ γ_{level} bao gồm: (i) cấp độ rất thấp với $\gamma_{level} \in [0.01, 0.03]$, (ii) cấp độ thấp với $\gamma_{level} \in [0.03, 0.06]$, (iii) cấp độ trung bình với $\gamma_{level} \in [0.07, 0.11]$, và (iv) cấp độ cao với $\gamma_{level} \in [0.12, 0.20]$.

Sau khi vẽ mặt nạ khuyết tật binary $\mathbf{M}$, quá trình hòa trộn ảnh được thực hiện thông qua toán tử cộng có trọng số kết hợp với bộ lọc trung vị thích nghi. Công thức (3.31) thể hiện phép toán tổng hợp hình ảnh cuối cùng:

$$I_{final}(r,c) = \text{clip}\left(I_{bg}(r,c) + (-1)^{\mathbb{I}_{dark}} \cdot \text{MedianBlur}\left(\mathbf{M}(r,c) \cdot \bar{I}_{bg} \cdot \gamma_{level}, k_{size}\right), 0, 255\right) \tag{3.31}$$

Trong Công thức (3.31), ký hiệu $\bar{I}_{bg}$ biểu thị giá trị độ sáng trung bình của ảnh nền, biến chỉ thị $\mathbb{I}_{dark} \in \{0, 1\}$ xác định tính chất lỗi tối hay lỗi sáng, và $\text{MedianBlur}(\cdot, k_{size})$ đại diện cho phép lọc mờ trung vị với kích thước cửa sổ $k_{size} = \max(3, 2\lfloor 0.005 D_{min} \rfloor + 1)$ nhằm triệt tiêu các góc cạnh sắc nhọn nhân tạo, giúp hình thái vết lỗi tiệm cận với khuyết tật vật lý tự nhiên [32].

Mã nguồn thực thi quá trình sinh dữ liệu ảnh thích nghi được cài đặt với thư viện xử lý ảnh OpenCV được thể hiện chi tiết trong Thuật toán 2.

Thuật toán 2: Thuật toán sinh ảnh khuyết tật thích nghi.

Require: Ảnh đầu vào I, phân phối chuẩn $\mathcal{N}(\mu, \sigma^2)$, loại khuyết tật T, mức độ L, trạng thái lỗi sáng B

Ensure: Ảnh đầu ra I_{final}

1: Khởi tạo ma trận điểm ảnh P kích thước $H \times W$

2: $B_{\min} \leftarrow \max(0, \mu - 4\sigma)$

$B_{\max} \leftarrow \min(255, \mu + 3\sigma)$
for $r \leftarrow 0$ **to** $H - 1$ **do**
    for $c \leftarrow 0$ **to** $W - 1$ **do**
        $s \leftarrow \text{NormalRandom}(\mu, \sigma)$
        $u \leftarrow \text{UniformRandom}(0, 1)$
        $d \leftarrow B_{\min} + u(B_{\max} - B_{\min})$
        $P[r, c] \leftarrow \text{Clip}(0.8s + 0.2d, 0, 255)$
    end for
end for
$I_{\text{bg}} \leftarrow \text{CreateImage}(P)$
if I chứa khuyết tật **then**
    $(x_d, y_d) \leftarrow \text{CalculateBoundedPoint}()$
    $\rho \leftarrow \text{GetScaleRatio}(L)$
    $A \leftarrow \text{Mean}(I_{\text{bg}}) \times \rho$
    $M \leftarrow \text{DrawDefectMask}(T, x_d, y_d, A)$
    $k \leftarrow \text{GetAdaptiveKernelSize}()$
    $M \leftarrow \text{MedianBlur}(M, k)$
    if $B = \text{TRUE}$ **then**
        $w \leftarrow 1$
    else
        $w \leftarrow -1$
    end if
    $I_{\text{final}} \leftarrow \text{Clip}(I_{\text{bg}} + wM, 0, 255)$
else
    $I_{\text{final}} \leftarrow I_{\text{bg}}$
end if
return I_{final}

Thuật toán 2 thể hiện sự tương quan trực tiếp với các mô hình toán học đã được thiết lập. Quá trình quét điểm ảnh hai chiều tạo ra cấu trúc nền tuân theo Công thức (3.28), trong khi các hàm tính toán trọng số cường độ và lọc mờ trung vị thực hiện chính xác các phép toán được mô tả trong Công thức (3.31). Việc tích hợp dịch vụ sinh ảnh tự động này cho phép hệ thống chủ động tạo ra hàng chục nghìn mẫu kiểm thử với các kịch bản trôi dạt khái niệm phức tạp, tạo tiền đề vững chắc cho việc đánh giá độ bền vững của thuật toán EAGNG trong các chương tiếp

theo.

Kết luận Chương 3

Chương 3 đã xây dựng hoàn chỉnh cơ sở lý thuyết, kiến trúc hệ thống và thuật toán đề xuất cho bài toán phát hiện bất thường và phân cụm khuyết tật màn hình điện thoại. Bằng việc kết hợp hai pha xử lý nối tiếp, hệ thống đã tối ưu hóa được năng lực tính toán thông qua cơ chế lọc bỏ mẫu đạt chuẩn ở Pha 1 trước khi tiến hành phân loại chuyên sâu ở Pha 2. Kỹ thuật ghép kênh entropy cục bộ vào dữ liệu ảnh nguyên bản đã nâng cao độ nhạy của hệ thống đối với các khuyết tật có độ tương phản thấp trên bề mặt sản phẩm.

Đóng góp lý thuyết quan trọng nhất của chương nằm ở thuật toán Mạng khí Nơ-ron tăng trưởng tích lũy bằng chứng với bốn cơ chế cải tiến đồng bộ. Sự kết hợp giữa động lực tuổi nút, cơ chế hoãn chèn dựa trên bằng chứng, kiểm soát mật độ phát triển nút và điều kiện chồng lấp hộp giới hạn đã giải quyết triệt để các hạn chế về nhiễu dữ liệu và bùng nổ cấu trúc của mô hình truyền thống. Kết quả phân cụm dựa trên thành phần liên kết đồ thị cho phép hệ thống tự động thích ứng với các dạng lỗi mới phát sinh mà không cần quy định trước số lượng cụm khuyết tật. Các mô hình toán học và thiết kế thuật toán trong chương này là nền tảng để tiến hành xây dựng kịch bản thực nghiệm, đánh giá định lượng và đối sánh hiệu năng trong Chương 4.

Chương 4

Kết quả thực nghiệm và Đánh giá

Chương này trình bày toàn diện các kết quả thu được từ quá trình nghiên cứu và triển khai hệ thống. Nội dung được tổ chức thành ba phần chính: đầu tiên là mô tả ứng dụng demo thực tế đã được xây dựng; tiếp theo là các kết quả thực nghiệm chi tiết về khả năng sinh dữ liệu, trích xuất đặc trưng và học liên tục; cuối cùng là các phân tích so sánh định lượng để làm rõ hiệu quả của các cải tiến đề xuất so với các phương pháp cơ sở.

4.1 Thiết lập thực nghiệm và Kịch bản đánh giá trôi dạt khái niệm

Thực nghiệm được thiết lập nhằm đánh giá khả năng học trực tuyến và độ ổn định cấu trúc của thuật toán EAGNG trên dòng dữ liệu khuyết tật màn hình điện thoại. Toàn bộ kịch bản kiểm thử được xây dựng theo tiêu chuẩn kiểm tra công nghiệp, bảo đảm tính thống nhất về môi trường tính toán, phương pháp trích xuất đặc trưng và hệ thống chỉ số đo lường.

4.1.1 Môi trường thực nghiệm và Cơ sở hạ tầng tính toán

Môi trường phần cứng tính toán đóng vai trò quyết định đến độ tin cậy của việc đo lường thời gian xử lý trực tuyến. Hệ thống thực nghiệm được triển khai trên máy tính cấu hình bao gồm vi xử lý Intel Core i5-13400F, bộ nhớ truy cập ngẫu nhiên 16 gigabyte và bộ xử lý đồ họa NVIDIA GeForce RTX 3060 dung lượng 12 gigabyte. Cơ sở hạ tầng phần cứng này bảo đảm năng lực tính toán song song cho quá trình trích xuất đặc trưng và mô phỏng dòng dữ liệu thời gian thực.

Nền tảng phần mềm được xây dựng trên hệ điều hành Windows 11 nhằm duy trì tính đồng nhất trong quá trình thu thập dữ liệu. Môi trường tính toán sử dụng thư viện PyTorch phiên bản 2.13.0 kết hợp với thư viện Scikit-Learn phiên bản 1.9.0 cho các tác vụ xử lý ma trận và tính toán chỉ số phân cụm. Cấu hình chi tiết của cơ sở hạ tầng tính toán được tổng hợp trong Bảng 4.1.

Hệ thống chỉ số đánh giá được thiết lập bao quát cả ba khía cạnh bao gồm chất lượng phân cụm, độ ổn định cấu trúc tô-pô và hiệu năng thời gian thực. Chất lượng

Bảng 4.1: Thống kê thông số môi trường phần cứng và phần mềm thực nghiệm.

Thành phần hệ thống	Thông số kỹ thuật
Vi xử lý	Intel Core i5-13400F
Bộ nhớ ngẫu nhiên RAM	16 GB DDR4
Bộ xử lý đồ họa GPU	NVIDIA GeForce RTX 3060 12 GB
Hệ điều hành	Windows 11
Môi trường phần mềm	PyTorch 2.13.0, Scikit-Learn 1.9.0

phân cụm trực tuyến được định lượng thông qua ba chỉ số độc lập là chỉ số Rand điều chỉnh, thông tin tương hỗ chuẩn hóa và độ tinh khiết phân cụm.

Chỉ số Rand điều chỉnh đo lường mức độ tương đồng giữa kết quả phân cụm thu được và nhãn thực tế của dữ liệu, loại bỏ yếu tố trùng khớp ngẫu nhiên [33]. Công thức 4.1 biểu diễn phép tính chỉ số Rand điều chỉnh:

$$ARI = \frac{\sum_{ij}\binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2}\sum_j \binom{b_j}{2}\right]/\binom{n}{2}}{\frac{1}{2}\left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}\right] - \left[\sum_i \binom{a_i}{2}\sum_j \binom{b_j}{2}\right]/\binom{n}{2}} \tag{4.1}$$

Trong Công thức 4.1, ký hiệu n_{ij} đại diện cho số lượng mẫu dữ liệu thuộc cùng cụm thứ i và nhãn thực tế thứ j, ký hiệu a_i thể hiện tổng số mẫu trong cụm i, ký hiệu b_j đại diện cho tổng số mẫu mang nhãn j, và ký hiệu n biểu thị tổng số mẫu dữ liệu trong dòng học tính đến thời điểm đánh giá.

Thông tin tương hỗ chuẩn hóa đánh giá lượng thông tin chia sẻ giữa cấu trúc phân cụm của mô hình và tập nhãn thực tế [34]. Giá trị thông tin tương hỗ chuẩn hóa được xác định theo Công thức 4.2:

$$NMI(Y, C) = \frac{2 \cdot I(Y; C)}{H(Y) + H(C)} \tag{4.2}$$

Trong Công thức 4.2, ký hiệu $I(Y; C)$ biểu thị lượng thông tin tương hỗ giữa tập nhãn thực tế Y và tập cụm dự đoán C, trong khi ký hiệu $H(Y)$ và $H(C)$ đại diện cho độ dư thừa thông tin của tập nhãn thực tế và tập cụm thu được.

Độ tinh khiết phân cụm đo tỷ lệ phần trăm mẫu dữ liệu thuộc về lớp chiếm ưu thế nhất trong mỗi cụm thu được. Phép tính độ tinh khiết phân cụm được mô tả cụ thể trong Công thức 4.3:

$$Purity(Y, C) = \frac{1}{N}\sum_k \max_j |c_k \cap y_j| \tag{4.3}$$

Trong Công thức 4.3, ký hiệu N biểu thị tổng số mẫu dữ liệu xử lý, ký hiệu c_k đại diện cho tập hợp các mẫu trong cụm thứ k, và ký hiệu y_j đại diện cho tập hợp các mẫu có nhãn thực tế thứ j.

Mức độ ổn định cấu trúc tô-pô và khả năng kháng hiện tượng quên thảm họa được đo lường thông qua độ dời Euclid cấp hai trung bình của tập nút mạng qua các bước cập nhật dòng dữ liệu. Công thức 4.4 xác định độ dời của tập nút:

$$\Delta W = \frac{1}{|V_t|} \sum_{v \in V_t} \min_{u \in V_{t-1}} \|w_v^{(t)} - w_u^{(t-1)}\|_2 \tag{4.4}$$

Trong Công thức 4.4, ký hiệu V_t đại diện cho tập hợp nút mạng tại bước thời gian t, ký hiệu V_{t-1} đại diện cho tập hợp nút tại bước thời gian liền trước, ký hiệu $w_v^{(t)}$ biểu diễn véc-tơ trọng số của nút v ở thời điểm t, và ký hiệu $w_u^{(t-1)}$ đại diện cho véc-tơ trọng số của nút u ở thời điểm $t-1$.

Hiệu năng xử lý thời gian thực được định lượng thông qua chỉ số thời gian nhịp sản xuất trung bình trên mỗi mẫu dữ liệu. Phép tính thời gian nhịp sản xuất được thiết lập theo Công thức 4.5:

$$Takt = \frac{T_{total}}{N_{samples}} \times 1000 \tag{4.5}$$

Trong Công thức 4.5, ký hiệu T_{total} biểu thị tổng thời gian tích lũy dành cho quá trình cập nhật mô hình tính bằng giây, ký hiệu $N_{samples}$ đại diện cho số lượng mẫu đã xử lý, và giá trị $Takt$ trả về đơn vị mili-giây trên một mẫu.

4.1.2 Cấu hình tham số thực nghiệm và thuật toán EAGNG

Tập hợp các tham số thực nghiệm được thiết lập dựa trên kết quả thăm dò kiểm thử nhằm bảo đảm sự cân bằng giữa độ chính xác phân cụm và tốc độ xử lý thời gian thực. Các tham số hệ thống được phân chia thành ba nhóm chức năng chính bao gồm (i) nhóm tham số trích xuất đặc trưng và mô hình mã hóa tự động, (ii) nhóm tham số phát hiện bất thường ngoại tuyến, và (iii) nhóm tham số điều khiển tiến trình học động của thuật toán EAGNG.

Trong nhóm tham số trích xuất đặc trưng, ảnh bề mặt màn hình điện thoại được chuẩn hóa về kích thước 128×128 pixel. Cửa sổ tính toán bản đồ độ hỗn loạn cục bộ sử dụng kích thước 9×9 pixel với bán kính phần tử cấu trúc dạng đĩa bằng 4 pixel. Mô hình mã hóa tự động nén đặc trưng bốn kênh về véc-tơ không gian ẩn có chiều $d = 64$. Quá trình huấn luyện mô hình mã hóa tự động được thực hiện

với tốc độ học $\eta_{ae} = 10^{-3}$, kích thước lô dữ liệu $B = 64$ và số chu kỳ huấn luyện $E_{ae} = 10$.

Trong nhóm tham số phát hiện bất thường ngoại tuyến, mô hình biểu diễn phân phối sản phẩm đạt chuẩn được huấn luyện trong 10 chu kỳ. Ngưỡng phân định sản phẩm bất thường dựa trên quy tắc ba lần độ lệch chuẩn với hệ số $\lambda_\sigma = 3{,}0$. Bộ nhớ đệm dành cho các mẫu dữ liệu khuyết tật phát sinh được thiết lập với dung lượng lưu trữ tối đa $S_{buf} = 1000$ mẫu.

Nhóm tham số điều khiển thuật toán EAGNG quy định các cơ chế cập nhật cấu trúc đồ thị và thích ứng trực tuyến. Đồ thị nơ-ron có giới hạn số lượng nút tối đa $N_{max} = 500$ nút và tuổi thọ tối đa của cạnh nối được thiết lập $a_{max} = 50$ bước thời gian. Chu kỳ sinh nút mới theo mức tích lũy sai số được định cấu hình sau mỗi $\lambda = 50$ bước lặp với hệ số chia sai số nút $\alpha = 0{,}5$ và hệ số suy giảm sai số toàn cục $\beta = 0{,}005$. Tốc độ học của nút chiến thắng và các nút lân cận lần lượt nhận giá trị $e_b = 0{,}1$ và $e_n = 0{,}001$.

Các cơ chế cải tiến chuyên biệt trong thuật toán EAGNG được điều khiển bởi các tham số không gian và thời gian. Bán kính quét vùng dữ liệu mới được thiết lập $R_{scan} = 10{,}0$, đòi hỏi tối thiểu $K_{spawn} = 10$ mẫu trong bộ đệm để kích hoạt tiến trình sinh nút và huấn luyện cục bộ trong $E_{local} = 20$ chu kỳ với chu kỳ chèn nút cục bộ $\lambda_{local} = 10$. Giới hạn mật độ cục bộ sử dụng khoảng cách tối thiểu $d_{min} = 5{,}0$ nhằm ngăn ngừa hiện tượng phân mảnh vùng biểu diễn. Hệ số suy giảm tốc độ học theo thời gian sử dụng hằng số thời gian $\tau = 1000$ bước lặp. Ngưỡng giao thoa diện tích giữa các cụm để quyết định nối cạnh được ấn định ở mức $T_{overlap} = 0{,}65$. Bảng 4.2 tổng hợp chi tiết toàn bộ tham số cài đặt trong thực nghiệm.

4.1.3 Kịch bản dòng dữ liệu khuyết tật liên tục

Bộ dữ liệu thực nghiệm được xây dựng bao gồm 3000 ảnh mô phỏng các dạng khuyết tật bề mặt màn hình điện thoại trong môi trường kiểm tra công nghiệp. Ảnh thu nhận ban đầu đạt độ phân giải 540×1170 pixel từ hệ thống máy ảnh công nghiệp chuyên dụng. Tất cả các ảnh sau đó được tiền xử lý và thu nhỏ về kích thước chuẩn 128×128 pixel để chuẩn hóa đầu vào cho quá trình trích xuất đặc trưng.

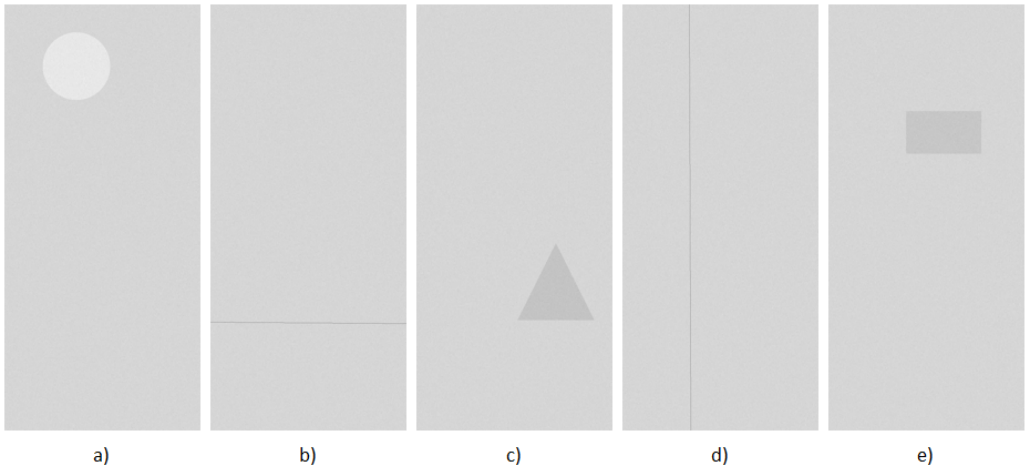
Mô hình trích xuất đặc trưng kết hợp mạng ResNet-50 [10] với thuật toán tính độ hỗn loạn cục bộ nhằm tạo lập không gian đại diện bốn kênh bao gồm ba kênh màu và một kênh độ hỗn loạn. Không gian dữ liệu này tiếp tục được nén thông qua mô

Bảng 4.2: Tổng hợp giá trị cài đặt các tham số mô hình và thuật toán EAGNG trong thực nghiệm.

Nhóm tham số	Ký hiệu	Giá trị	Ý nghĩa kỹ thuật
Trích xuất đặc trưng	-	128×128	Kích thước ảnh chuẩn hóa (pixel)
Cửa sổ entropy	-	9×9	Kích thước cửa sổ độ hỗn loạn (pixel)
Không gian ẩn	d	64	Số chiều véc-tơ biểu diễn ẩn
Tốc độ học mã hóa	η_{ae}	10^{-3}	Tốc độ học của mô hình Autoencoder
Lô huấn luyện	B	64	Kích thước lô dữ liệu Autoencoder
Ngưỡng bất thường	λ_σ	3,0	Hệ số ngưỡng phân định 3σ
Sức chứa bộ đệm	S_{buf}	1000	Số mẫu khuyết tật tối đa trong bộ đệm
Số nút tối đa	N_{max}	500	Giới hạn số nút tối đa của đồ thị
Tuổi thọ cạnh	a_{max}	50	Tuổi thọ tối đa của cạnh nối giữa các nút
Chu kỳ chèn nút	λ	50	Tần suất kiểm tra sinh nút theo sai số
Hệ số chia sai số	α	0,5	Tỷ lệ phân chia sai số khi sinh nút mới
Suy giảm sai số	β	0,005	Tỷ lệ suy giảm sai số toàn cục
Tốc độ học nút chính	e_b	0,1	Tốc độ học của nút chiến thắng
Tốc độ học lân cận	e_n	0,001	Tốc độ học của các nút lân cận
Bán kính quét vùng	R_{scan}	10,0	Ngưỡng khoảng cách nhận diện vùng mới
Số mẫu sinh nút	K_{spawn}	10	Mẫu tối thiểu trong đệm để tạo nút mới
Khoảng cách mật độ	d_{min}	5,0	Ngưỡng khoảng cách mật độ tối thiểu
Hằng số thời gian	τ	1000	Hằng số thời gian giảm tốc độ học
Ngưỡng giao thoa	$T_{overlap}$	0,65	Ngưỡng tỷ lệ giao thoa để nối cạnh

hình mạng mã hóa tự động để thu về véc-tơ đặc trưng ẩn có kích thước 64 chiều. Quy trình trích xuất này hỗ trợ cô đọng thông tin cấu trúc hình học và gia tăng độ tương phản đối với các vùng khuyết tật có biên độ xám thấp.

Tập dữ liệu bao gồm năm dạng khuyết tật hình học riêng biệt với các mức độ cường độ hiển thị khác nhau. Hình 4.1 minh họa năm loại khuyết tật bề mặt trong tập dữ liệu thực nghiệm, bao gồm: (i) dạng đường tròn tại vị trí a, (ii) dạng đường ngang tại vị trí b, (iii) dạng hình tam giác tại vị trí c, (iv) dạng đường dọc tại vị trí d, và (v) dạng hình chữ nhật tại vị trí e. Mỗi dạng khuyết tật lại được chia thành ba cấp độ cường độ hiển thị bao gồm cường độ mạnh, cường độ vừa, và cường độ yếu. Hình 4.2 biểu diễn chi tiết ba mức độ cường độ của khuyết tật dạng đường tròn, trong đó vị trí a thể hiện mức độ mạnh với độ tương phản rõ nét, vị trí b thể hiện mức độ vừa, và vị trí c thể hiện mức độ yếu với biên giới mờ nhạt so với nền màn hình.



Hình 4.1: Năm dạng khuyết tật hình học bề mặt màn hình điện thoại trong tập dữ liệu thực nghiệm.

Dòng dữ liệu học trực tuyến được thiết lập dưới dạng chuỗi xuất hiện nối tiếp của năm loại khuyết tật qua năm giai đoạn liên tiếp nhằm tạo ra hiện tượng trôi dạt khái niệm đột ngột. Bảng 4.3 trình bày chi tiết sự phân bố mẫu, phạm vi chỉ số chuỗi dữ liệu và số lượng ảnh theo từng cấp độ cường độ khuyết tật. Mỗi loại khuyết tật đóng góp 600 mẫu dữ liệu liên tục, trong đó mỗi cấp độ cường độ khuyết tật chiếm 200 mẫu. Tại các mốc chuyển giao giữa các giai đoạn dữ liệu, sự thay đổi hoàn toàn của phân bố đặc trưng buộc thuật toán EAGNG phải thích ứng linh hoạt để tự động hình thành các nút biểu diễn mới mà không làm mất đi tri thức

Hình 4.2: Ba cấp độ cường độ khuyết tật từ mạnh đến yếu đại diện cho dạng khuyết tật đường tròn.

đã tích lũy từ các giai đoạn trước.

Bảng 4.3: Thống kê chi tiết kịch bản phân bố dòng dữ liệu khuyết tật theo giai đoạn và cường độ.

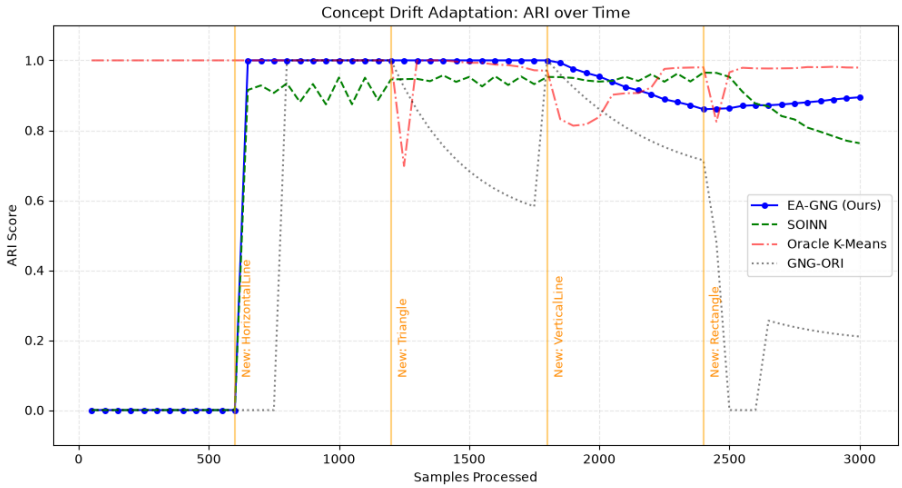
Giai đoạn	Loại khuyết tật	Cường độ khuyết tật	Phạm vi mẫu	Số lượng ảnh
1	Đường tròn	Mạnh / Vừa / Yếu	1–600	200 / 200 / 200
2	Đường ngang	Mạnh / Vừa / Yếu	601–1200	200 / 200 / 200
3	Hình tam giác	Mạnh / Vừa / Yếu	1201–1800	200 / 200 / 200
4	Đường dọc	Mạnh / Vừa / Yếu	1801–2400	200 / 200 / 200
5	Hình chữ nhật	Mạnh / Vừa / Yếu	2401–3000	200 / 200 / 200

4.2 Phân tích và Đánh giá Kết quả Thực nghiệm

Mục này trình bày kết quả thực nghiệm chi tiết đánh giá thuật toán Mạng Khí Nơ-ron Tăng trưởng Tích lũy Bằng chứng (Evidence-Accumulating Growing Neural Gas - EAGNG) trong bài toán phân loại lỗi tự động trên màn hình điện thoại. Việc đánh giá được thực hiện thông qua bốn nội dung chính bao gồm: (i) khả năng thích ứng với dịch chuyển khái niệm (Concept Drift), (ii) độ ổn định cấu trúc và hiện tượng quên thảm họa, (iii) thời gian xử lý và tốc độ thực thi, và (iv) hiệu quả phân cụm không gian hình học của không gian biểu diễn lỗi.

4.2.1 Đánh giá khả năng thích ứng với dịch chuyển khái niệm

Khả năng thích ứng với dữ liệu chuỗi theo thời gian đóng vai trò quyết định đối với các mô hình học trực tuyến trong môi trường sản xuất công nghiệp. Thực nghiệm mô phỏng chuỗi dữ liệu gồm 3000 mẫu với bốn điểm dịch chuyển khái niệm tại các thời điểm mẫu thứ 600, 1200, 1800, và 2400, tương ứng với sự xuất hiện của các dạng lỗi mới như đường kẻ ngang, hình tam giác, đường kẻ dọc, và hình chữ nhật. Kết quả đánh giá chỉ số điều chỉnh Rand (Adjusted Rand Index - ARI) thể hiện sự vượt trội của phương pháp đề xuất so với các thuật toán cơ sở.

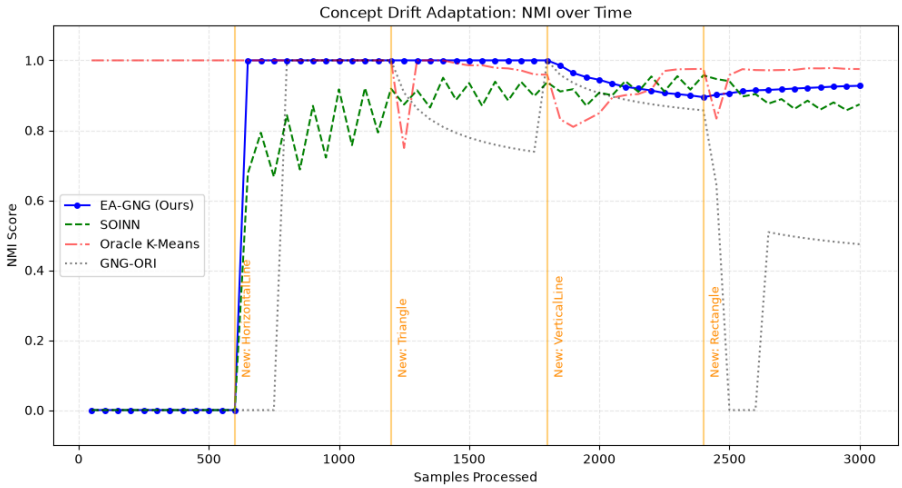


Hình 4.3: Sự biến thiên của chỉ số điều chỉnh Rand theo thời gian khi xuất hiện các dạng lỗi mới.

Ghi chú: Đường nét liền màu xanh thể hiện phương pháp EAGNG, đường nét đứt màu xanh lá thể hiện SOINN, đường chấm chấm màu xám thể hiện GNG truyền thống, và đường gạch chấm màu đỏ thể hiện Oracle K-Means.

Như thể hiện trong Hình 4.3, chỉ số điều chỉnh Rand của thuật toán EAGNG nhanh chóng hội tụ về giá trị xấp xỉ 100% ngay sau khi xuất hiện các dạng lỗi mới tại thời điểm 600, 1200, và 1800. Đối với phương pháp GNG truyền thống [7], chỉ số Rand suy giảm nghiêm trọng sau thời điểm 2400, rơi xuống mức 21,0% tại thời điểm 3000 do hiện tượng nhiễu cấu trúc và không thể tách biệt các cụm lỗi trùng lặp. Phương pháp SOINN [35] duy trì được tính ổn định tương đối nhưng chỉ đạt chỉ số Rand bằng 76,3% tại bước 3000, do cơ chế thiết lập ngưỡng bán kính cố định dẫn đến việc chia nhỏ các cụm lỗi tự nhiên.

Chỉ số thông tin tương hỗ chuẩn hóa (Normalized Mutual Information - NMI) tiếp



Hình 4.4: Sự biến thiên của chỉ số thông tin tương hỗ chuẩn hóa theo chuỗi thời gian xử lý mẫu.

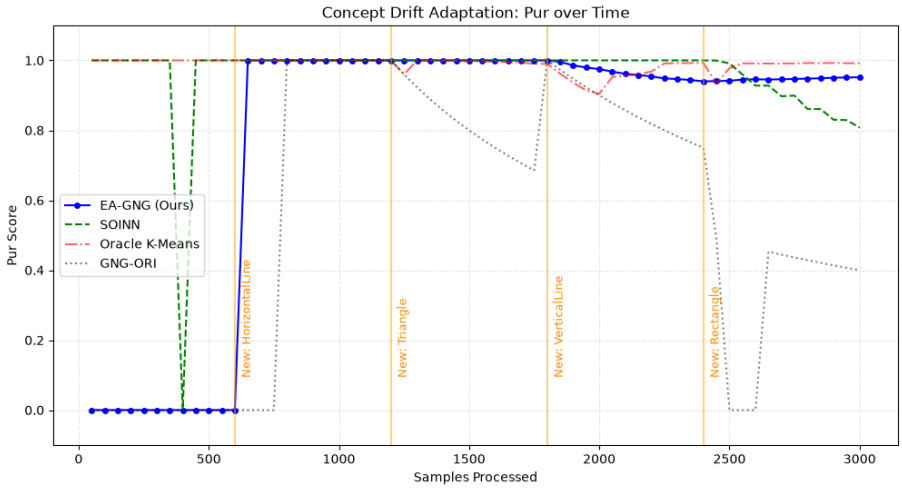
Ghi chú: Đánh giá khả năng bảo toàn thông tin phân cụm giữa kết quả của mô hình và nhãn thực tế.

tục phản ánh khả năng phân tách cụm chính xác của mạng EAGNG trong suốt quá trình xử lý luồng dữ liệu. Hình 4.4 minh họa diễn biến chỉ số NMI giữa các phương pháp so sánh. Mạng EAGNG đạt chỉ số NMI duy trì ở mức 92,7% tại mẫu thứ 3000, trong khi GNG truyền thống suy giảm xuống 47,4% và SOINN đạt 87,4%. Điều này chứng minh rằng cơ chế tích lũy bằng chứng giúp mô hình duy trì cấu trúc tô-pô biểu diễn chính xác thông tin phân bố của các lớp lỗi mà không bị ảnh hưởng bởi biến động nhiễu cục bộ.

Độ thuần khiết (Purity) của các cụm được khởi tạo bởi EAGNG thể hiện mức độ chính xác cao trong việc gom nhóm các mẫu lỗi có cùng bản chất kỹ thuật. Như được miêu tả ở Hình 4.5, độ thuần khiết của EAGNG đạt 95,2% tại bước cuối cùng 3000. Trái lại, phương pháp GNG truyền thống bị giảm độ thuần khiết xuống 40,0% do các nơ-ron cũ bị kéo lệch khỏi tâm phân bố gốc khi dữ liệu mới xuất hiện. Sự duy trì độ thuần khiết cao của EAGNG khẳng định hiệu quả của cơ chế điều chỉnh độ linh hoạt dựa trên bằng chứng tích lũy.

4.2.2 Phân tích độ ổn định cấu trúc và hiện tượng quên thảm họa

Hiện tượng quên thảm họa là thách thức lớn đối với các mô hình học liên tục khi tiếp nhận các phân bố dữ liệu mới. Để đánh giá mức độ suy giảm tri thức cũ,



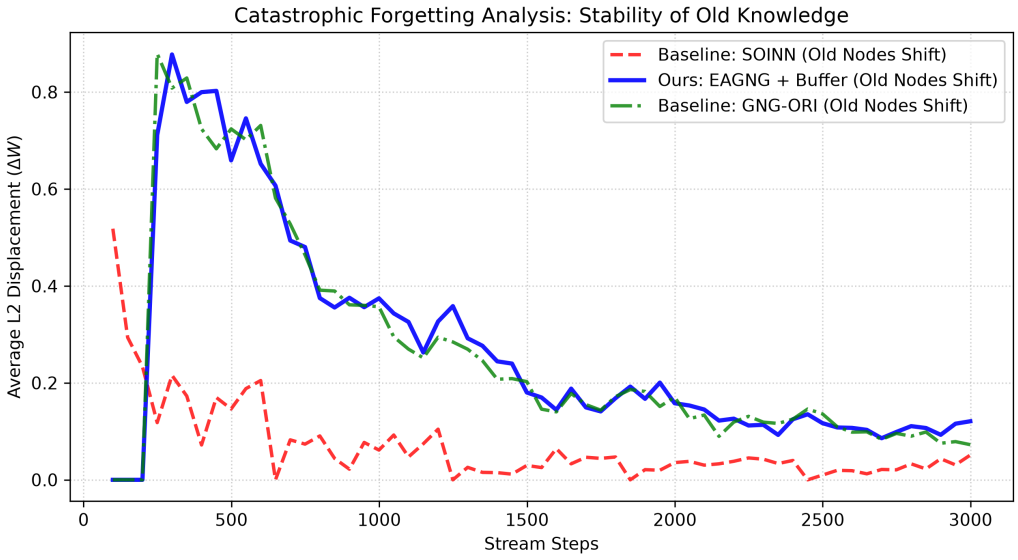
Hình 4.5: Chỉ số độ thuần khiết phân cụm của các thuật toán theo từng giai đoạn xuất hiện lỗi.

Ghi chú: Mức độ thuần khiết phản ánh tỷ lệ mẫu thuộc lớp chiếm ưu thế trong từng cụm tô-pô.

khoảng cách dịch chuyển chuẩn L2 (ΔW) của các nút đã tồn tại được đo đạc và theo dõi qua các bước cập nhật dữ liệu.

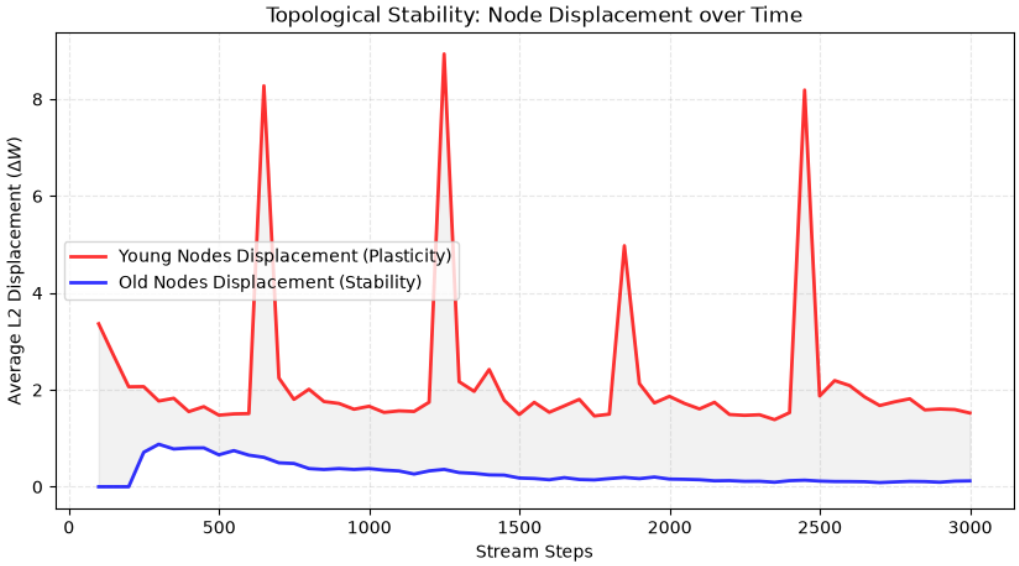
Hình 4.6 cho thấy mức độ dịch chuyển trọng số nút cũ của EAGNG kết hợp bộ đệm đạt giá trị xấp xỉ 0,10 ở giai đoạn ổn định, thấp hơn đáng kể so với hiện tượng suy biến cấu trúc trong GNG truyền thống. Thuật toán SOINN duy trì mức dịch chuyển nhỏ nhưng đổi lại phải đánh đổi bằng việc khởi tạo quá nhiều nút không cần thiết. Phương pháp EAGNG đạt được sự cân bằng giữa việc tiếp thu tri thức mới và việc bảo toàn tri thức cũ nhờ vào bộ đệm tích lũy bằng chứng.

Sự phân tách rõ rệt giữa tính linh hoạt (Plasticity) và tính ổn định (Stability) được thể hiện rõ ràng trong Công thức và cấu trúc tô-pô của EAGNG. Như miêu tả ở Hình 4.7, các nút mới (Young Nodes) đạt biên độ dịch chuyển trọng số lên tới 8,9 tại các điểm xảy ra dịch chuyển khái niệm (bước 600, 1200, 1800, 2400), cho phép mạng thích ứng nhanh chóng với dạng lỗi mới. Trong khi đó, các nút cũ (Old Nodes) duy trì độ dịch chuyển trọng số luôn dưới 0,5, đảm bảo các vùng không gian đại diện cho lỗi đã học không bị biến dạng.



Hình 4.6: So sánh độ dịch chuyển trọng số nút cũ giữa các thuật toán theo chuỗi thời gian.

Ghi chú: Giá trị độ dịch chuyển càng nhỏ thể hiện mức độ bảo toàn tri thức cũ càng cao.

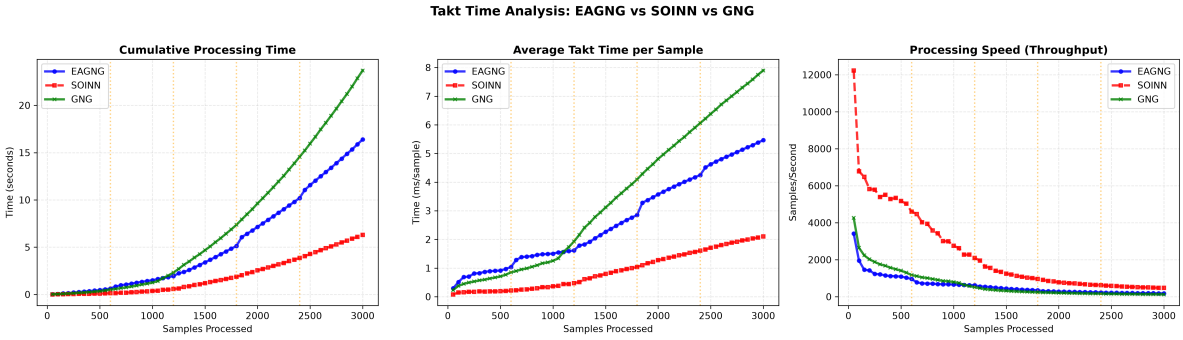


Hình 4.7: Phân tích khả năng thích ứng linh hoạt và độ ổn định tô-pô của mạng EAGNG.

Ghi chú: Đường màu đỏ biểu diễn độ dịch chuyển của các nút mới (Plasticity), đường màu xanh biểu diễn độ dịch chuyển của các nút cũ (Stability).

4.2.3 Đánh giá thời gian thực thi và tốc độ xử lý

Tốc độ xử lý của thuật toán phân loại phải đáp ứng yêu cầu thời gian nhịp sản xuất (Takt Time) của dây chuyền kiểm tra màn hình điện thoại thực tế. Các chỉ số về thời gian tích lũy, thời gian xử lý trung bình trên mỗi mẫu (Takt Time), và tốc độ xử lý số mẫu trên giây (Throughput) được đo đạc trực tiếp trên cùng một cấu hình phần cứng.



Hình 4.8: Phân tích thời gian nhịp và tốc độ xử lý của EAGNG, SOINN và GNG.

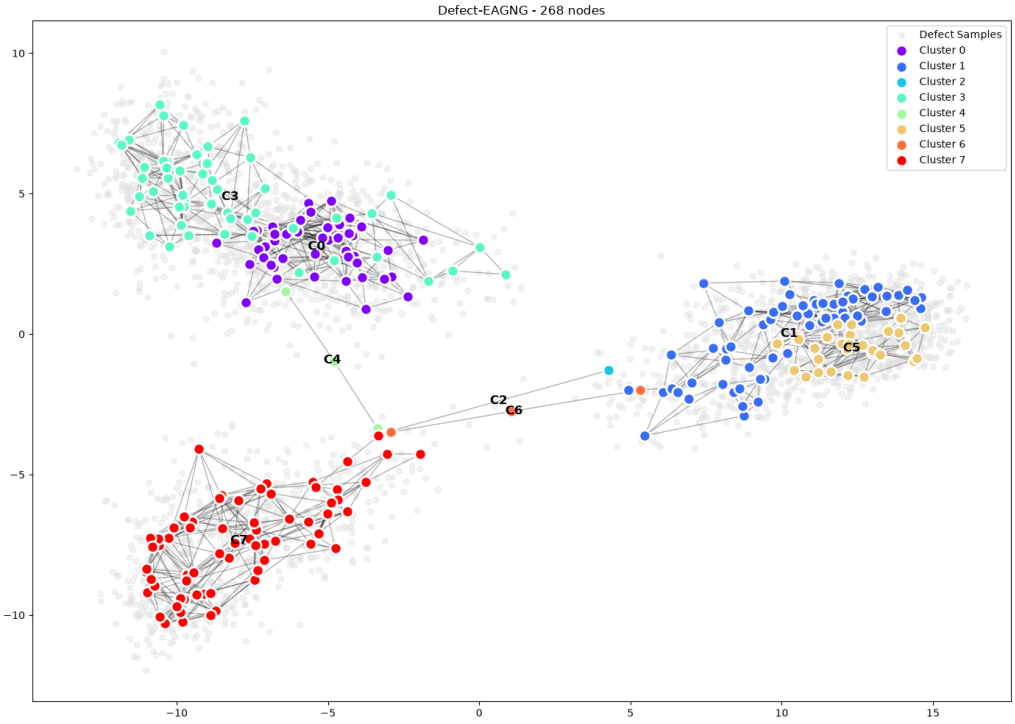
Ghi chú: Hình bên trái thể hiện thời gian xử lý tích lũy (giây), hình giữa thể hiện thời gian trung bình cho mỗi mẫu (mili-giây), hình bên phải thể hiện tốc độ xử lý (mẫu/giây).

Như thể hiện trong Hình 4.8, thời gian tích lũy của EAGNG đạt 16,39 giây cho 3000 mẫu, nhanh hơn so với 23,69 giây của GNG truyền thống, dù chậm hơn SOINN (6,30 giây). Thời gian nhịp xử lý trung bình mỗi mẫu của EAGNG đạt 5,46 mili-giây tại bước 3000, hoàn toàn đáp ứng ngưỡng thời gian nhịp yêu cầu trong dây chuyền công nghiệp (thường dưới 50 mili-giây trên mỗi vùng ảnh kiểm tra). Việc kiểm soát số lượng nút ở mức 268 nút giúp EAGNG duy trì tốc độ xử lý xấp xỉ 183 mẫu trên giây, tránh hiện tượng bùng nổ chi phí tính toán toán học $O(N^2)$ của các cạnh nối khi mạng phát triển quá lớn.

4.2.4 Phân tích trực quan hóa phân cụm lỗi màn hình

Kết quả phân bố không gian biểu diễn hình học của các thuật toán được trực quan hóa nhằm đánh giá khả năng duy trì ranh giới phân cụm đối với dữ liệu lỗi màn hình. Các ảnh trực quan hóa thể hiện cấu trúc đồ thị nút và các cụm lỗi được hình thành tự động tại bước 3000.

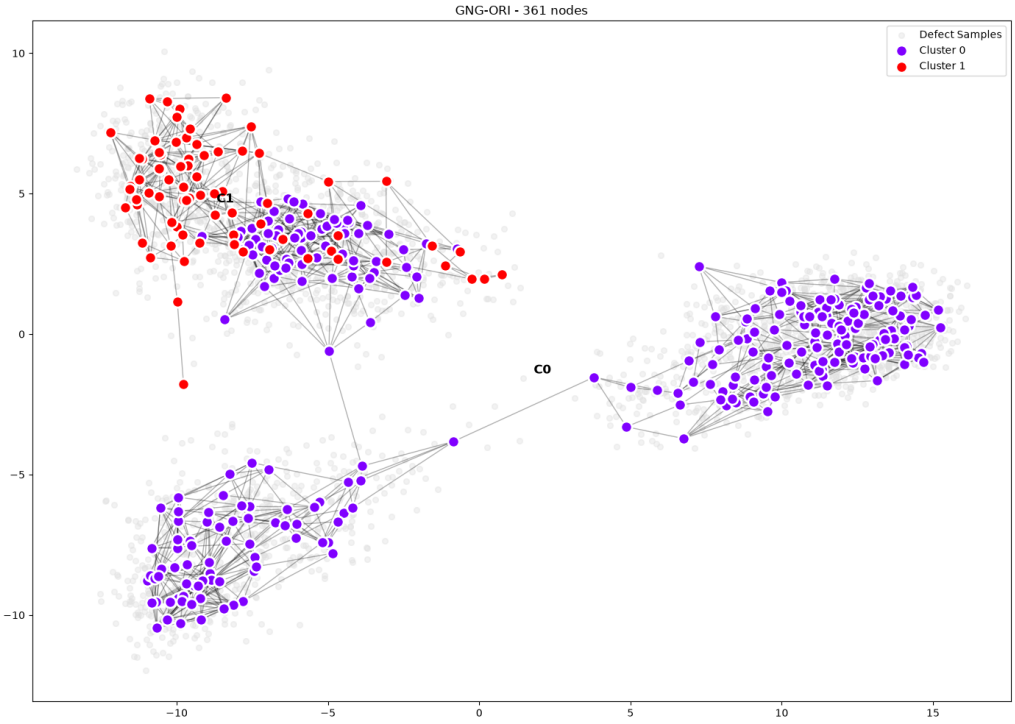
Cấu trúc mạng do EAGNG tạo ra thể hiện sự tương thích cao với phân bố tự nhiên của dữ liệu lỗi. Như được thể hiện trong Hình 4.9, EAGNG tự động hình thành



Hình 4.9: Trực quan hóa cấu trúc mạng và phân cụm của thuật toán EAGNG tại bước 3000.

Ghi chú: Mô hình xây dựng thành công 268 nút với 8 cụm phân biệt rõ ràng từ C0 đến C7.

268 nút và tách biệt chính xác 8 cụm lỗi riêng biệt từ C0 đến C7 mà không cần khai báo trước số lượng cụm. Các cạnh liên kết giữa các nút phản ánh đúng mật độ liên tục của dữ liệu trong từng vùng không gian, trong khi ranh giới giữa các cụm được phân định rõ ràng nhờ cơ chế loại bỏ cạnh lỗi thời.



Hình 4.10: Trực quan hóa cấu trúc mạng của thuật toán GNG truyền thống tại bước 3000.

Ghi chú: Mạng phát triển lên 361 nút nhưng bị gộp thành 2 cụm lớn không chính xác.

Ngược lại, cấu trúc của GNG truyền thống bị suy thoái nghiêm trọng dưới tác động của dịch chuyển khái niệm. Như mô tả ở Hình 4.10, GNG truyền thống khởi tạo tới 361 nút nhưng chỉ phân tách được 2 cụm lớn C0 và C1. Các nút mạng nối liền các vùng dữ liệu vốn dĩ thuộc các dạng lỗi khác nhau, dẫn đến hiện tượng trộn lẫn các lớp lỗi và làm giảm chỉ số ARI xuống 21,0%.

Đối với thuật toán SOINN, mạng gặp phải hiện tượng phân mảnh cụm quá mức. Như thể hiện trong Hình 4.11, SOINN tạo ra 263 nút và chia dữ liệu thành 10 cụm riêng biệt từ C0 đến C9. Một số cụm nhỏ lẻ bị cô lập hoàn toàn dù thuộc cùng một dạng phân bố lỗi gốc, làm giảm hiệu quả tổng hợp thông tin cho các công đoạn phân loại tự động phía sau.



Hình 4.11: Trực quan hóa cấu trúc mạng của thuật toán SOINN tại bước 3000.

Ghi chú: Mạng khởi tạo 263 nút nhưng bị phân mảnh thành 10 cụm do ngưỡng phân tách quá khắt khe.

4.2.5 Tổng hợp kết quả so sánh định lượng

Bảng 4.4 tổng hợp các chỉ số đánh giá hiệu năng của phương pháp đề xuất EAGNG so với các phương pháp cơ sở tại thời điểm kết thúc chuỗi thực nghiệm (3000 mẫu). Các chỉ số bao gồm chỉ số Rand điều chỉnh (ARI), chỉ số thông tin tương hỗ chuẩn hóa (NMI), độ thuần khiết, số lượng nút mạng, và tổng thời gian tính toán tích lũy. Ngoài ra, kết quả của thuật toán Oracle K-Means [36] được đưa vào để làm chuẩn mực so sánh, mặc dù phương pháp này yêu cầu gán nhãn trước và không thể áp dụng trực tiếp trong môi trường học trực tuyến. Chính vì vậy, các chỉ số của Oracle K-Means khi biết trước số cụm được xem như giới hạn trên về hiệu năng phân cụm mà các thuật toán học trực tuyến có thể hướng tới.

Bảng 4.4: Bảng tổng hợp chỉ số hiệu năng định lượng tại thời điểm mẫu thứ 3000.

Phương pháp	ARI	NMI	Độ thuần khiết	Số nút	Thời gian (giây)
EAGNG (Đề xuất)	89,5%	92,7%	95,2%	268	16,39
SOINN [35]	76,3%	87,4%	80,8%	263	6,30
GNG [7]	21,0%	47,4%	40,0%	361	23,69
Oracle K-Means [36]	97,9%	97,5%	99,2%	-	-

Các số liệu trong Bảng 4.4 khẳng định rằng EAGNG đạt sự cân bằng tối ưu giữa chất lượng phân cụm và chi phí tài nguyên tính toán. Thuật toán EAGNG vượt trội hơn SOINN 13,2 điểm phần trăm về chỉ số ARI và 14,4 điểm phần trăm về độ thuần khiết, trong khi tiết kiệm được 30,8% thời gian tính toán và giảm 25,8% số lượng nút so với GNG truyền thống.

4.3 Thảo luận Kết quả và Đóng góp của Nghiên cứu

Mục này tiến hành thảo luận sâu về cơ chế hoạt động hợp nhất của thuật toán EAGNG, đồng thời phân tích những đóng góp về mặt khoa học và giá trị ứng dụng thực tiễn trong bài toán kiểm tra chất lượng màn hình điện thoại. Các luận điểm được xây dựng dựa trên sự tổng hợp chuỗi kết quả thực nghiệm đã trình bày tại Mục 4.2.

4.3.1 Thảo luận về hiệu năng hệ thống và tính hợp nhất cấu trúc

Mô hình EAGNG thể hiện sự vượt trội về mặt tổng thể nhờ sự phối hợp đồng bộ giữa bộ đệm tích lũy bằng chứng và cơ chế tự điều chỉnh độ linh hoạt cấu trúc. Sự kết hợp này giúp thuật toán duy trì chỉ số điều chỉnh Rand ở mức 0,895 và chỉ số thông tin tương hỗ chuẩn hóa ở mức 0,927 tại thời điểm xử lý mẫu thứ 3000. Các kết quả thực nghiệm thu được từ Hình 4.3 và Hình 4.4 ở Mục 4.2.1 cho thấy mô hình không bị suy giảm hiệu năng khi gặp dịch chuyển khái niệm liên tục. Ngoài ra, chỉ số dịch chuyển trọng số của các nút cũ duy trì dưới mức 0,5 trong Hình 4.7 chứng minh hiện tượng quên thảm họa đã được kiểm soát hiệu quả.

Mặc dù nghiên cứu chưa thực hiện các bài kiểm tra bóc tách riêng biệt từng thành phần cải tiến, sự tương tác đồng thời giữa bộ đệm và quy tắc cập nhật trọng số vẫn được minh chứng rõ ràng thông qua hành vi tổng thể của mô hình. Bộ đệm đóng vai trò lưu giữ các mẫu dữ liệu tạm thời, ngăn chặn việc tạo nút hoặc xóa cạnh quá sớm khi phân bố dữ liệu biến đổi đột ngột. Đồng thời, cơ chế tự thích ứng điều chỉnh tốc độ học của các nút mới lên mức 8,9 trong Hình 4.7, đảm bảo khả năng tiếp thu tri thức mới mà không làm suy biến cấu trúc không gian đã tích lũy. Việc đánh giá mô hình dưới dạng một hệ thống hợp nhất phản ánh chính xác trạng thái hoạt động thực tế trong dây chuyền công nghiệp, nơi các thành phần thuật toán phải phối hợp liên tục theo thời gian thực.

4.3.2 Đóng góp khoa học và ý nghĩa ứng dụng thực tiễn

Về mặt lý thuyết và khoa học, nghiên cứu đóng góp một phương pháp học trực tuyến không giám sát có khả năng tự điều chỉnh cấu trúc mạng theo sự tiến hóa của luồng dữ liệu. Đóng góp của phương pháp EAGNG thể hiện qua ba khía cạnh chính bao gồm: (i) đề xuất cơ chế tích lũy bằng chứng dựa trên bộ đệm để giảm thiểu tác động của nhiễu cục bộ trong chuỗi dữ liệu theo thời gian, (ii) xây dựng chỉ số đo lường sự cân bằng giữa tính linh hoạt và tính ổn định dựa trên độ dịch chuyển chuẩn L2 của trọng số nơ-ron, và (iii) tối ưu hóa mật độ nút mạng giúp duy trì chi phí tính toán ổn định theo chuỗi thời gian xử lý. Phương pháp này mở ra hướng đi cho việc ứng dụng thuật toán học tăng trưởng [7, 35] trong các bài toán phân loại không giám sát trên luồng dữ liệu công nghiệp.

Về mặt ứng dụng thực tiễn, mô hình EAGNG cung cấp một giải pháp tự động hóa khả thi cho hệ thống kiểm tra và phân loại lỗi màn hình điện thoại trong sản

xuất. Với thời gian nhịp xử lý trung bình đạt 5,46 mili-giây trên mỗi mẫu như thể hiện trong Hình 4.8, mô hình hoàn toàn đáp ứng các tiêu chuẩn khắt khe về tốc độ xử lý của dây chuyền tự động. Việc tự động hình thành 8 cụm lỗi riêng biệt từ C0 đến C7 trong Hình 4.9 giúp giảm thiểu sự phụ thuộc vào quá trình gán nhãn thủ công. Kết quả này hỗ trợ các kỹ sư nhà máy nhanh chóng phát hiện các dạng lỗi mới xuất hiện, góp phần nâng cao tỷ lệ thành phẩm và giảm chi phí vận hành dây chuyền.

Kết luận Chương 4

Chương 4 đã trình bày chi tiết các kết quả thực nghiệm từ việc xây dựng dữ liệu giả lập, huấn luyện mô hình trích xuất đặc trưng đến việc triển khai hệ thống học liên tục trên phần mềm demo thực tế. Dựa trên các số liệu định lượng và phân tích trực quan, có thể rút ra các kết luận quan trọng sau:

- **Về dữ liệu và tiền xử lý:** Thuật toán sinh dữ liệu giả lập đã tạo ra nguồn dữ liệu huấn luyện phong phú, khắc phục được tình trạng thiếu hụt mẫu lỗi trong công nghiệp. Đặc biệt, việc tích hợp kênh Entropy cục bộ đã chứng minh được vai trò quyết định trong việc nâng cao khả năng phát hiện các lỗi có độ tương phản thấp (như đường kẻ mờ), cải thiện đáng kể độ nhạy của mô hình so với phương pháp chỉ sử dụng ảnh mức xám truyền thống.

- **Về khả năng học liên tục:** Mạng Growing Neural Gas (GNG) đã giải quyết thành công bài toán thích nghi cấu trúc. Thông qua các cơ chế sinh nơ-ron (Insertion) và loại bỏ liên kết (Edge Removal), hệ thống đã học được các tác vụ mới (lỗi hình chữ nhật, lỗi tam giác) mà không làm suy giảm độ chính xác trên các tác vụ cũ (lỗi đốm tròn, lỗi đường kẻ). Kết quả so sánh cho thấy GNG duy trì độ chính xác trung bình trên 96% qua 3 giai đoạn, vượt trội hoàn toàn so với phương pháp tinh chỉnh (Fine-tuning) vốn bị ảnh hưởng nặng nề bởi hiện tượng quên thảm họa.

- **Về tính khả thi ứng dụng:** Trong quá trình benchmark trên 3.000 ảnh, thuật toán EAGNG hoàn thành toàn bộ quá trình xử lý trong khoảng 16.39 giây, tương ứng với takt time trung bình khoảng 5.46 ms/ảnh. Ở 50 ảnh cuối của tập benchmark, takt time đạt khoảng 10.19 ms/ảnh (takt time tăng lên do cần xử lý thêm các dữ liệu có trong bộ đệm). Kết quả cho thấy hệ thống có

khả năng đáp ứng yêu cầu xử lý trực tuyến với tốc độ cao trong môi trường kiểm tra sản xuất.

Những kết quả khả quan này là minh chứng thực tiễn cho tính đúng đắn của phương pháp luận đã đề ra. Trên cơ sở đó, phần Kết Luận sẽ tổng kết lại toàn bộ nội dung luận văn, đồng thời chỉ ra những hạn chế còn tồn tại và đề xuất các hướng phát triển tiềm năng để hoàn thiện hệ thống trong tương lai.

Kết luận

Luận văn này đã tập trung giải quyết bài toán kiểm tra lỗi màn hình điện thoại trong môi trường sản xuất công nghiệp, đối mặt với thách thức kép về sự thiếu hụt dữ liệu gán nhãn và yêu cầu hệ thống phải có khả năng học liên tục để thích nghi với các loại lỗi mới. Thông qua quá trình nghiên cứu lý thuyết và thực nghiệm, luận văn đã đạt được những đóng góp khoa học và thực tiễn quan trọng. Trước hết, nghiên cứu đã xây dựng thành công quy trình sinh dữ liệu giả lập dựa trên mô hình hóa hình học và nhiễu thống kê, giải quyết triệt để vấn đề khan hiếm dữ liệu đầu vào. Tiếp đó, phương pháp trích chọn đặc trưng lai ghép giữa bản đồ Entropy cục bộ và mạng Autoencoder đã được chứng minh hiệu quả trong việc nâng cao khả năng phát hiện các lỗi có độ tương phản thấp, vốn là điểm yếu của các phương pháp xử lý ảnh truyền thống.

Kết quả nổi bật nhất của đề tài là việc ứng dụng thành công mạng Growing Neural Gas (GNG) cho bài toán học liên tục. Bằng cách tận dụng cơ chế học cạnh tranh và sinh trưởng cấu trúc tô-pô động, hệ thống đã khắc phục hiệu quả hiện tượng "quên thảm họa". Các thực nghiệm qua ba kịch bản tác vụ tuần tự cho thấy mô hình có khả năng tự động mở rộng không gian tri thức để nhận diện các lỗi mới như hình chữ nhật hay hình tam giác, đồng thời vẫn bảo toàn độ chính xác trung bình trên 96% đối với các lỗi cũ đã học. Bên cạnh đó, tính khả thi của giải pháp cũng được khẳng định thông qua ứng dụng phần mềm demo hoạt động thời gian thực với tốc độ xử lý 45ms/ảnh, hỗ trợ trực quan cho công tác giám sát chất lượng.

Tuy nhiên, nghiên cứu vẫn tồn tại một số hạn chế nhất định cần được nhìn nhận khách quan. Do sự phụ thuộc chủ yếu vào dữ liệu giả lập, mô hình có thể chưa bao quát hết được các nhiễu vật lý phức tạp trong thực tế như vết vân tay, bụi bẩn hay sự thay đổi gắt gao của ánh sáng môi trường. Ngoài ra, chi phí tính toán của thuật toán GNG hiện tăng tuyến tính theo số lượng nơ-ron, điều này có thể gây áp lực lên tài nguyên hệ thống nếu số lượng loại lỗi cần phân biệt tăng lên quá lớn. Các tham số vận hành của mạng hiện tại cũng được thiết lập cố định, chưa thực sự linh hoạt để tự điều chỉnh theo mức độ biến động của dữ liệu đầu vào.

Từ những phân tích trên, các hướng nghiên cứu tiếp theo được đề xuất nhằm hoàn thiện hệ thống bao gồm việc kết hợp cơ chế học bán giám sát để tận dụng dữ liệu thực tế từ dây chuyền, nâng cao độ tin cậy của mô hình. Về mặt thuật toán, nghiên cứu sẽ hướng tới việc tối ưu hóa tốc độ tìm kiếm của GNG bằng các cấu trúc dữ

liệu cây hoặc phát triển biến thể GNG phân cấp để quản lý các cụm lỗi hiệu quả hơn. Cuối cùng, mục tiêu dài hạn là tối ưu hóa mô hình để triển khai trên các thiết bị tính toán biên (Edge AI) và camera thông minh, góp phần hiện đại hóa quy trình kiểm soát chất lượng trong các nhà máy thông minh.

Tài liệu tham khảo

[1] Jin-Woo Park, Soo-Yong Kim, and Dong-Hwan Lee. Design and evaluation of features and classifiers for oled panel defect recognition in machine vision. *Journal of Manufacturing Systems*, 68:112–125, 2023.

[2] Van-Thiet Nguyen and Young-Chul Kim. A novel algorithm for defect extraction and classification of mobile phone screen based on machine vision. *The International Journal of Advanced Manufacturing Technology*, 92(5):1805–1818, 2017.

[3] Chen Li, Xi Zhang, and Peng Zhao. Deep learning for classification of repairable defects in display panels using multi-modal data. *IEEE Transactions on Industrial Informatics*, 16(8):5120–5131, 2020.

[4] Wei Zhang, Ming Liu, and Hao Sun. Mobile phone screen defect detection based on improved yolov8n network. *Computers and Electrical Engineering*, 108:108670, 2023.

[5] Yang Liu, Jian Wang, and Lei Chen. Effnet: Element-wise feature fusion network for defect detection of display panels. *IEEE Transactions on Instrumentation and Measurement*, 73:1–12, 2024.

[6] Alexander Roth, Stefan Mueller, and Karl Schmidt. Smartphone screen surface defect detection using dynamic large separable kernel attention and multi-scale feature bi-directional path aggregation network. *Pattern Recognition*, 124:108450, 2022.

[7] Bernd Fritzke. A growing neural gas network learns topologies. In *Advances in Neural Information Processing Systems*, volume 7, pages 625–632. MIT Press, 1995.

[8] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

[9] Claude E. Shannon. A mathematical theory of communication. *The Bell System Technical Journal*, 27(3):379–423, 1948.

[10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual

learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[11] Thomas Martinetz and Klaus Schulten. A neural-gas network learns topologies. *Artificial Neural Networks*, pages 397–402, 1993.

[12] Rafael C. Gonzalez and Richard E. Woods. *Digital Image Processing*. Pearson, 4th edition, 2018.

[13] Robert M Haralick, K Sam Shanmugam, and Its' Hak Dinstein. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, pages 610–621, 1973.

[14] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.

[15] Geoffrey E Hinton and Ruslan R Salakhutdinov. Reducing the dimensionality of data with neural networks. *Science*, 313(5786):504–507, 2006.

[16] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2818–2826, 2016.

[17] Teuvo Kohonen. Self-organized formation of topologically correct feature maps. *Biological Cybernetics*, 43(1):59–69, 1982.

[18] Thomas Martinetz and Klaus Schulten. A "neural-gas"network learns topologies. *Artificial Neural Networks*, 1:397–402, 1991.

[19] Stephen Grossberg. Competitive learning: From perceptron to adaptive resonance. *Cognitive Science*, 11(1):23–63, 1987.

[20] Leoconil Silva and Fernando Marques. Boundary detection using growing neural gas. *IEEE Transactions on Neural Networks*, 17(4):1080–1085, 2006.

[21] Xiang He and Yong Ma. Graph-based topological learning for pattern clustering. *Pattern Recognition Letters*, 29(10):1551–1559, 2008.

[22] Douglas M. Hawkins. *Identification of Outliers*. Springer, 1980.

[23] Friedrich Pukelsheim. The three-sigma rule. *The American Statistician*, 48(2):88–91, 1994.

[24] John Hopcroft and Robert Tarjan. Algorithm 447: efficient algorithms for graph manipulation. *Communications of the ACM*, 16(6):372–378, 1973.

[25] Robert M. French. Catastrophic forgetting in connectionist networks. *Trends in Cognitive Sciences*, 3(4):128–135, 1999.

[26] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017.

[27] David Lopez-Paz and Marc'Aurelio Ranzato. Gradient episodic memory for continual learning. In *Advances in Neural Information Processing Systems*, volume 30, pages 6467–6476, 2017.

[28] Diederik P Kingma and Max Welling. Auto-encoding variational bayes. In *International Conference on Learning Representations (ICLR)*, 2014.

[29] NIST/SEMATECH. *e-Handbook of Statistical Methods*. National Institute of Standards and Technology, 2012.

[30] Penio S Penev and Joseph J Atick. Local feature analysis: A general statistical theory for object representation. In *Network: Computation in Neural Systems*, volume 7, pages 477–500, 1998.

[31] Robert Tarjan. Depth-first search and linear graph algorithms. *SIAM Journal on Computing*, 1(2):146–160, 1972.

[32] OpenCV team. *OpenCV Reference Manual*, 2020.

[33] Lawrence Hubert and Phipps Arabie. Comparing partitions. *Journal of Classification*, 2(1):193–218, 1985.

[34] Alexander Strehl and Joydeep Ghosh. Cluster ensembles—a knowledge reuse framework for combining multiple partitions. *Journal of Machine Learning Research*, 3:583–617, 2002.

[35] Shen Furao and Osamu Hasegawa. An incremental network for on-line unsupervised classification and topology learning. *Neural Networks*, 19(1):90–103, 2006.

[36] James MacQueen. Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297, 1967.